# Analítica de Datos

## Clase 2 - Data Profiling y Visualizaciones

# ¿Qué vieron con Pablo?

# Agenda

- Data Profiling & Visualization
- Caso de aplicación real
- TP de Pablo
- Notebook
- Kahoot

# Dos conceptos

Entender y analizar bien los datos es demasiado importante (En cualquier situación)

## Dos conceptos

Entender y analizar bien los datos es demasiado importante (En cualquier situación)

Podes visualizar bien, con buen concepto, es una herramienta que les va a dar mucho laburo

# ¿Qué es el data profiling?

# ¿Qué es el data profiling?

## Técnica para entender los datos

# ¿Qué es el data profiling?

**Técnica para entender los datos**

- Entender la estructura de los datos

# ¿Qué es el data profiling?

**Técnica para entender los datos**

- Entender la estructura de los datos
- Evaluar la calidad del dataset

# ¿Qué es el data profiling?

**Técnica para entender los datos**

- Entender la estructura de los datos
- Evaluar la calidad del dataset
- Identificar problemas potenciales

# ¿Qué es el data profiling?

**Técnica para entender los datos**

- Entender la estructura de los datos
- Evaluar la calidad del dataset
- Identificar problemas potenciales
- Primer paso (Y usualmente el más dificil) en cualquier proyecto de analítica

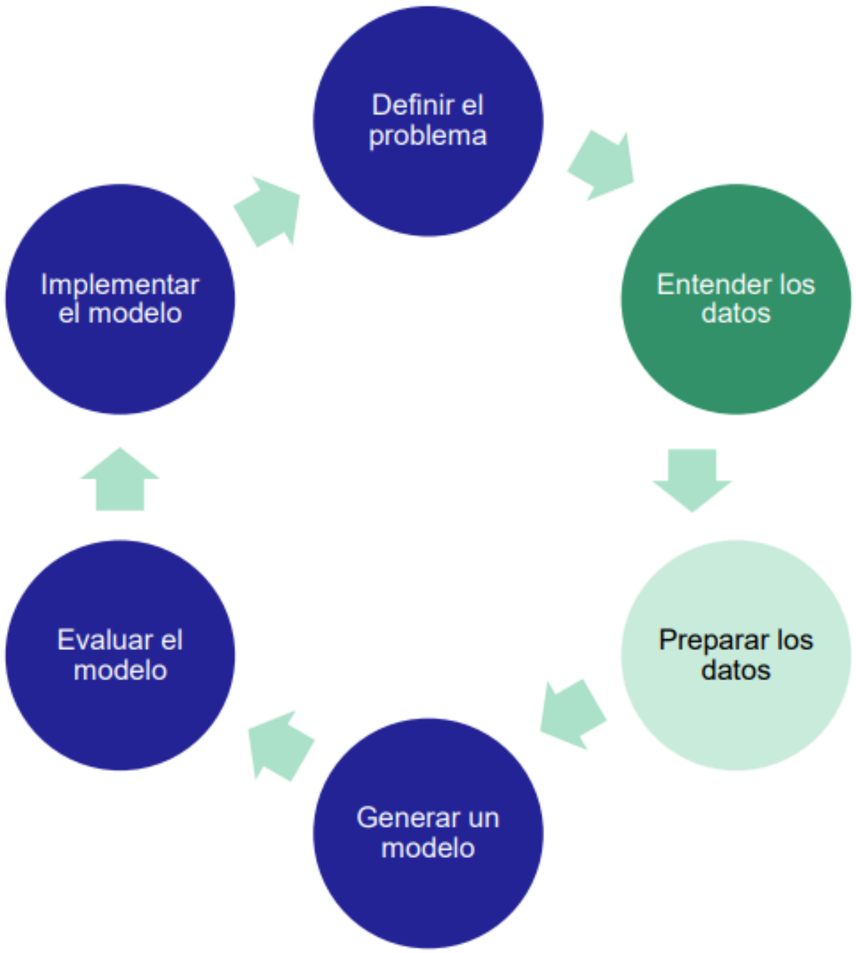
Definir el problema
Entender los datos
Preparar los datos
Generar un modelo
Evaluar el modelo
Implementar el modelo

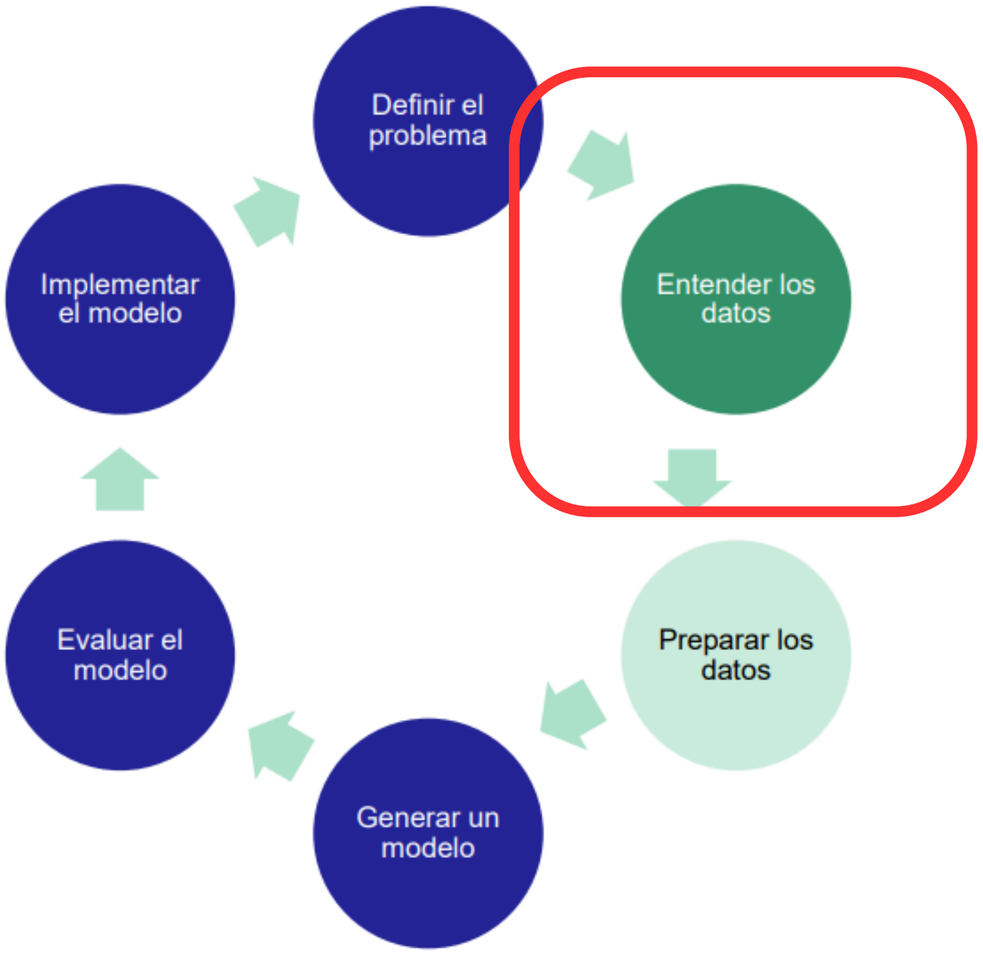
Definir el problema
Entender los datos
Preparar los datos
Generar un modelo
Evaluar el modelo
Implementar el modelo

# Entender los datos

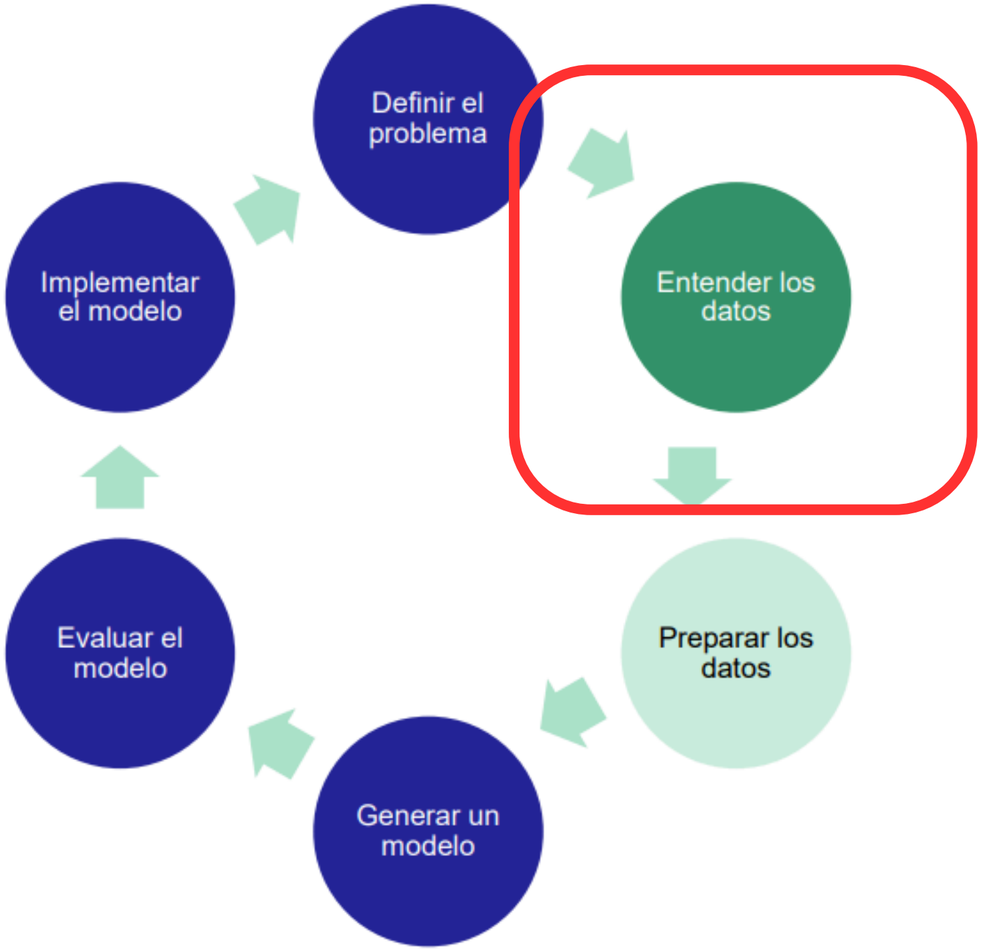

# Entender las variables

## Variables numéricas

# Entender las variables

**Variables numéricas**

Dos tipos... ¿?

# Entender las variables

## Variables numéricas

**Continuas**: Valores enteros específicos
**Discretas**: Cualquier valor en un rango

# Entender las variables

## Variables numéricas

**Continuas**: Valores enteros específicos
**Discretas**: Cualquier valor en un rango

## Variables categóricas

También dos tipos...

# Entender las variables

## Nominales

## Ordinales

# Entender las variables

## Variables numéricas

**Continuas**: Valores enteros específicos
**Discretas**: Cualquier valor en un rango

## Variables categóricas

**Nominales:** Sin un orden natural
**Ordinales:** Con un orden natural

# Entender las variables

## Variables numéricas

**Continuas**: Valores enteros específicos
**Discretas**: Cualquier valor en un rango

## Variables categóricas

**Nominales:** Sin un orden natural
**Ordinales:** Con un orden natural

## ¿Otros tipos de variable?

# Entender las variables

## Variables numéricas

**Continuas**: Valores enteros específicos
**Discretas**: Cualquier valor en un rango

## Variables categóricas

**Nominales:** Sin un orden natural
**Ordinales:** Con un orden natural

## ¿Otros tipos de variable?

**Fechas:** Momentos específicos
**Variables compuestas:** Distintos tipos de datos

1. **Medidas de tendencia central**

2. **Medidas de dispersión**

3. **Datos faltantes**

1. **Medidas de tendencia central**

2. **Medidas de dispersión**

4. **Datos faltantes**

# Medidas de tendencia central

**¿Donde se concentran los datos?**

**Media**

**Mediana**

**Moda**

# Medidas de tendencia central

**¿Donde se concentran los datos?**

**Media:** Promedio de todos los valores

**Mediana**

**Moda**

# Medidas de tendencia central

¿Donde se concentran los datos?

**1, 1, 2, 3, 4, 5, 6, 10, 100**

**Media:** Promedio de todos los valores

**Mediana**

**Moda**

# Medidas de tendencia central

¿Donde se concentran los datos?

**Media:** Promedio de todos los valores

Mediana

Moda

$$1, 1, 2, 3, 4, 5, 6, 10, 100$$

$$1 + 1 + 2 + 3 + 4 + 5 + 6 + 10 + 100 = 132$$

# Medidas de tendencia central

¿Donde se concentran los datos?

**Media:** Promedio de todos los valores

Mediana

Moda

$$1, 1, 2, 3, 4, 5, 6, 10, 100$$

$$1 + 1 + 2 + 3 + 4 + 5 + 6 + 10 + 100 = 132$$

$$132/9 = 14.7$$

# Medidas de tendencia central

¿Donde se concentran los datos?

**Media:** Promedio de todos los valores

Mediana

Moda

**1, 1, 2, 3, 4, 5, 6, 10, 100**

**1 + 1 + 2 + 3 + 4 + 5 + 6 + 10 + 100 = 132**

**132/9 = 14.7**

En promedio, la gente gana 14 millones por año...¿ ?

# Medidas de tendencia central

**¿Donde se concentran los datos?**

**Media:** Promedio de todos los valores

**Mediana:** Valor central de la distribución

**Moda**

# Medidas de tendencia central

**¿Donde se concentran los datos?**

**1, 1, 2, 3, 4, 5, 6, 10, 100**

**Media:** Promedio de todos los valores

**Mediana:** Valor central de la distribución

**Moda**

# Medidas de tendencia central

**¿Donde se concentran los datos?**

**1, 1, 2, 3, 4, 5, 6, 10, 100**

**Media:** Promedio de todos los valores

**Mediana:** Valor central de la distribución **4**

**Moda**

# Medidas de tendencia central

**¿Donde se concentran los datos?**

**1, 1, 2, 3, 4, 5, 6, 10, 100**

**Media:** Promedio de todos los valores

**Mediana:** Valor central de la distribución **4**

**Moda**

La gente gana 4 millones por año... Mucho mejor !

# Medidas de tendencia central

**¿Donde se concentran los datos?**

**Media:** Promedio de todos los valores

**Mediana:** Valor central de la distribución

**Moda:** Valor más frecuente

# Medidas de tendencia central

**¿Donde se concentran los datos?**

**1, 1, 2, 3, 4, 5, 6, 10, 100**

**Media:** Promedio de todos los valores

**Mediana:** Valor central de la distribución

**Moda:** Valor más frecuente

# Medidas de tendencia central

**¿Donde se concentran los datos?**

**1, 1, 2, 3, 4, 5, 6, 10, 100**

**Media:** Promedio de todos los valores

**Mediana:** Valor central de la distribución **1**

**Moda:** Valor más frecuente

1. Medidas de tendencia central

2. **Medidas de dispersión**

3. Datos faltantes

# Medidas de dispersión

**Varianza:** Promedio de desviaciones al cuadrado

**Desviación Estandar**: Raíz cuadrada de la varianza

**Cuartil Q1, 2, 3 Y 4:** Valor que divide un conjunto de datos ordenados en cuatro partes iguales

**Rango Interquartil (IQR):** La diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1), y representa el 50 % central de los datos

# Medidas de dispersión

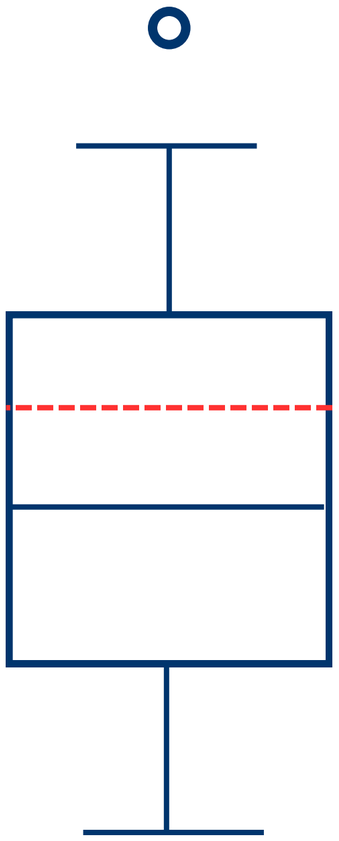

# Medidas de dispersión

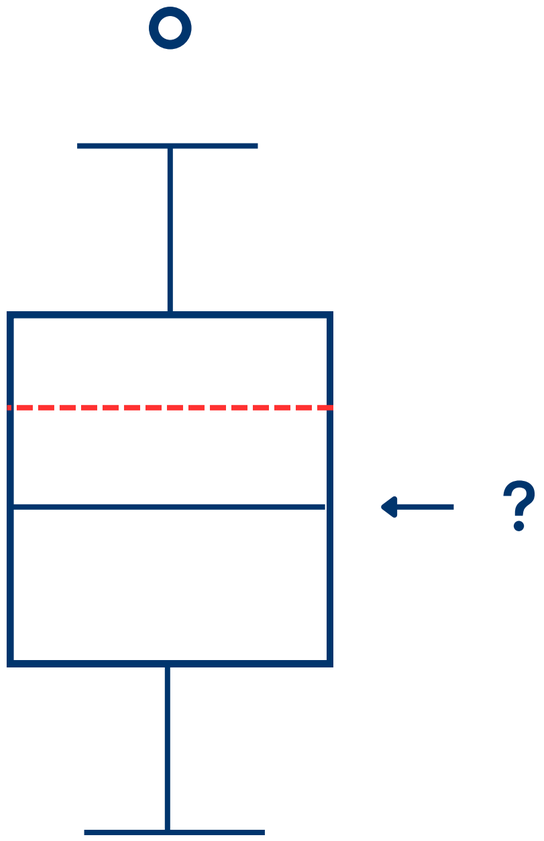

# Medidas de dispersión

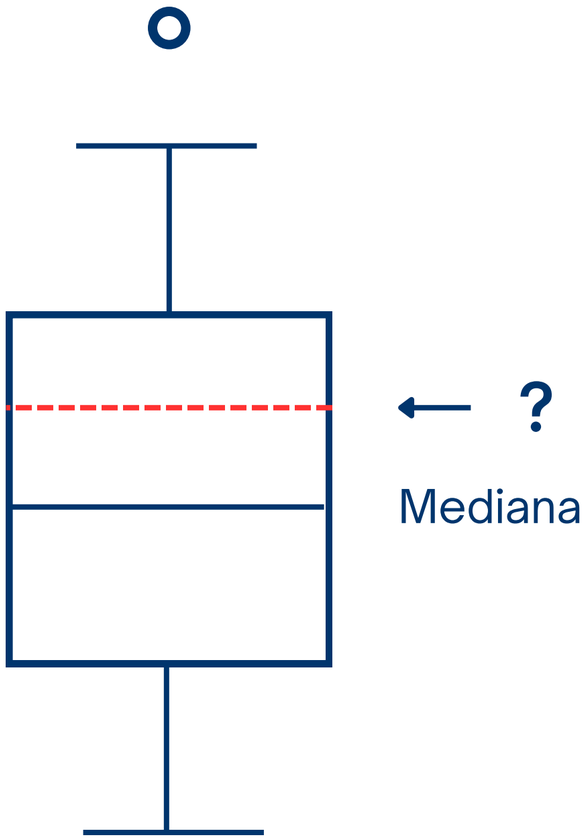

# Medidas de dispersión

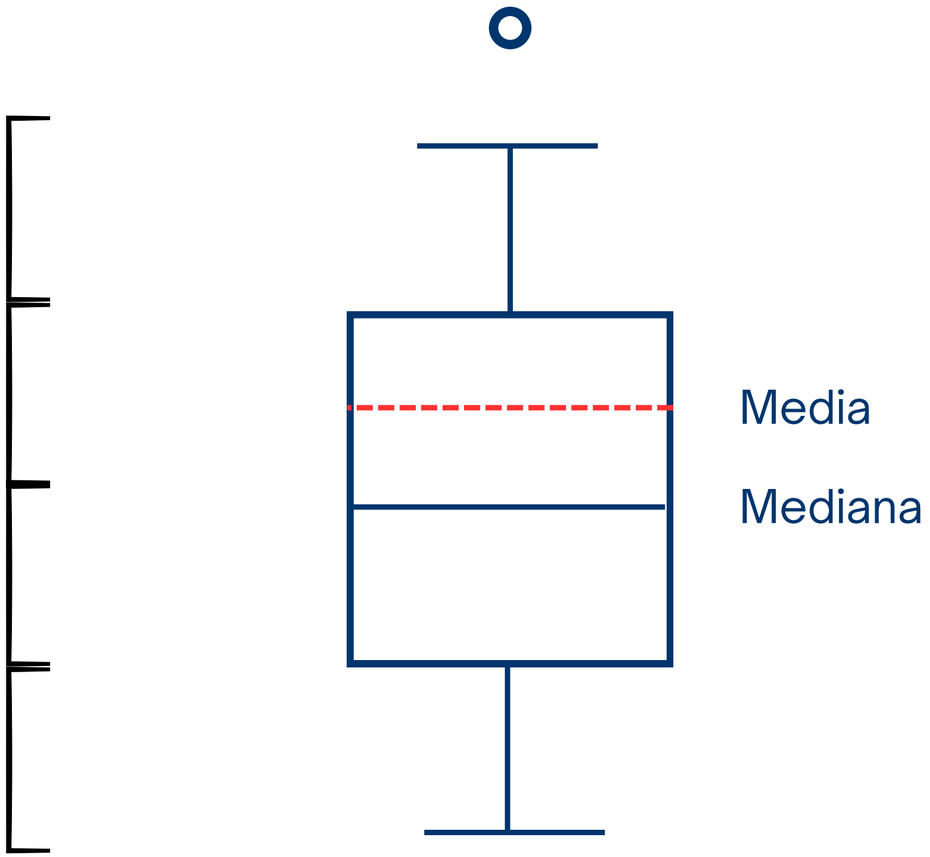

# Medidas de dispersión

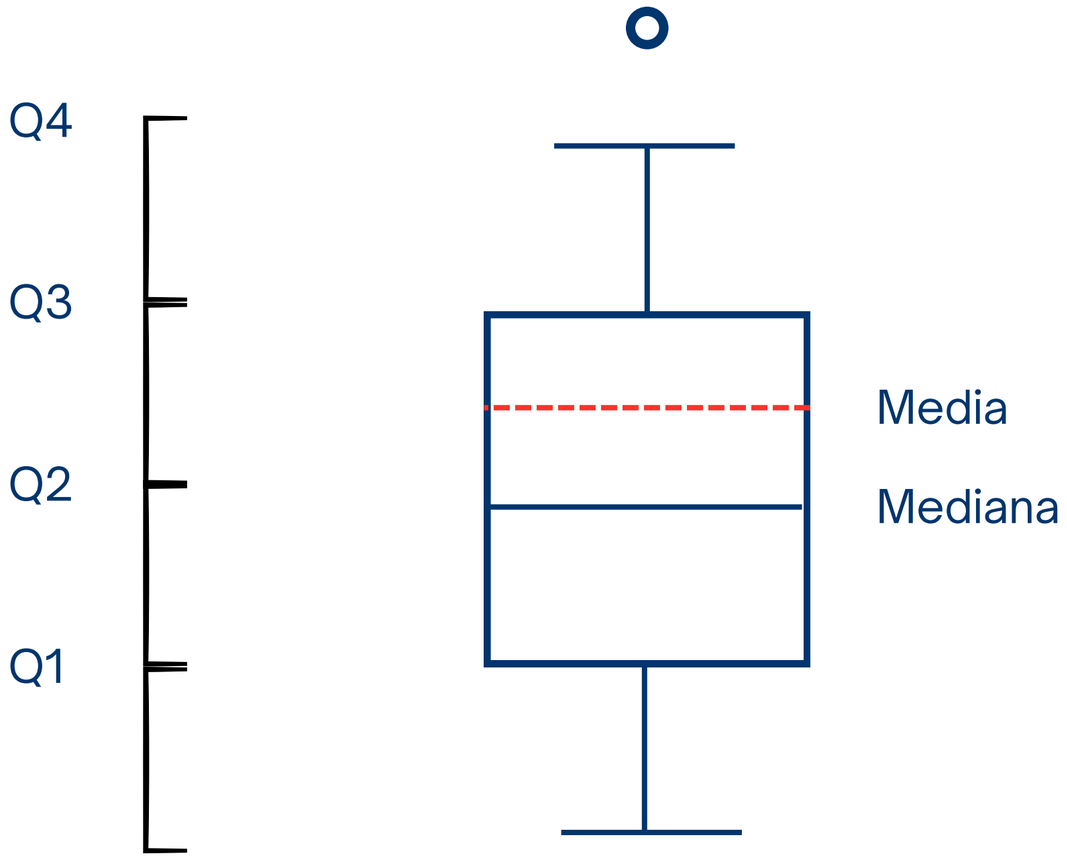

# Medidas de dispersión

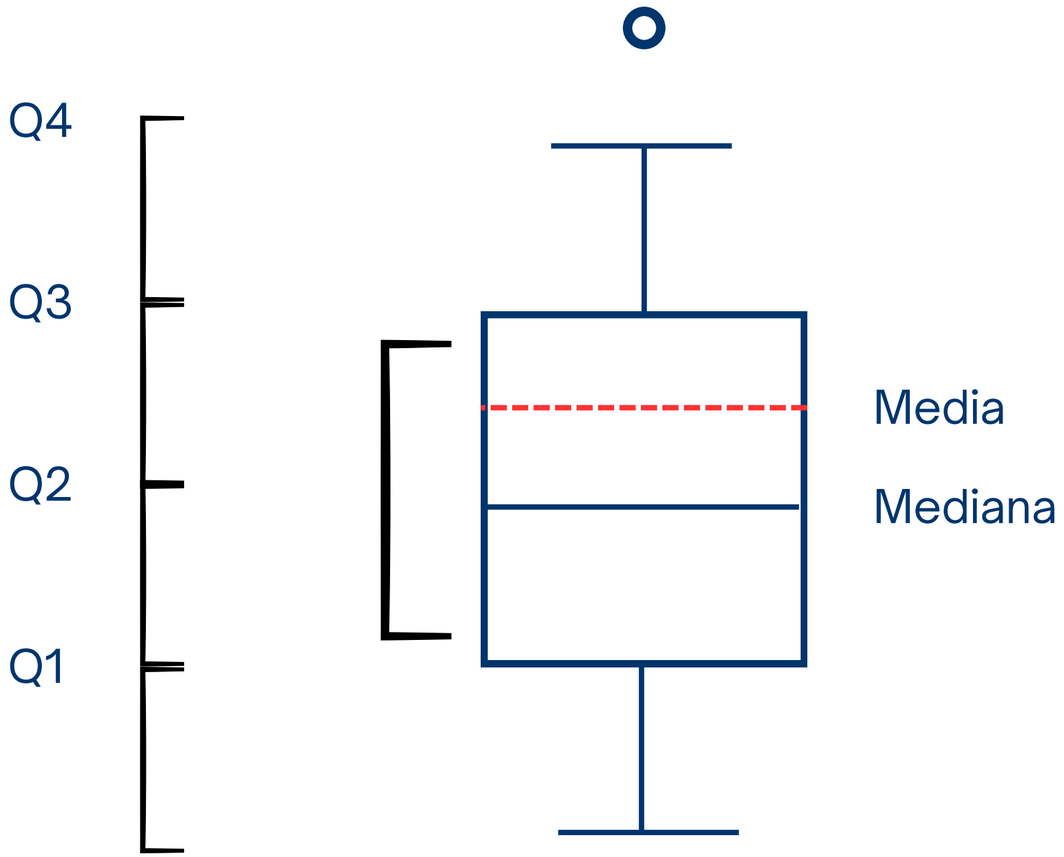

# Medidas de dispersión

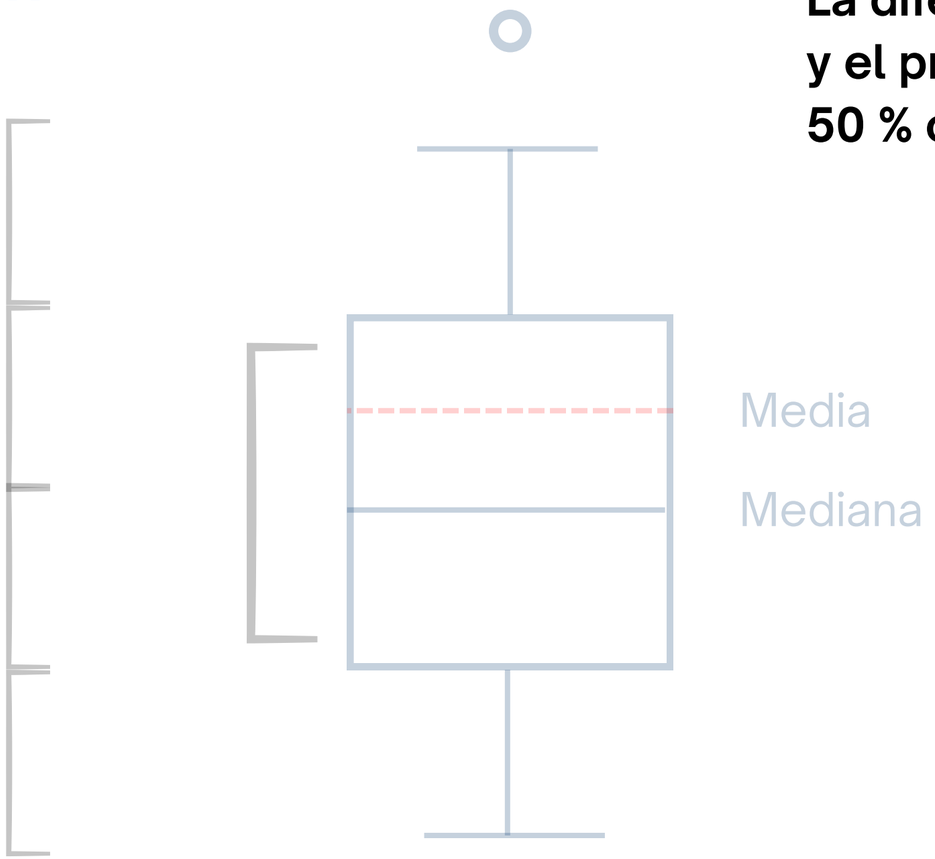


**La diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1), y representa el 50 % central de los datos**

# Medidas de dispersión

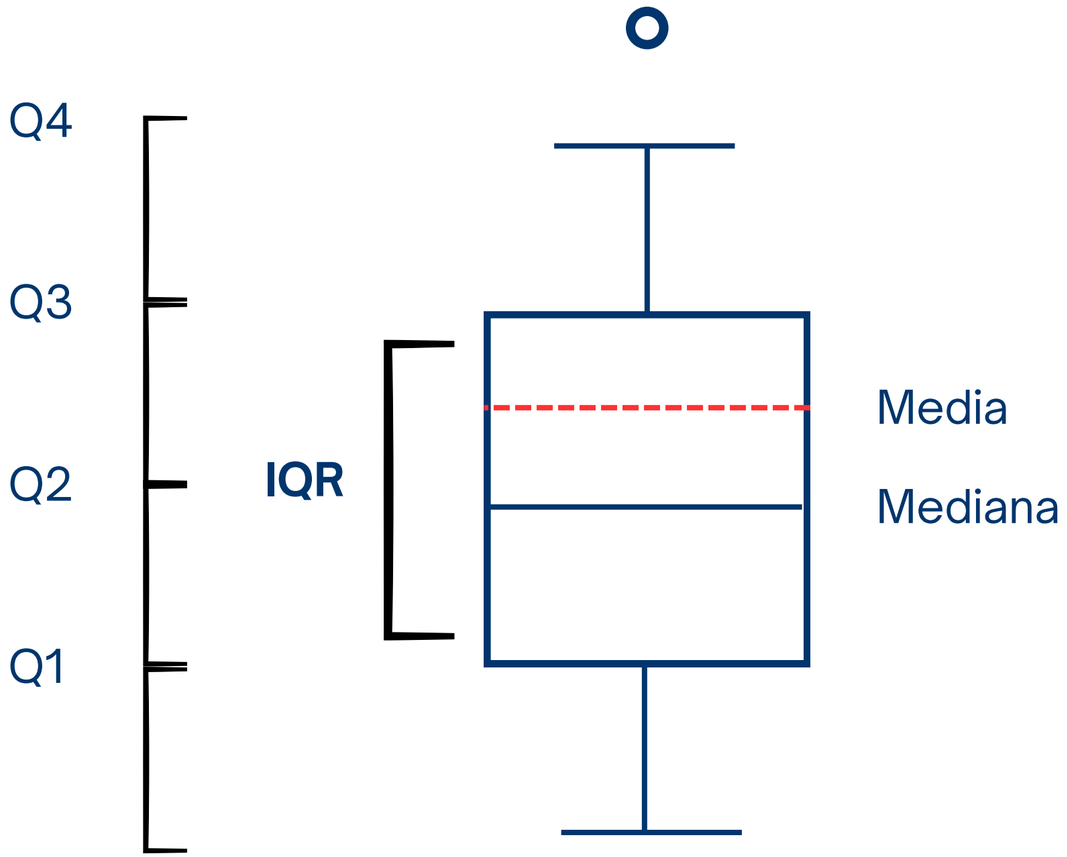

# Medidas de dispersión

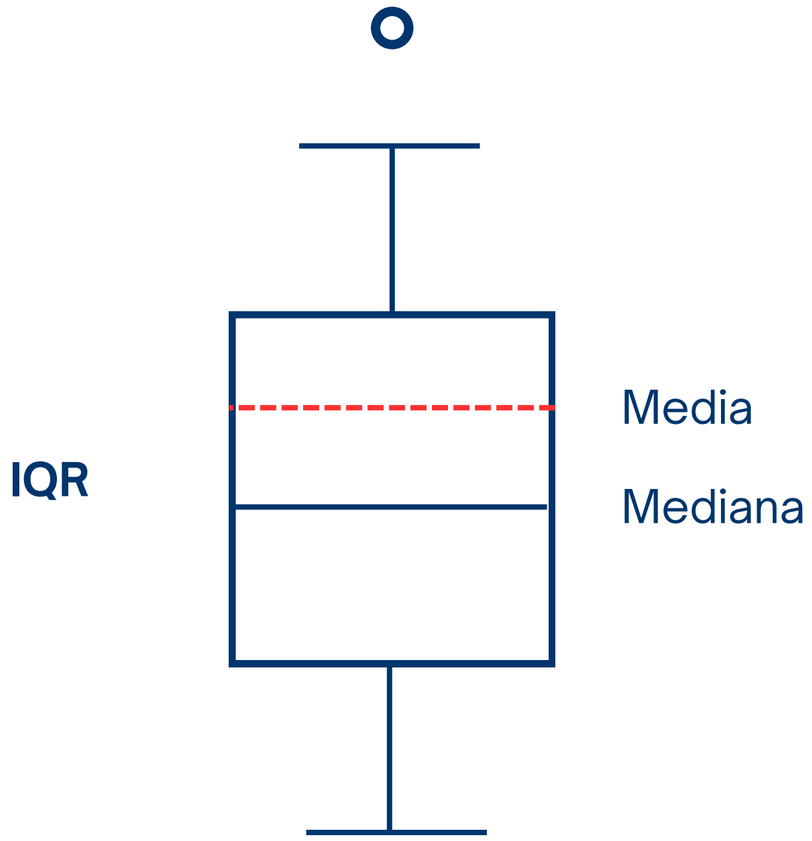

# Medidas de dispersión

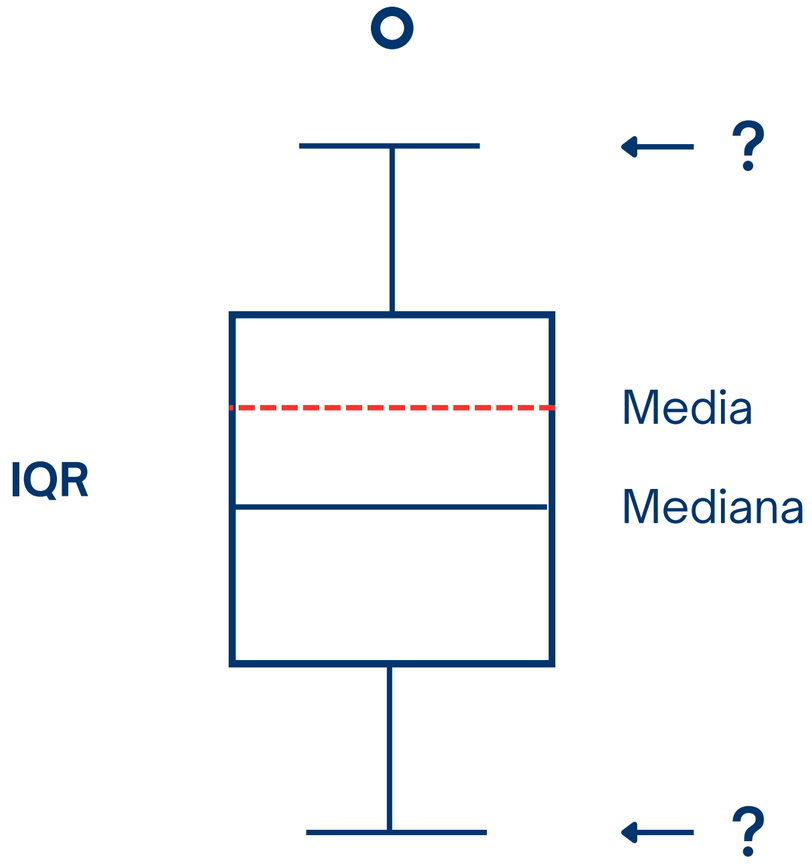

# Medidas de dispersión

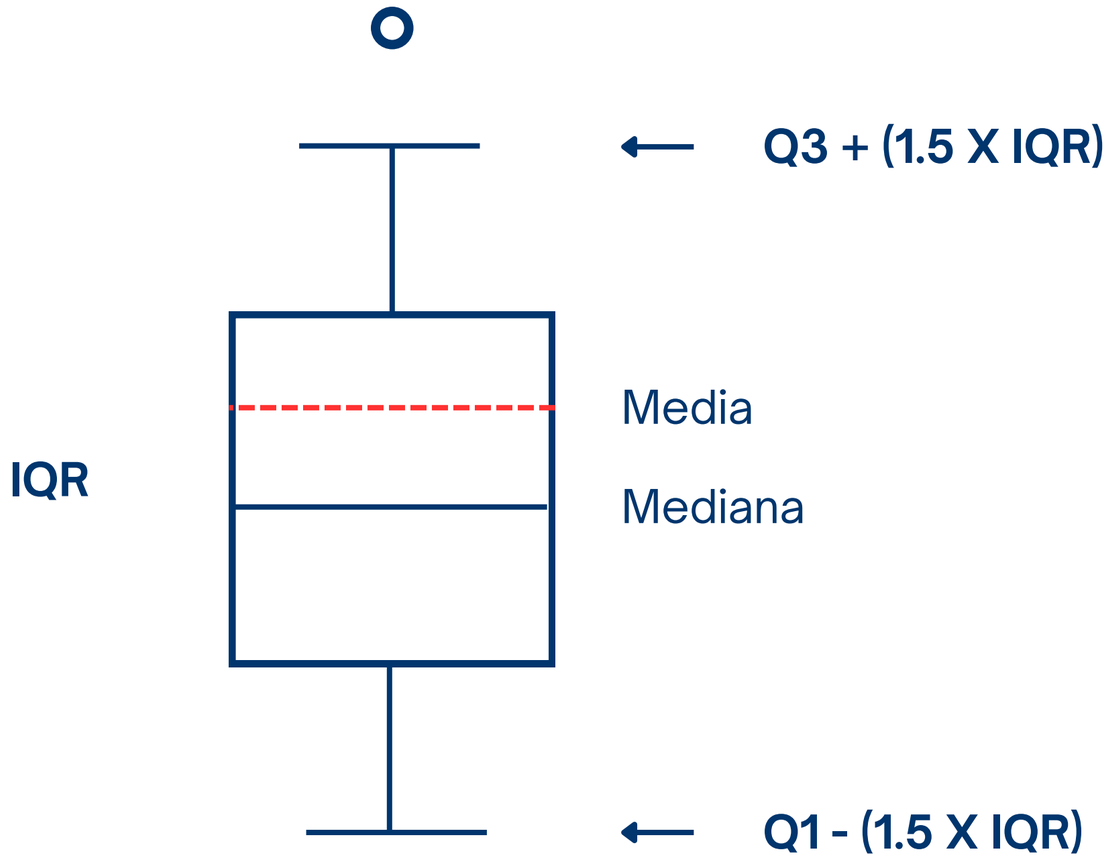

# Medidas de dispersión

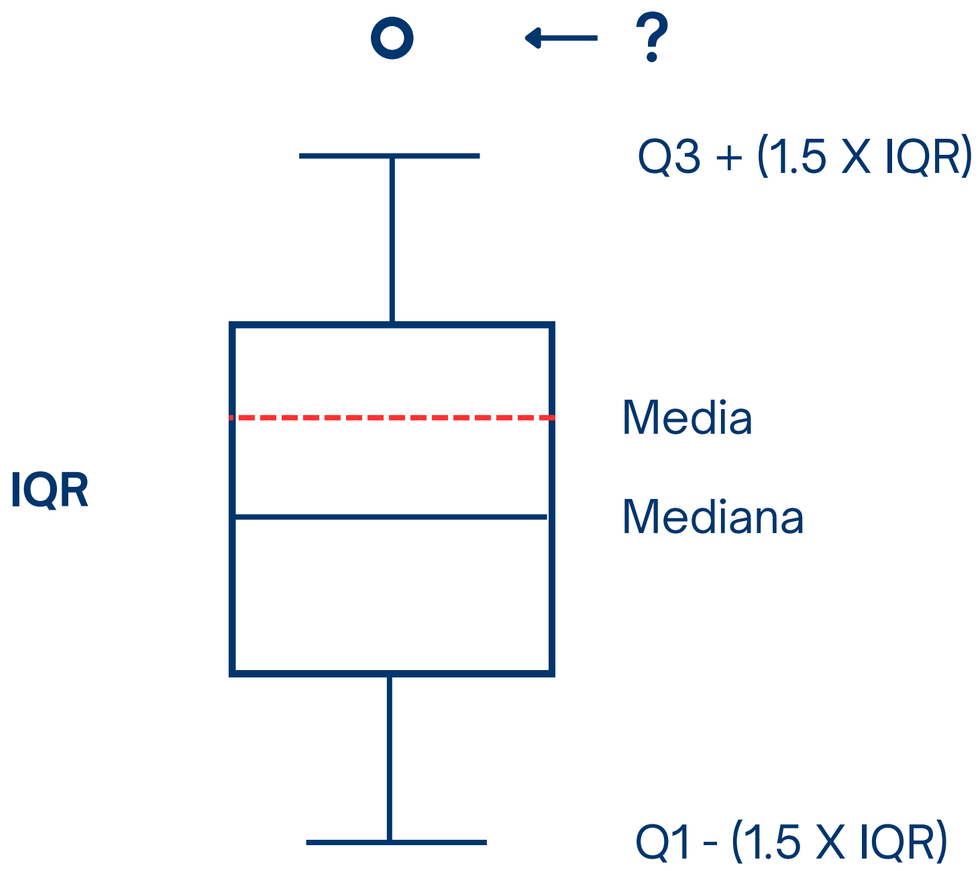

# Medidas de dispersión

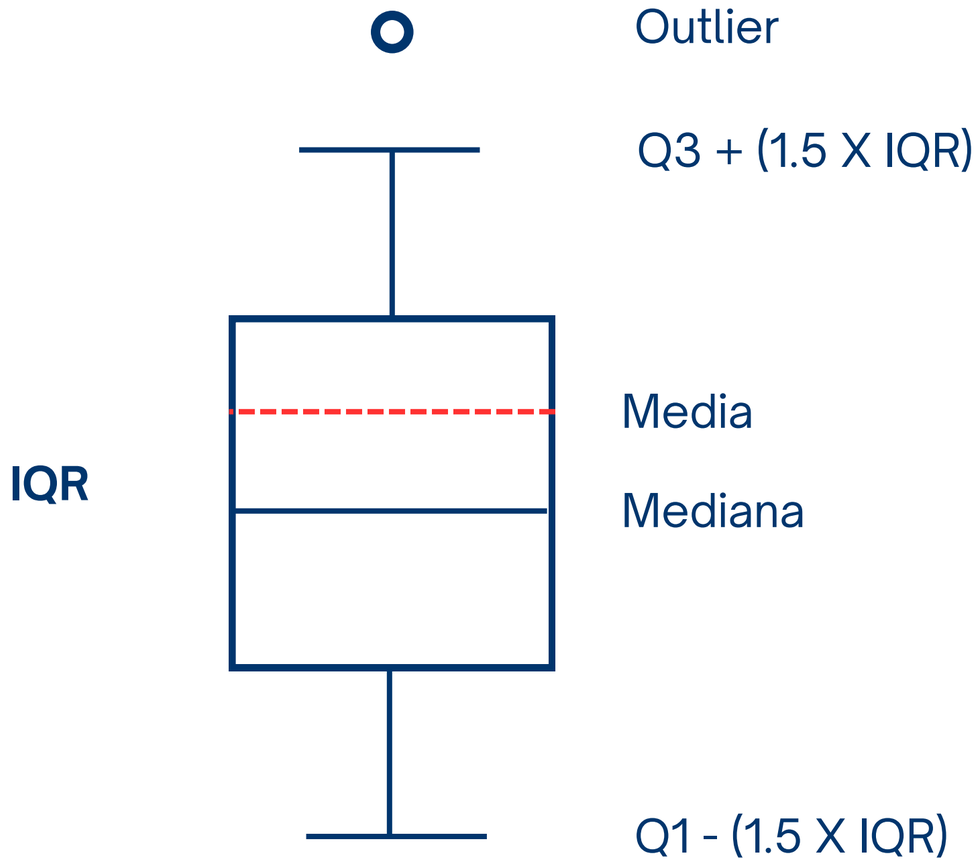

1. Medidas de tendencia central

2. Medidas de dispersión

3. **Datos faltantes**

# Datos faltantes

# Datos faltantes

**MCAR:** Missing Completely at Random

**MAR:** Missing at Random

**MNAR:** Missing not at Random

# Datos faltantes - MCAR

Los datos faltantes **no están relacionados** *con ninguna variable observable*.
El patrón de faltantes es **completamente** aleatorio.

# Datos faltantes - MCAR

| Id | Edad | Rubro | Salario |
|---|---|---|---|
| 1 | 29 | Abogado/a | 1.500.000 |
| 2 | 53 | **Null** | 430.000 |
| 3 | 21 | Analista de datos | **Null** |
| 4 | 34 | Analista de marketing | 1.000.000 |
| 5 | **Null** | A. financiero/a | 600.000 |
| 5 | 31 | Asesor/a del congreso | 700.000 |
| 6 | 48 | Recepcionista | **Null** |

# Datos faltantes - MCAR

| Id | Edad | Rubro | Salario |
|---|---|---|---|
| 1 | 29 | Abogado/a | 1.500.000 |
| 2 | 53 | **Null** | 430.000 |
| 3 | 21 | Analista de datos | **Null** |
| 4 | 34 | Analista de marketing | 1.000.000 |
| 5 | **Null** | A. financiero/a | 600.000 |
| 5 | 31 | Asesor/a del congreso | 700.000 |
| 6 | 48 | Recepcionista | **Null** |

Los datos faltantes aparecen de forma aleatoria sin relación con ninguna variable observable.
Los participantes se olvidaron de responder preguntas al azar

# Datos faltantes - MAR

Los datos faltantes **están relacionados** con variables **observables**, pero *no con el valor faltante mismo.*

# Datos faltantes - MAR

| Id | Edad | Rubro | Salario |
|---|---|---|---|
| 1 | 29 | Abogado | 1.500.000 |
| 2 | 37 | Profesora | 430.000 |
| 3 | 53 | Analista de datos | **Null** |
| 4 | 34 | Analista de marketing | 1.000.000 |
| 5 | 23 | A. financiera | 600.000 |
| 5 | 31 | Asesora del congreso | 700.000 |
| 6 | 48 | Recepcionista | **Null** |

## Datos faltantes - MAR

| Id | Edad | Rubro | Salario |
|---|---|---|---|
| 1 | 29 | Abogado | 1.500.000 |
| 2 | 37 | Profesora | 430.000 |
| 3 | 53 | Analista de datos | **Null** |
| 4 | 34 | Analista de marketing | 1.000.000 |
| 5 | 23 | A. financiera | 600.000 |
| 5 | 31 | Asesora del congreso | 700.000 |
| 6 | 48 | Recepcionista | **Null** |

La falta depende de los datos observados (la edad). Los entrevistados mayores de 40 años no se sienten cómodos de divulgar su salario.

# Datos faltantes - MNAR

Los datos faltantes **están relacionados con el valor faltante mismo**

# Datos faltantes - MNAR

| Id | Edad | Rubro | Salario |
|---|---|---|---|
| 1 | 45 | Abogado | Null |
| 2 | 52 | Profesora | 430.000 |
| 3 | 21 | Analista de datos | Null |
| 4 | 34 | Analista de marketing | Null |
| 5 | 23 | A. financiera | 600.000 |
| 5 | 31 | Asesora del congreso | 700.000 |
| 6 | 48 | Recepcionista | 770.000 |

# Datos faltantes - MNAR

| Id | Edad | Rubro | Salario |
|---|---|---|---|
| 1 | 45 | Abogado | Null |
| 2 | 52 | Profesora | 430.000 |
| 3 | 21 | Analista de datos | Null |
| 4 | 34 | Analista de marketing | Null |
| 5 | 23 | A. financiera | 600.000 |
| 5 | 31 | Asesora del congreso | 700.000 |
| 6 | 48 | Recepcionista | 770.000 |

La falta depende del dato que no tengo. Las personas con salarios más altos tienden a evitar contestar la pregunta.

# Datos faltantes

**¿Qué significa que un dato falte?**

# Visualización de datos

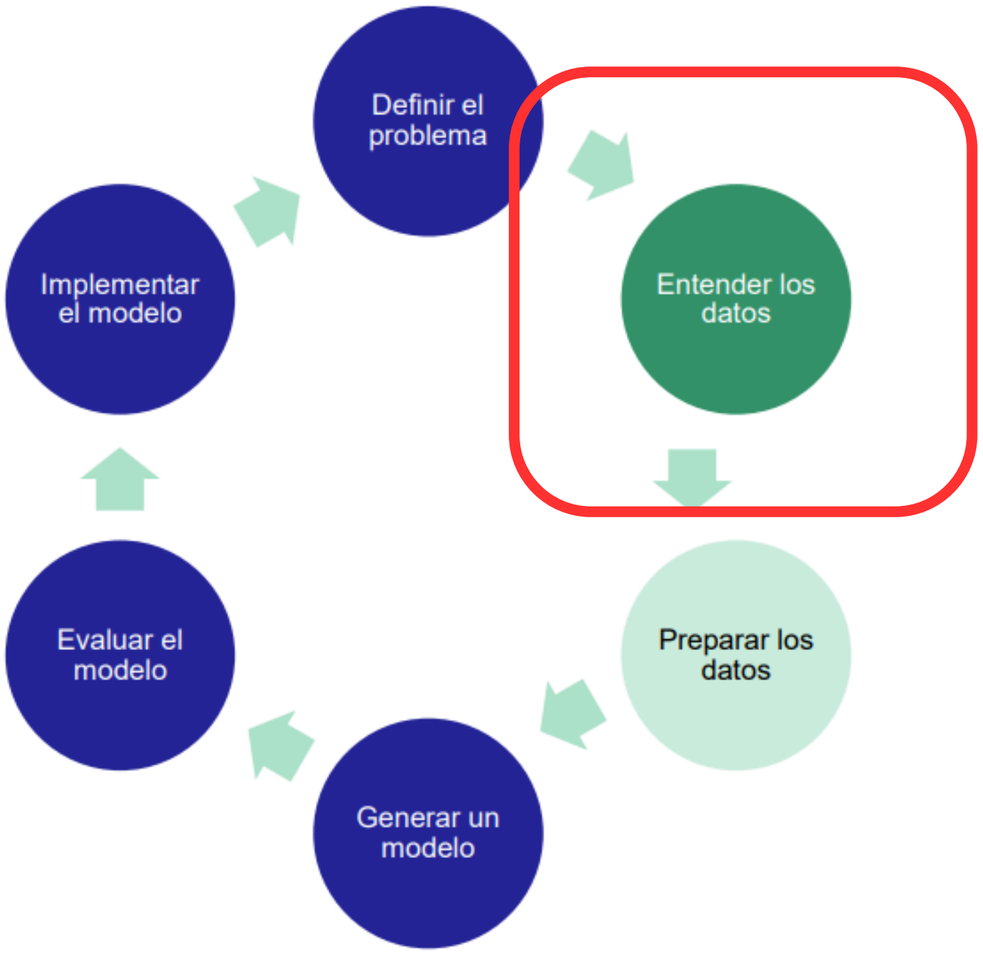

# Visualización de datos

# Visualización de datos

- Hace visibles patrones e insights que no se detectan fácilmente solo con números (tendencias, outliers, relaciones)
- Facilita la comprensión rápida, reduciendo el esfuerzo cognitivo de la audiencia
- Mejora la toma de decisiones, porque comunica información clave de forma clara y directa
- Evita interpretaciones erróneas, si está bien diseñada (sin distorsiones ni ruido visual)
- Permite comunicar una historia con datos, haciendo el mensaje más persuasivo y memorable

## Elegir el gráfico equivocado

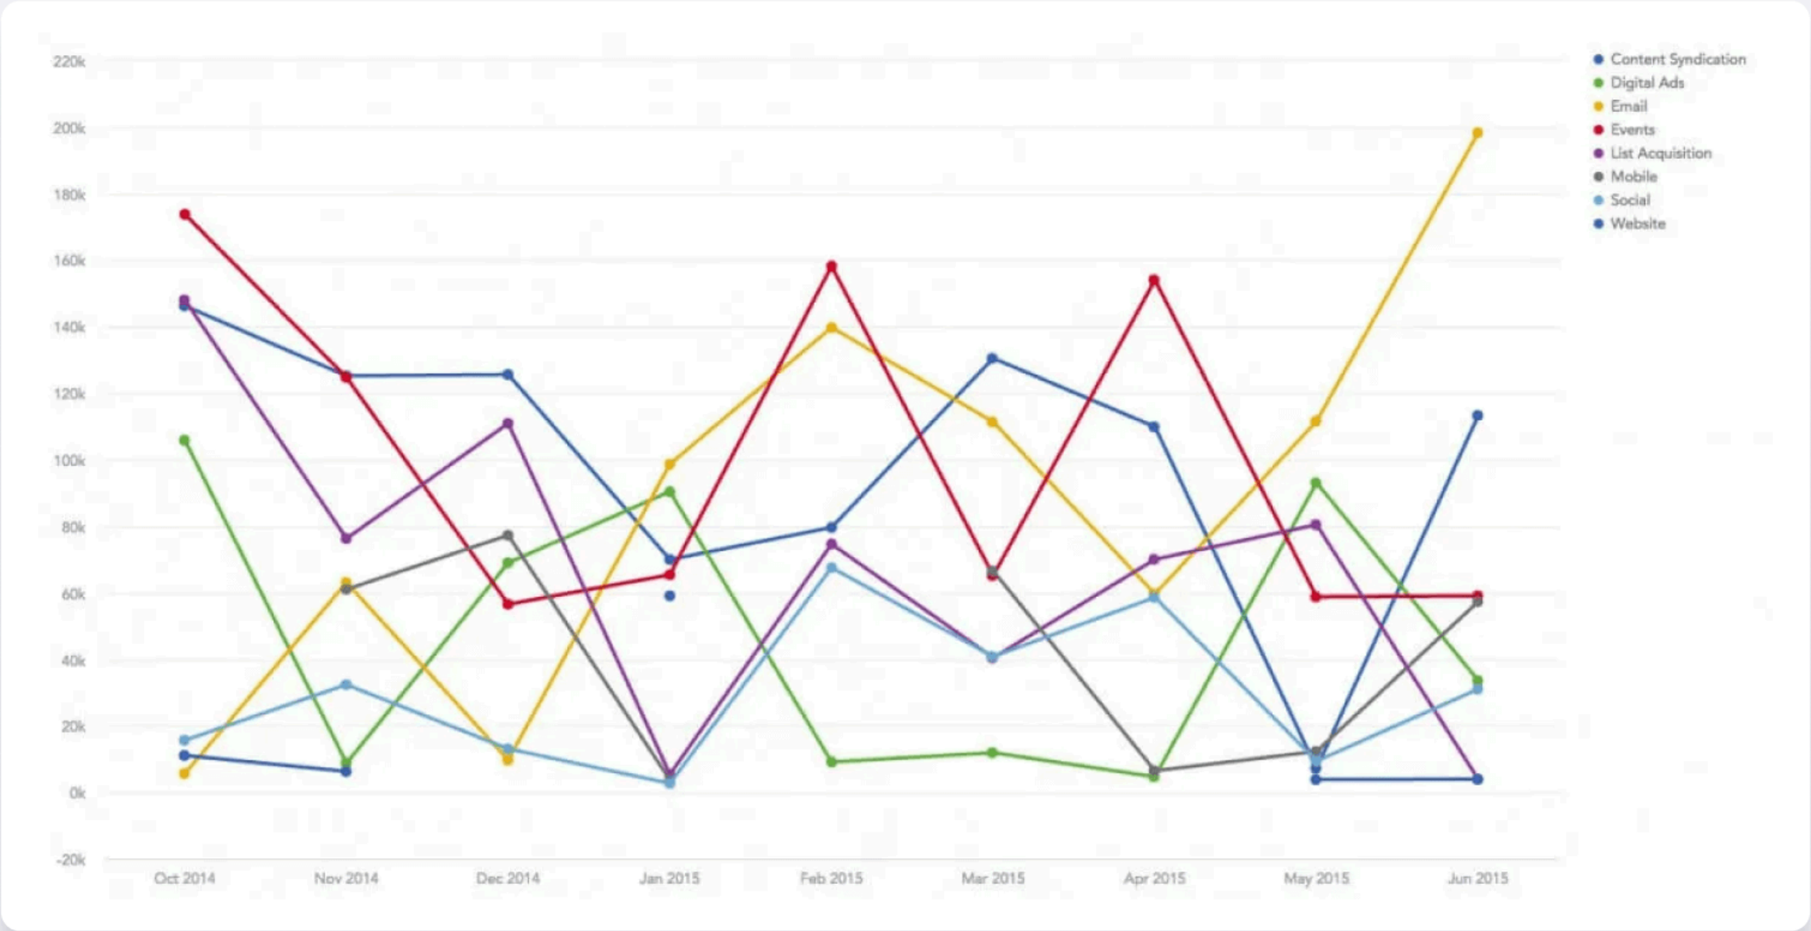

**Complejizar la información sin sentido**

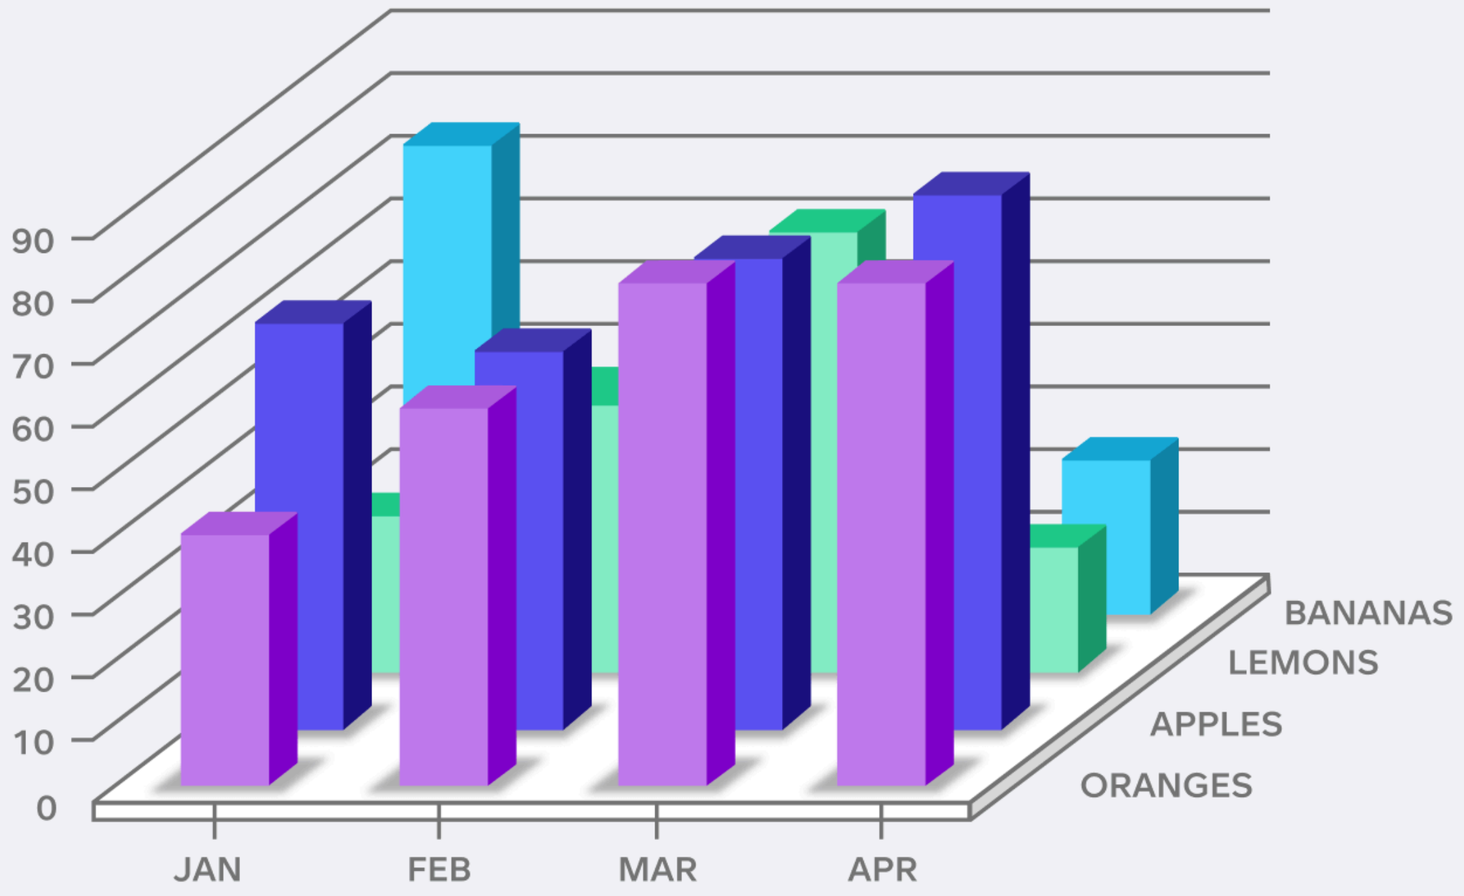

**No decir NADA**

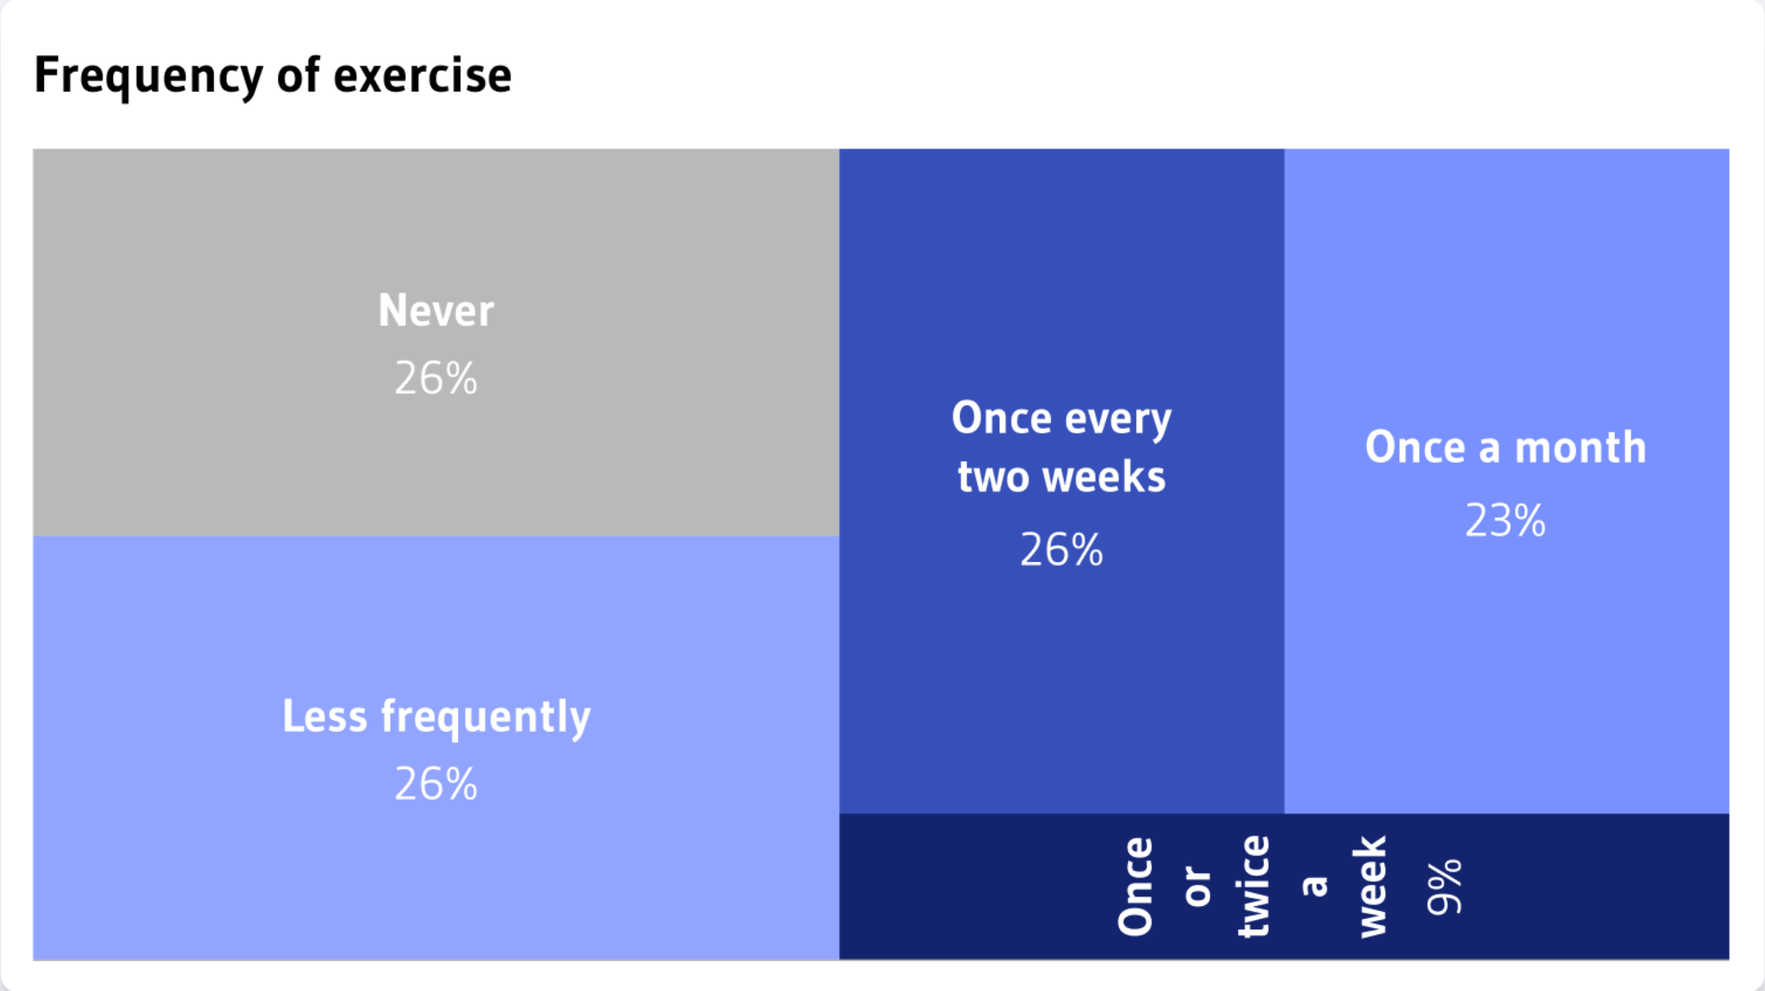

## Mal uso del color

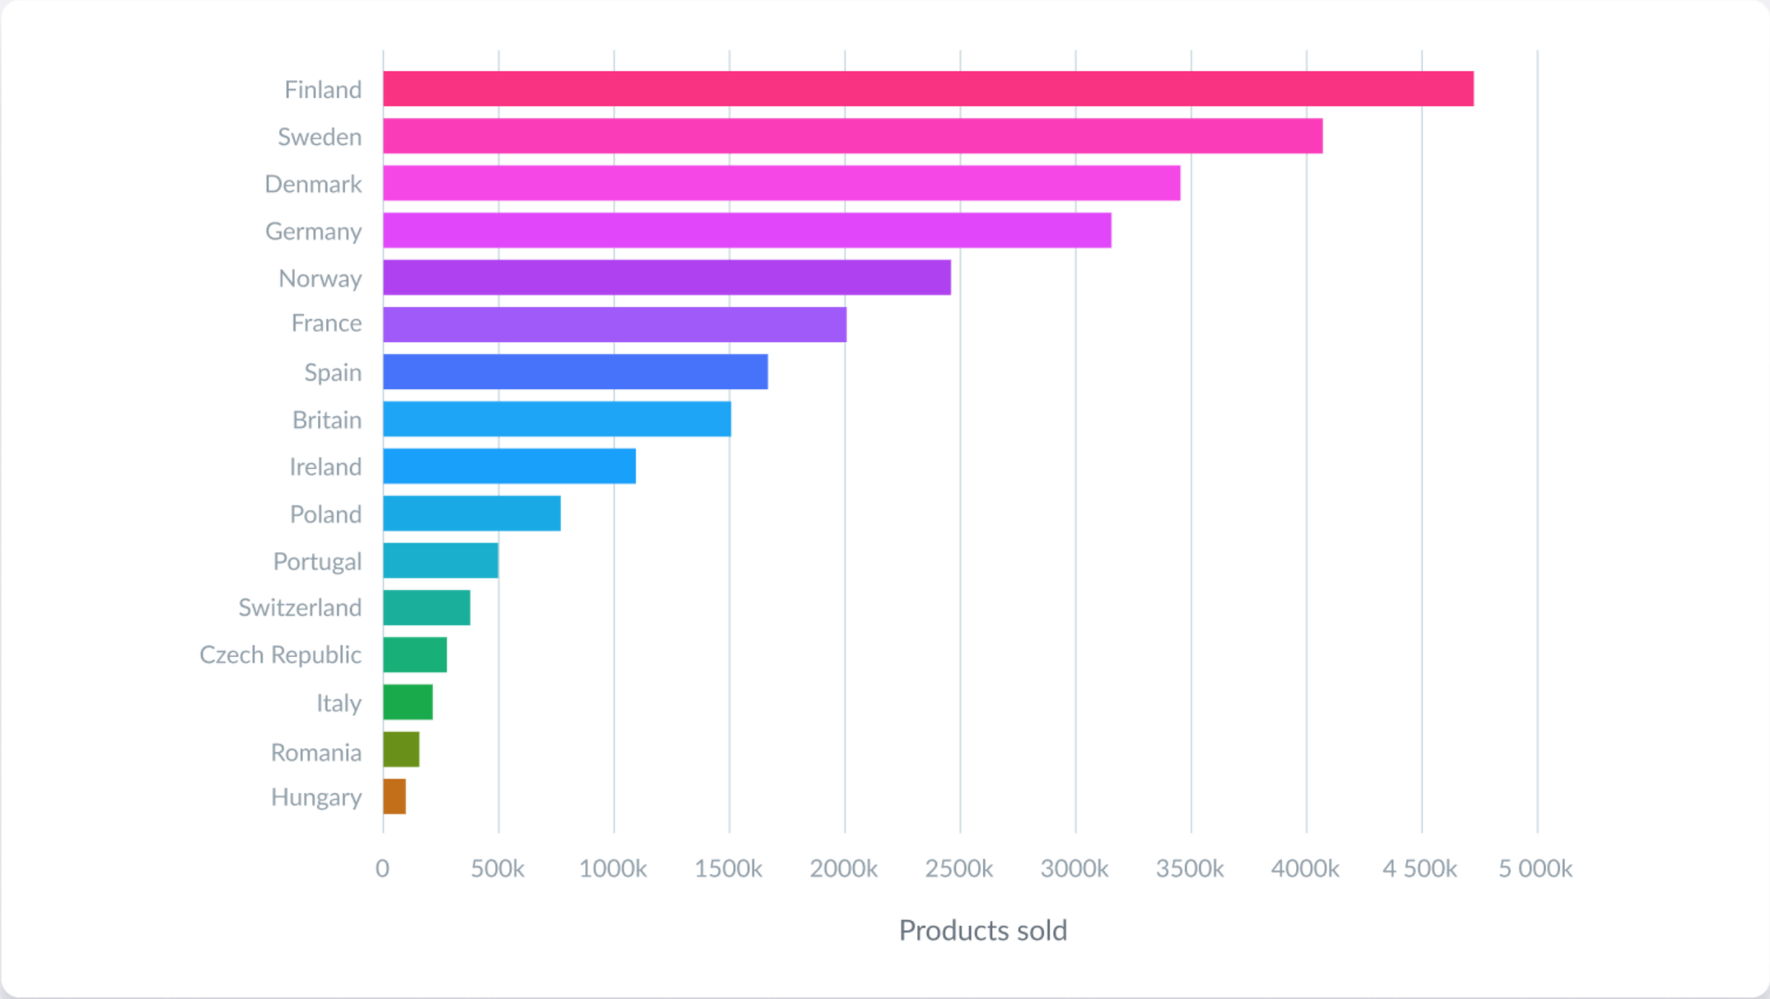

## Usar 3D (Sin razón)

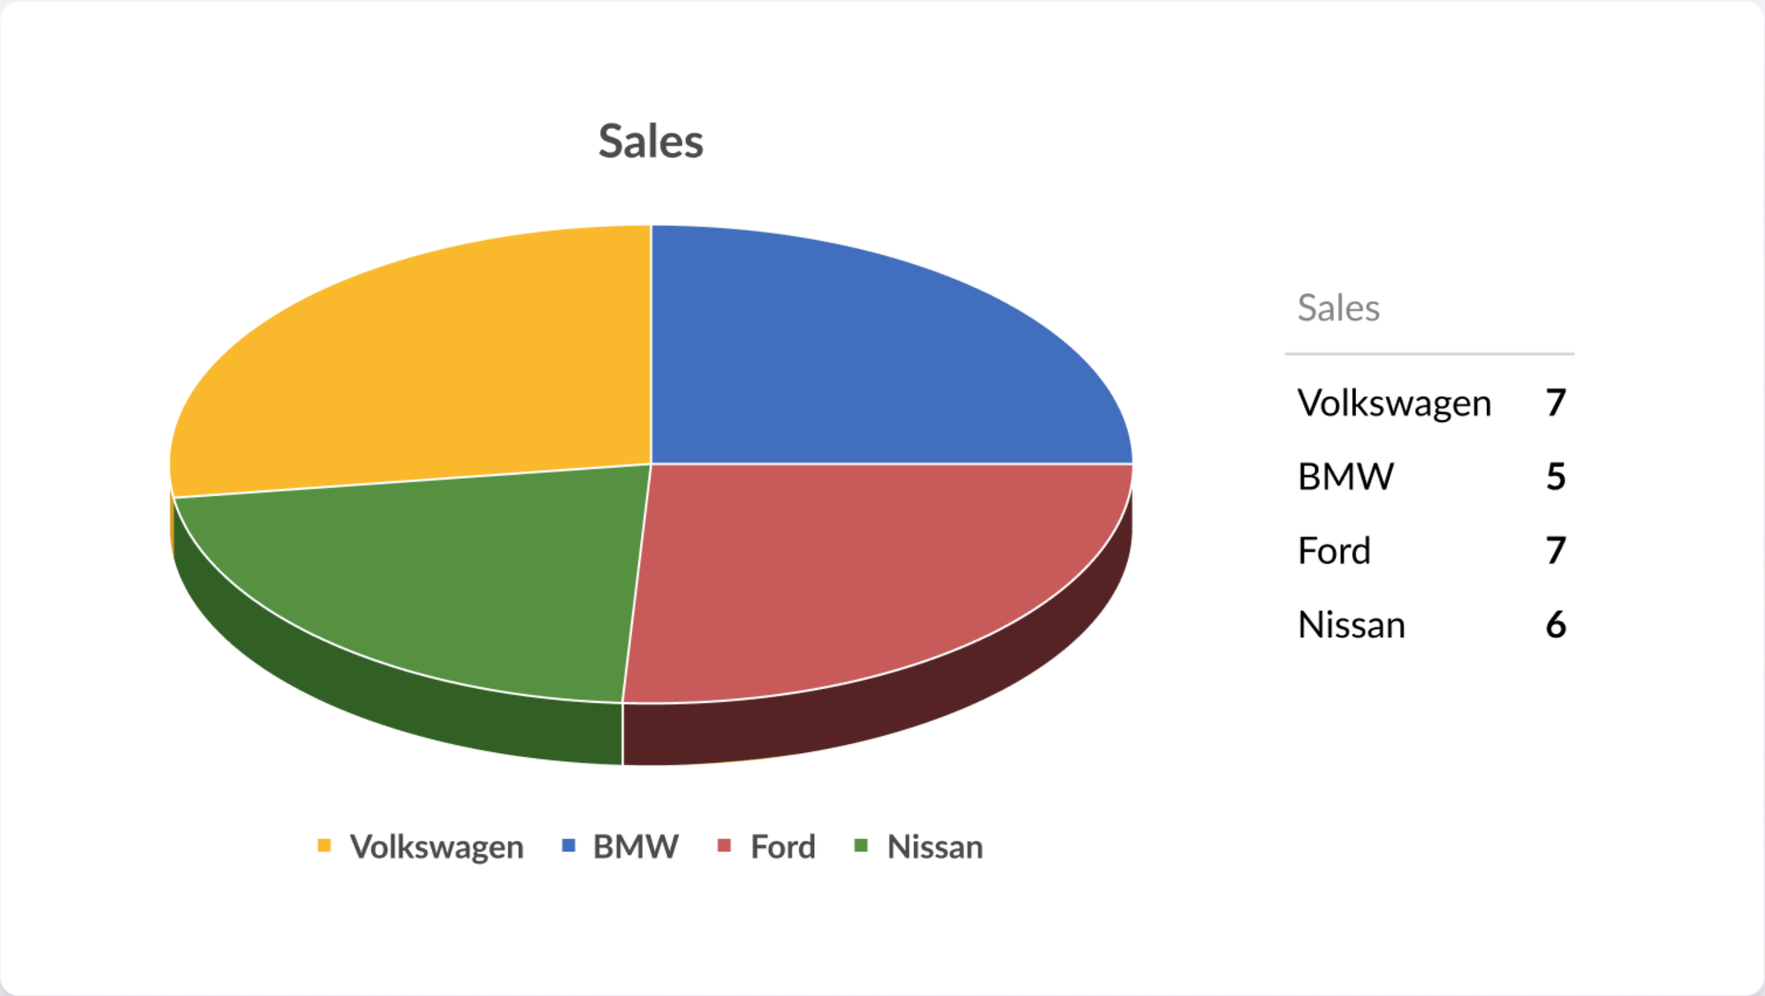

## Hablemos de esto...

## Barras apiladas, gráfico

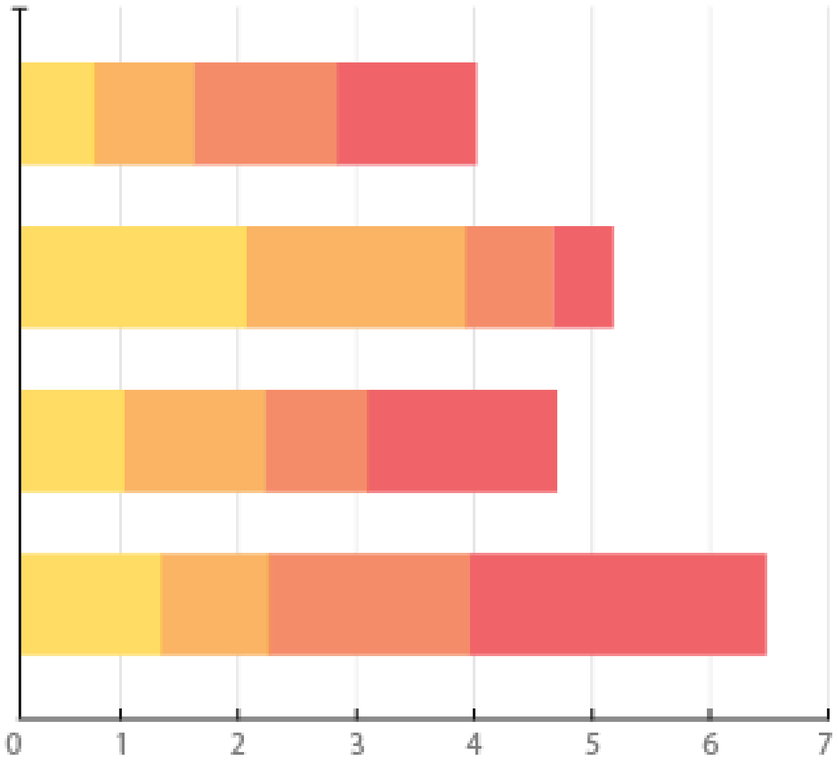

## Hablemos de esto...

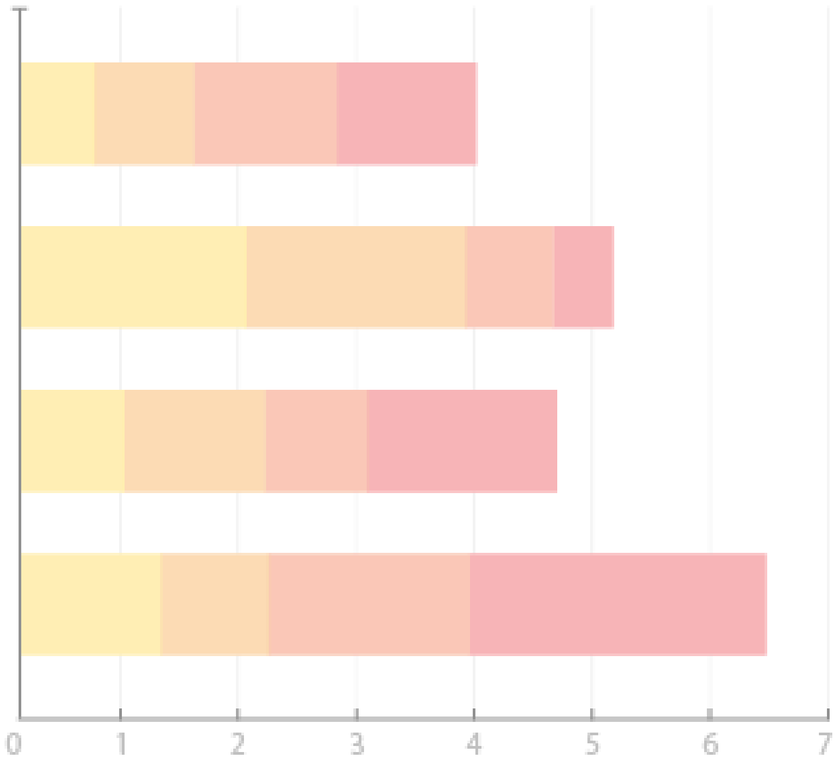


## Barras apiladas, gráfico

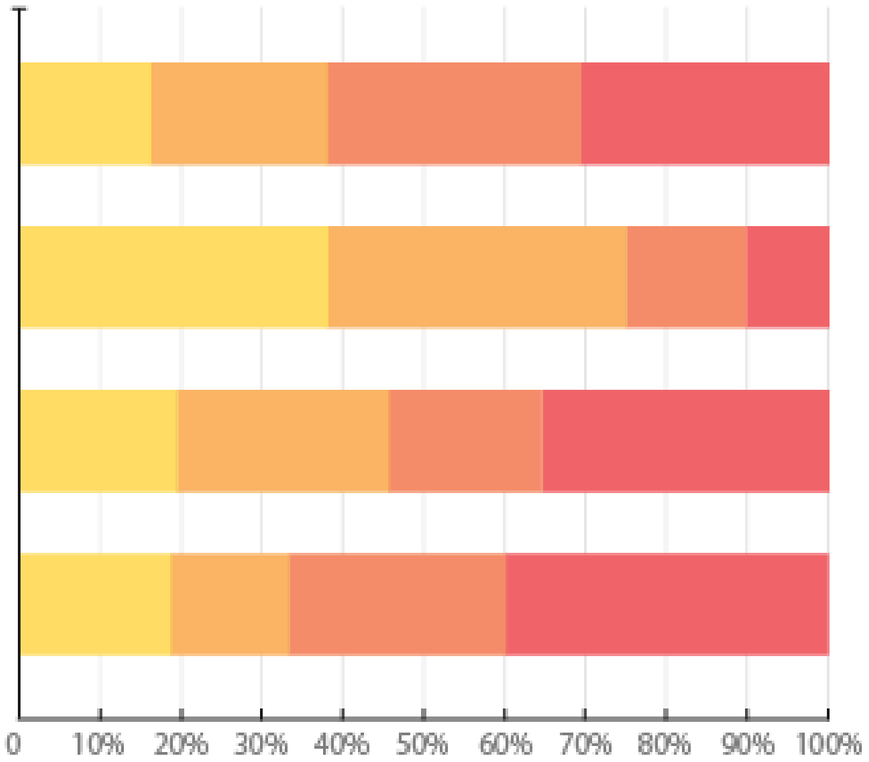

## Hablemos de esto...

## Gráfico de tortas

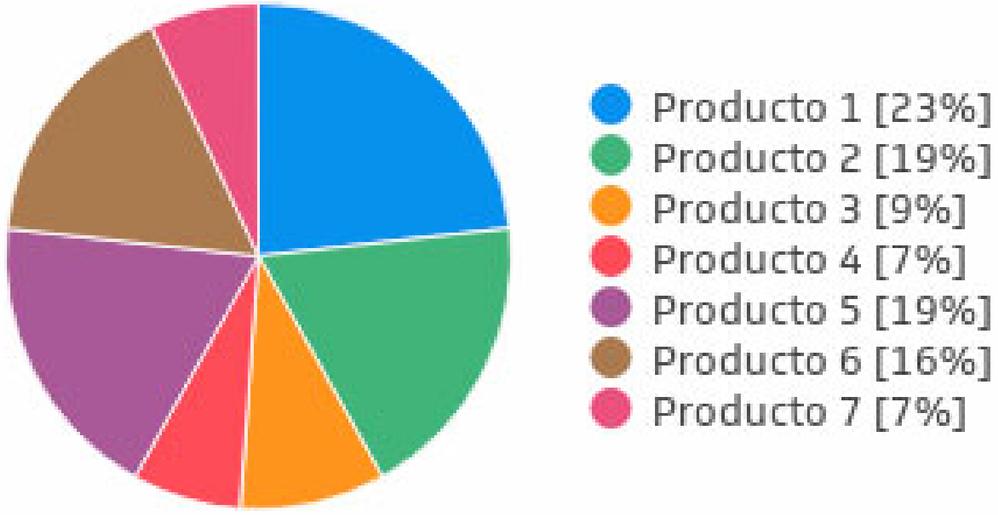

## Hablemos de esto...




## Gráfico de tortas

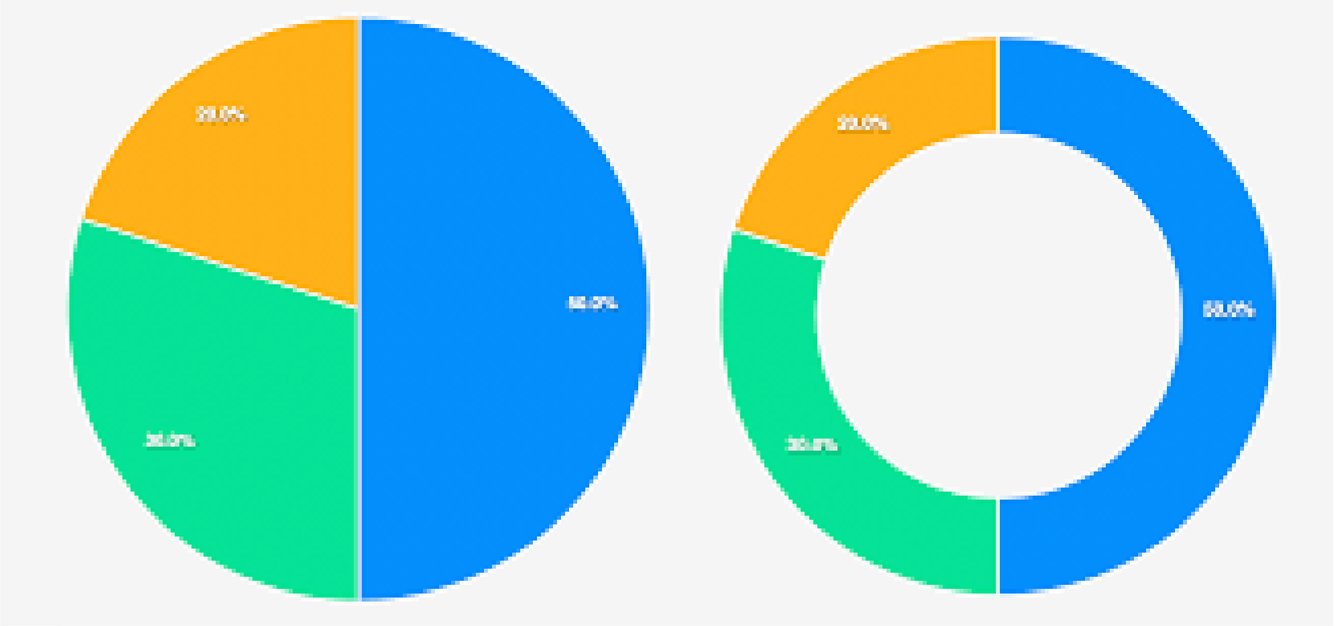

# ¿Cómo sería una buena visualización?

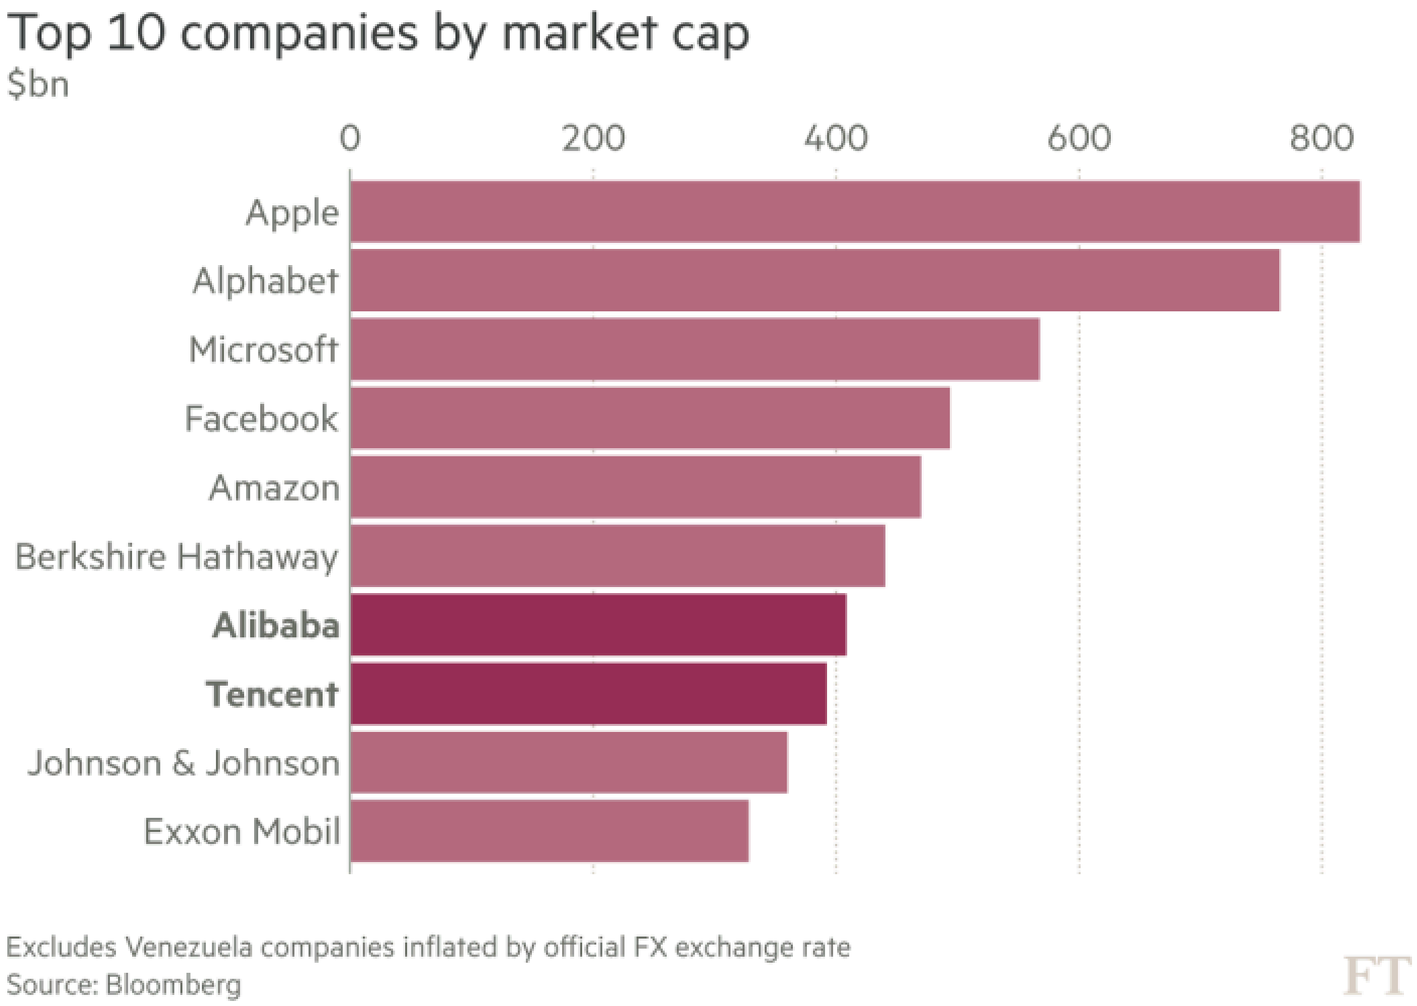
Top 10 companies by market cap
$bn
0
200
400
600
800
Apple
Alphabet
Microsoft
Facebook
Amazon
Berkshire Hathaway
Alibaba
Tencent
Johnson & Johnson
Exxon Mobil
Excludes Venezuela companies inflated by official FX exchange rate
Source: Bloomberg
FT

# Good vs Bad Data Visualization: Information Congestion

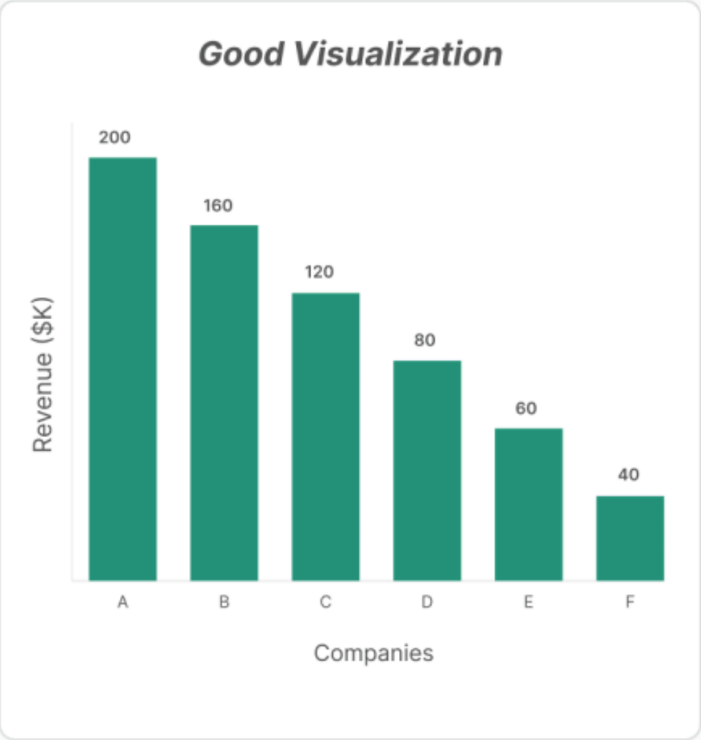


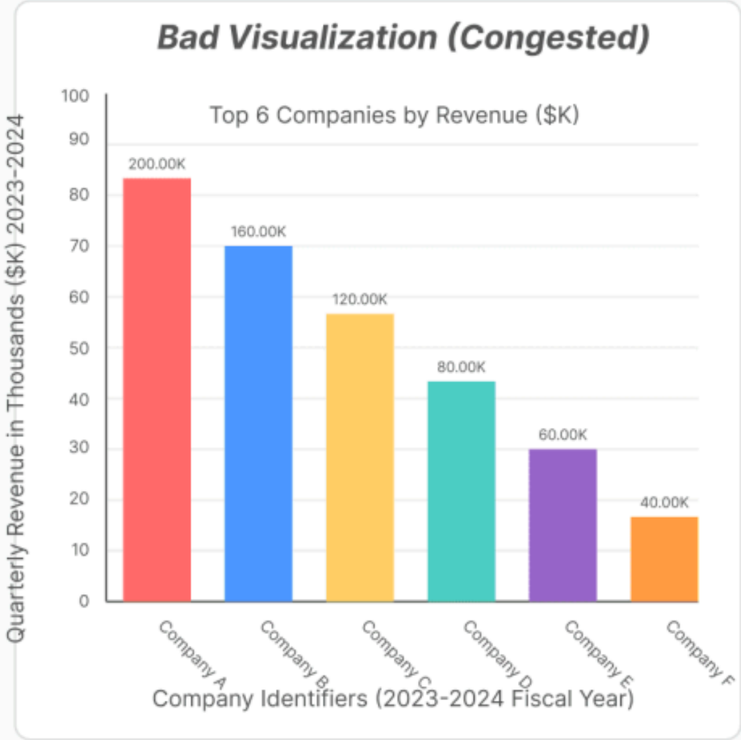


SR analytics

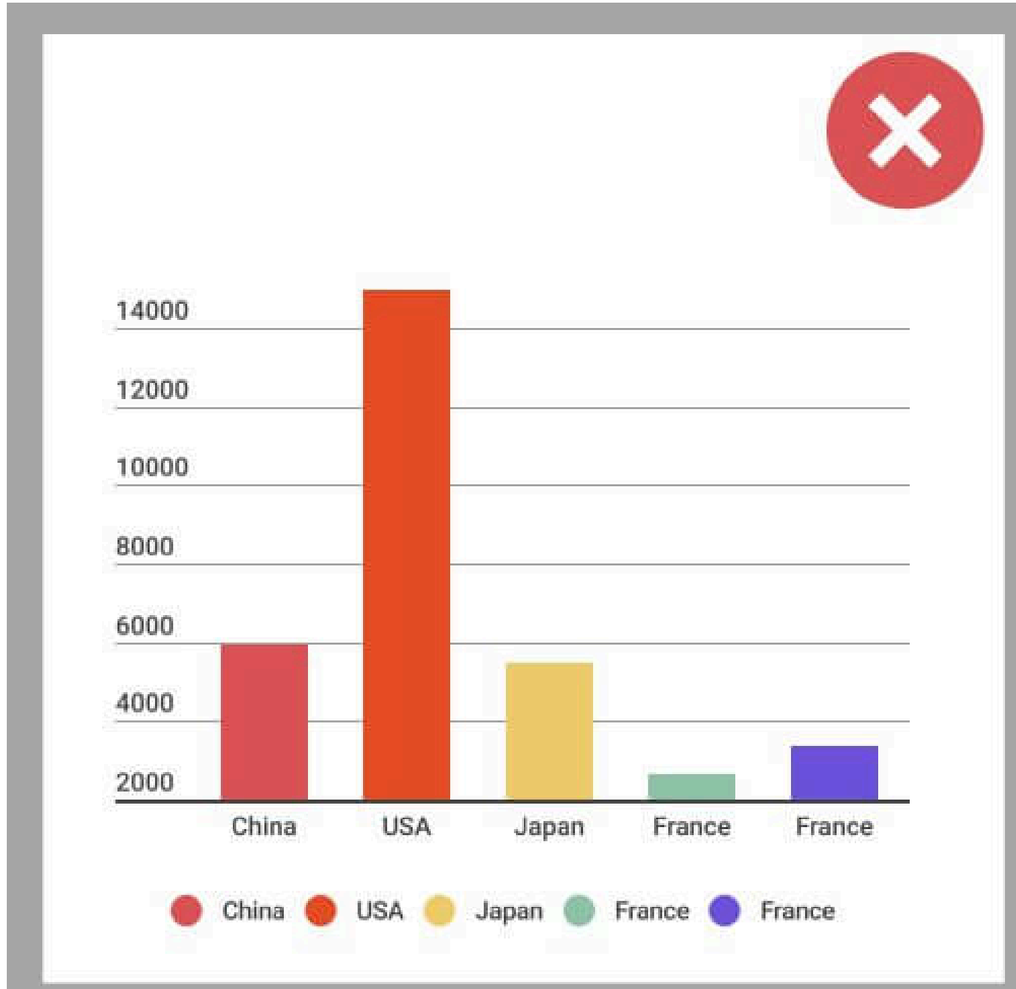
14000
12000
10000
8000
6000
4000
2000
China
USA
Japan
France
France
China
USA
Japan
France
France

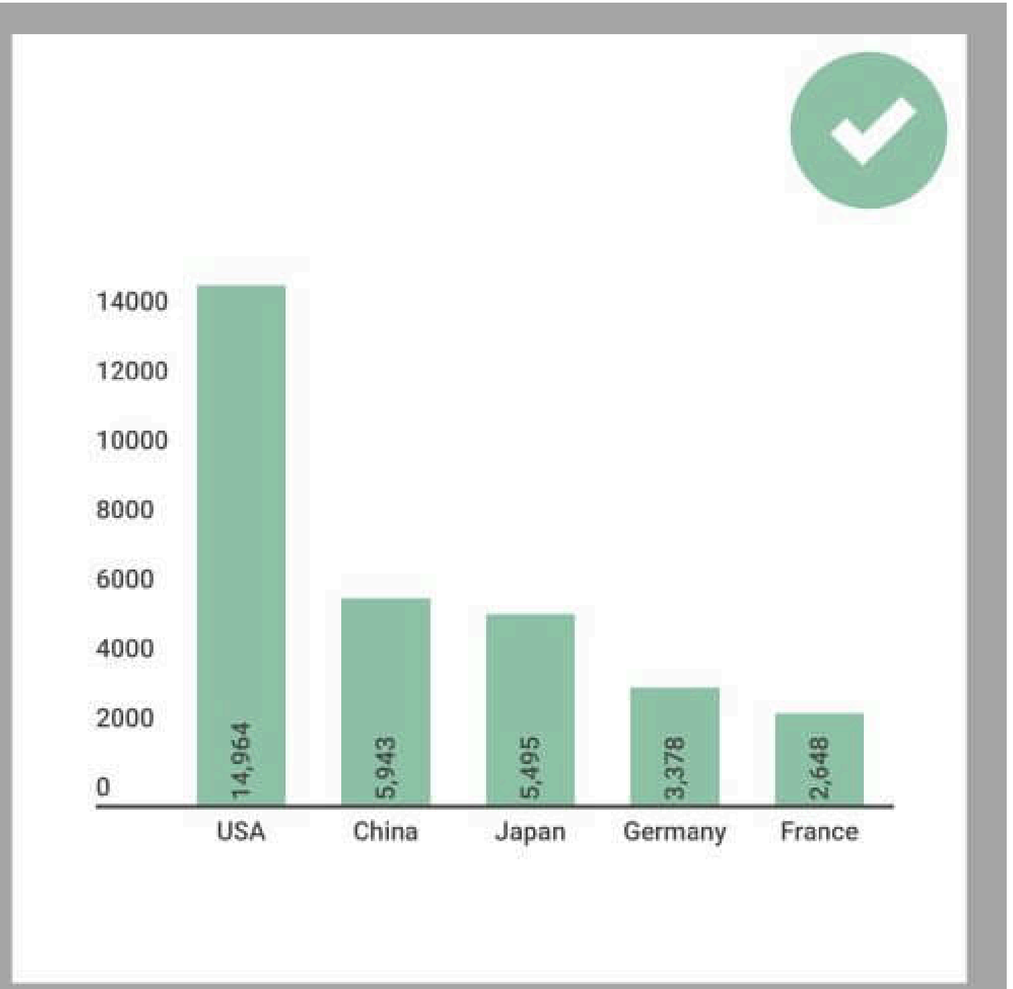
14000
12000
10000
8000
6000
4000
2000
0
14,964
5,943
5,495
3,378
2,648
USA
China
Japan
Germany
France

# Pensemos entre todos

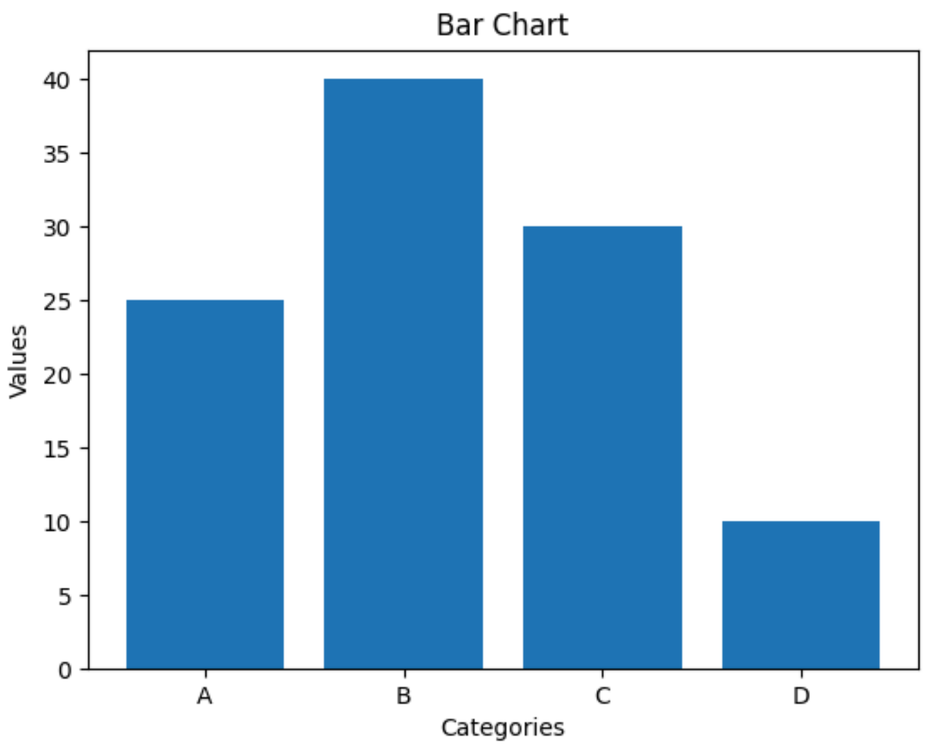

# Pensemos entre todos

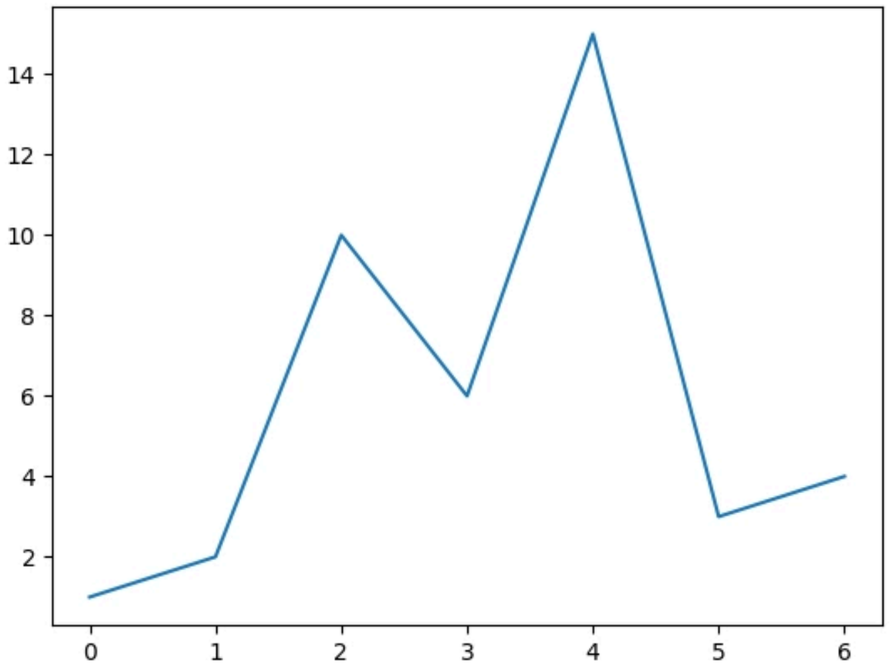

# Pensemos entre todos

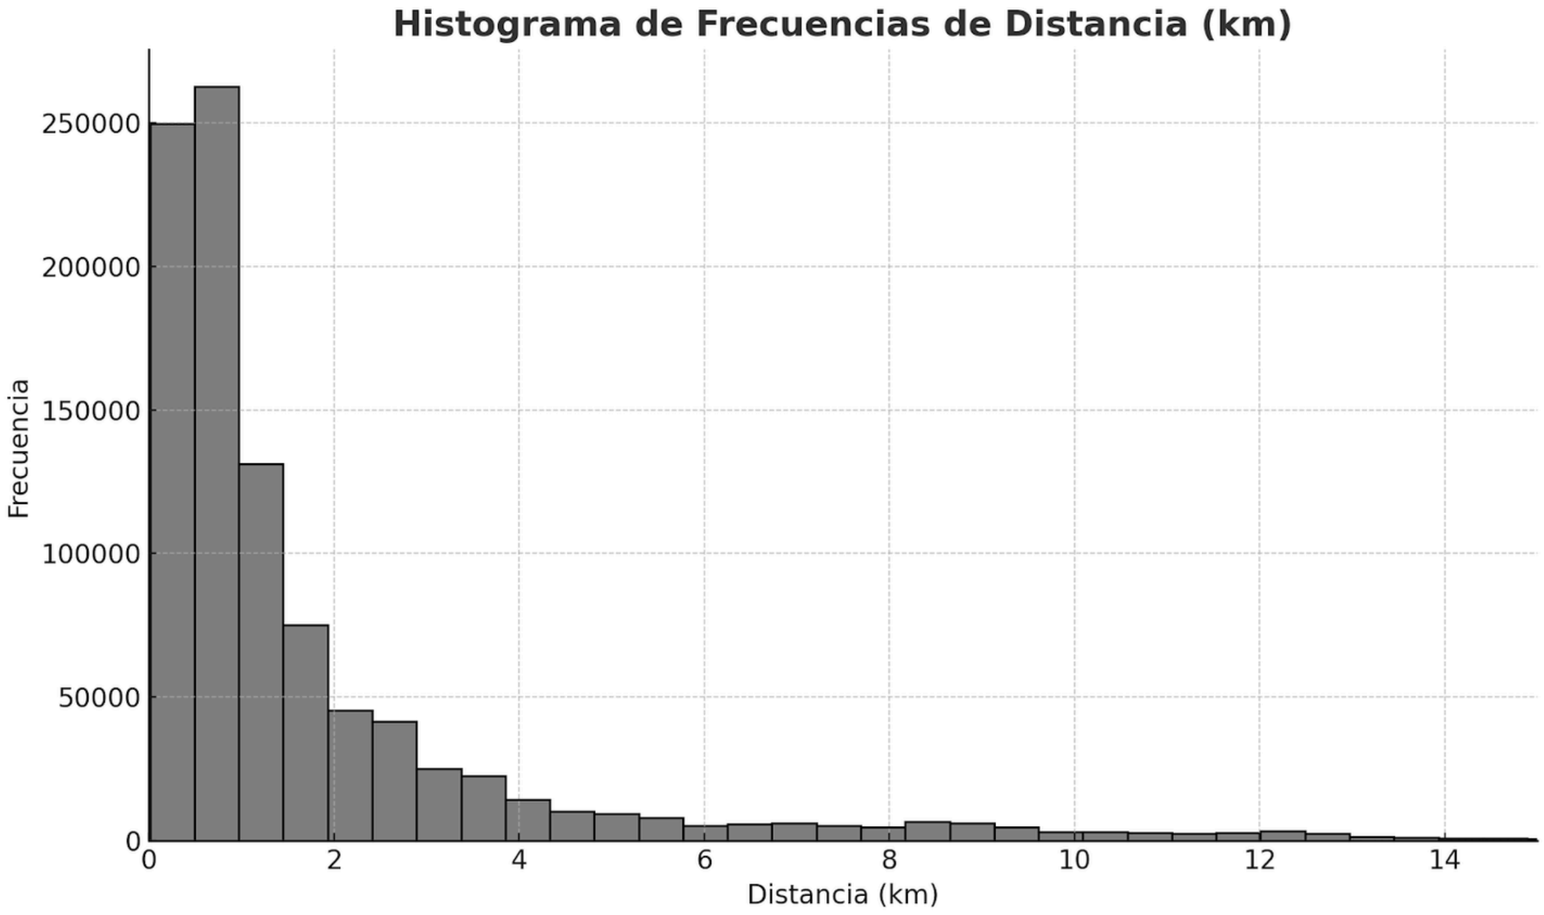

# Pensemos entre todos

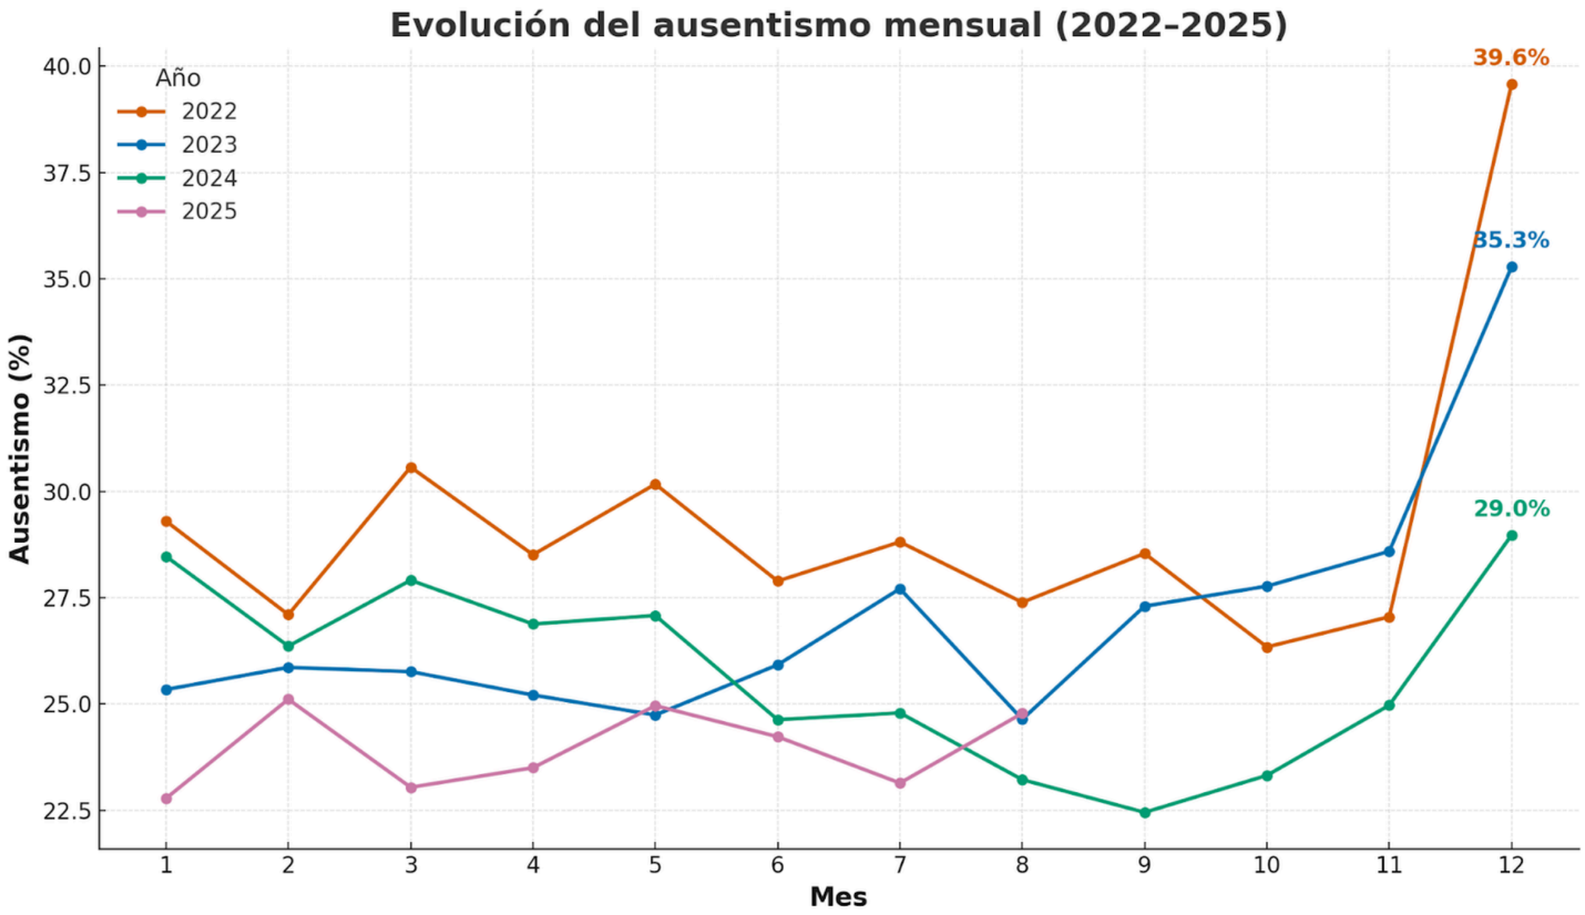

# Trabajo Práctico

Analítica de Datos
Profesor: Ing. Pablo Sciolla

**Actividad Práctica de Visualización de Datos**

**1. Objetivo**

El objetivo de esta práctica es desarrollar habilidades de exploración, análisis y comunicación de datos, utilizando datos abiertos del Gobierno de la Ciudad de Buenos Aires para construir una historia basada en evidencia.

El portal de datos abiertos de la Ciudad reúne más de 400 datasets públicos sobre distintas áreas de gestión (transporte, educación, seguridad, ambiente, obras públicas, entre otros) que pueden ser descargados y reutilizados libremente para generar visualizaciones, análisis y nuevas ideas.

A partir de uno de estos datasets, cada equipo deberá identificar un insight interesante y comunicarlo mediante un storytelling claro y atractivo.

**2. Consigna**

1. Ingresar al portal de datos abiertos del Gobierno de la Ciudad de Buenos Aires: https://data.buenosaires.gob.ar/
2. Seleccionar un dataset que resulte interesante para analizar.
3. Realizar un análisis exploratorio de los datos, buscando patrones, tendencias o fenómenos relevantes.
4. Construir una historia basada en datos (data storytelling) que responda a una pregunta o problema claro.

# Notebook

# Kahoot