Analítica de Datos

Clase 2 - Data Profiling y Visualizaciones

Agenda

- Data Profiling & Visualization
- Caso de aplicación real
- Xxxxxxx
- Notebook
- Kahoot

Dos conceptos

Entender y analizar bien los datos es demasiado importante (En cualquier situación)

Dos conceptos

Entender y analizar bien los datos es demasiado importante (En cualquier situación)

Podes visualizar bien, con buen concepto, es una herramienta que les va a dar mucho laburo

¿Qué vieron con Pablo?

¿Qué es el data profiling?

¿Qué es el data profiling?

Técnica para entender los datos

¿Qué es el data profiling?

Técnica para entender los datos

- Entender la estructura de los datos

¿Qué es el data profiling?

Técnica para entender los datos

- Entender la estructura de los datos
- Evaluar la calidad del dataset

¿Qué es el data profiling?

Técnica para entender los datos

- Entender la estructura de los datos
- Evaluar la calidad del dataset
- Identificar problemas potenciales

¿Qué es el data profiling?

Técnica para entender los datos

- Entender la estructura de los datos
- Evaluar la calidad del dataset
- Identificar problemas potenciales
- Primer paso (Y usualmente el más dificil) en cualquier proyecto de analítica

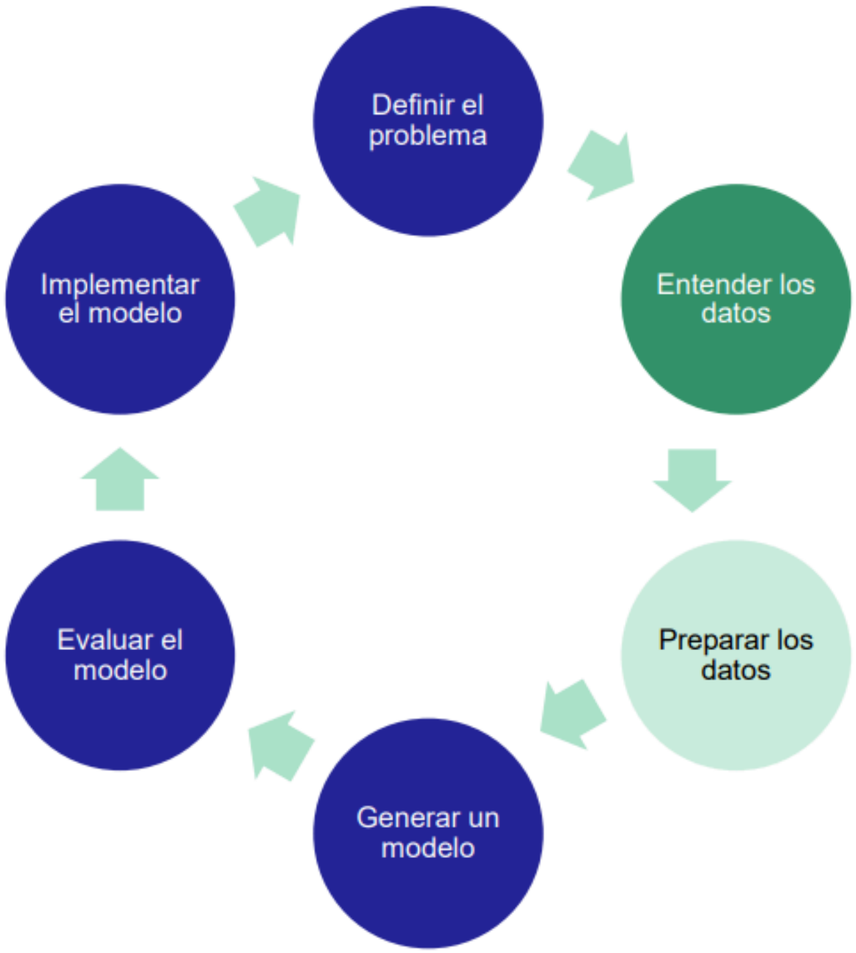
Definir el problema
Entender los datos
Preparar los datos
Generar un modelo
Evaluar el modelo
Implementar el modelo

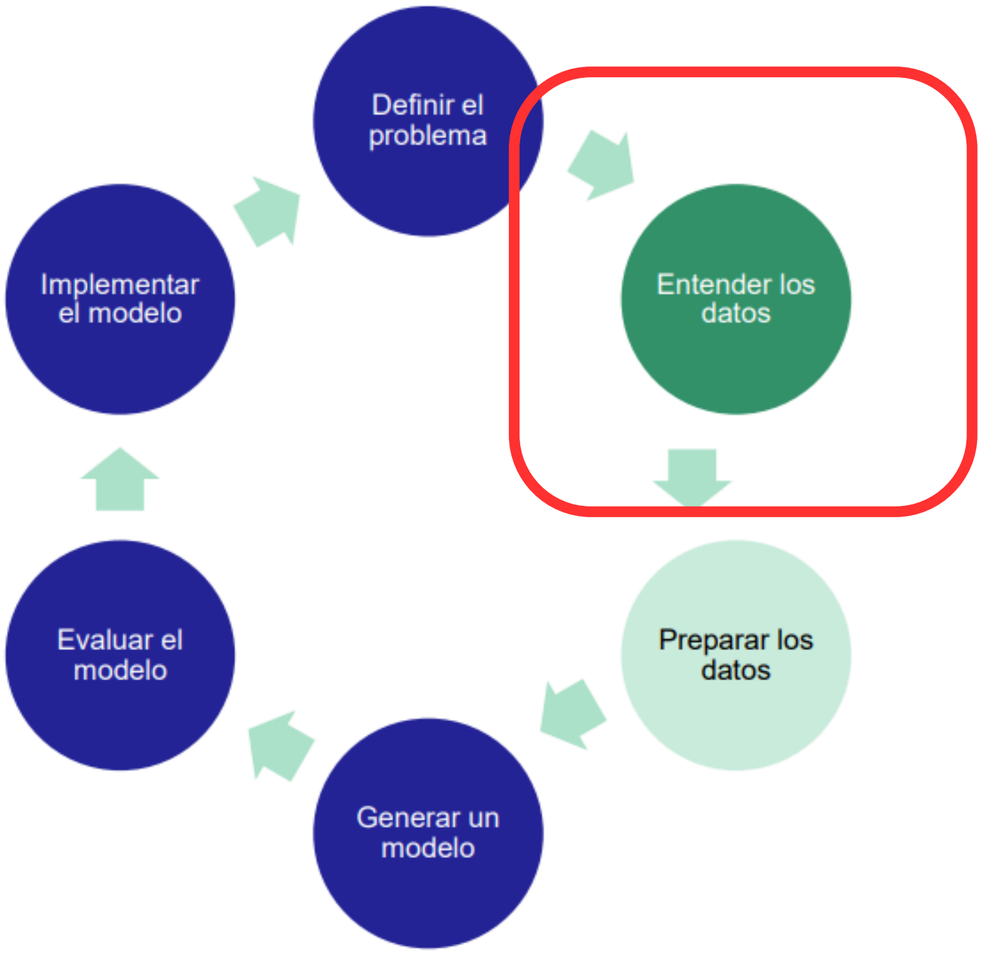
Definir el problema
Entender los datos
Preparar los datos
Generar un modelo
Evaluar el modelo
Implementar el modelo

Entender los datos

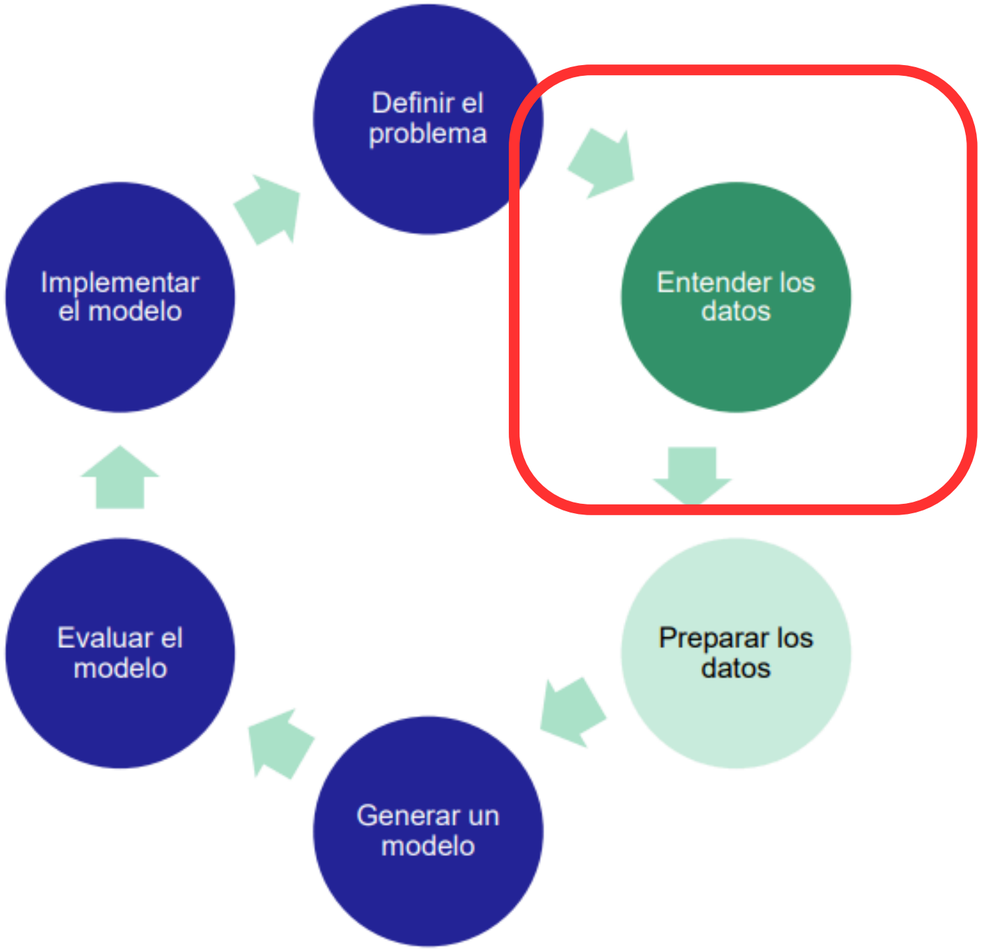

Entender las variables

Variables numéricas

Entender las variables

Variables numéricas

Dos tipos... ¿?

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos
Discretas: Cualquier valor en un rango

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos
Discretas: Cualquier valor en un rango

Variables categóricas

También dos tipos...

Entender las variables

Nominales

Ordinales

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos
Discretas: Cualquier valor en un rango

Variables categóricas

Nominales: Sin un orden natural
Ordinales: Con un orden natural

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos
Discretas: Cualquier valor en un rango

Variables categóricas

Nominales: Sin un orden natural
Ordinales: Con un orden natural

¿Otros tipos de variable?

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos
Discretas: Cualquier valor en un rango

Variables categóricas

Nominales: Sin un orden natural
Ordinales: Con un orden natural

¿Otros tipos de variable?

Fechas: Momentos específicos
Variables compuestas: Distintos tipos de datos

1. **Medidas de tendencia central**

2. **Medidas de dispersión**

3. **Datos faltantes**

1. **Medidas de tendencia central**

2. **Medidas de dispersión**

3. **Tipos de distribución**

4. **Datos faltantes**

Medidas de tendencia central

¿Donde se concentran los datos?

Media

Mediana

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

Media: Promedio de todos los valores

Mediana

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

Media: Promedio de todos los valores

Mediana

Moda

$$1, 1, 2, 3, 4, 5, 6, 10, 100$$

$$1 + 1 + 2 + 3 + 4 + 5 + 6 + 10 + 100 = 132$$

Medidas de tendencia central

¿Donde se concentran los datos?

Media: Promedio de todos los valores

Mediana

Moda

$$1, 1, 2, 3, 4, 5, 6, 10, 100$$

$$1 + 1 + 2 + 3 + 4 + 5 + 6 + 10 + 100 = 132$$

$$132/9 = 14.7$$

Medidas de tendencia central

¿Donde se concentran los datos?

Media: Promedio de todos los valores

Mediana

Moda

1, 1, 2, 3, 4, 5, 6, 10, 100

1 + 1 + 2 + 3 + 4 + 5 + 6 + 10 + 100 = 132

132/9 = 14.7

En promedio, la gente gana 14 millones por año...¿ ?

Medidas de tendencia central

¿Donde se concentran los datos?

Media: Promedio de todos los valores

Mediana: Valor central de la distribución

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución **4**

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución **4**

Moda

La gente gana 4 millones por año... Mucho mejor !

Medidas de tendencia central

¿Donde se concentran los datos?

Media: Promedio de todos los valores

Mediana: Valor central de la distribución

Moda: Valor más frecuente

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución

Moda: Valor más frecuente

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución **1**

Moda: Valor más frecuente

1. Medidas de tendencia central

2. **Medidas de dispersión**

3. Datos faltantes

Medidas de dispersión

Varianza: Promedio de desviaciones al cuadrado

Desviación Estandar: Raíz cuadrada de la varianza

Cuartil Q1, 2, 3 Y 4: Valor que divide un conjunto de datos ordenados en cuatro partes iguales

Rango Interquartil (IQR): La diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1), y representa el 50 % central de los datos

Medidas de dispersión

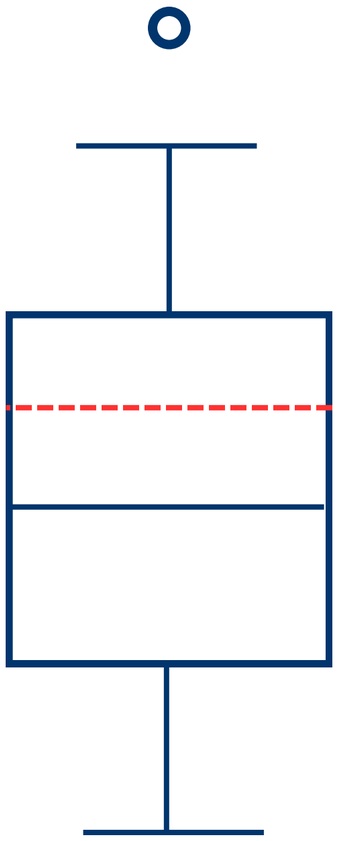

Medidas de dispersión

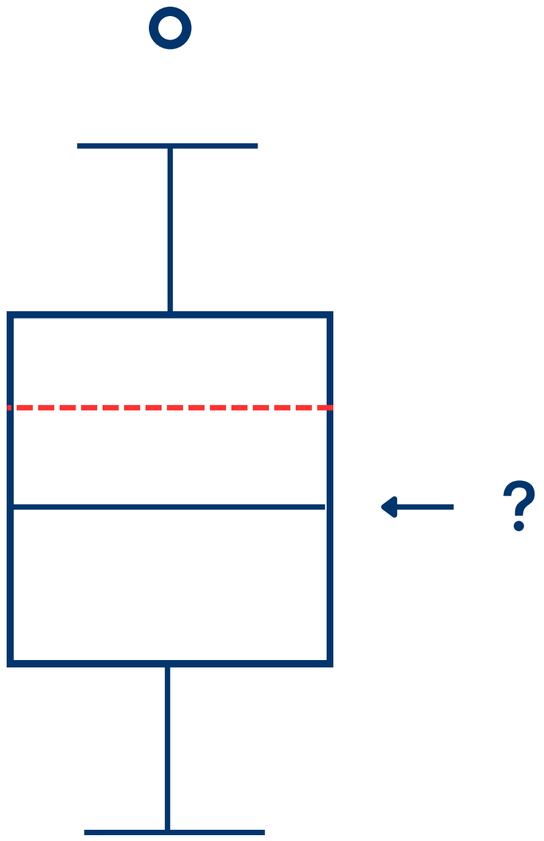

Medidas de dispersión

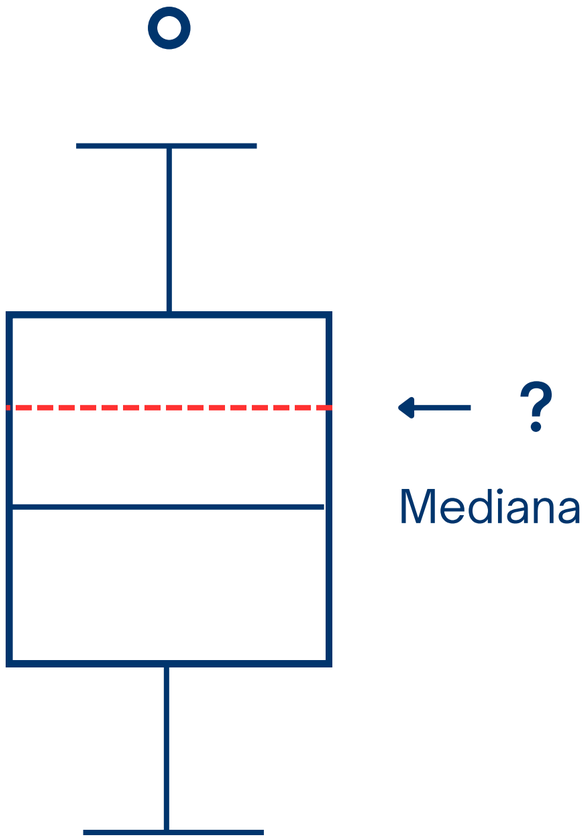

Medidas de dispersión

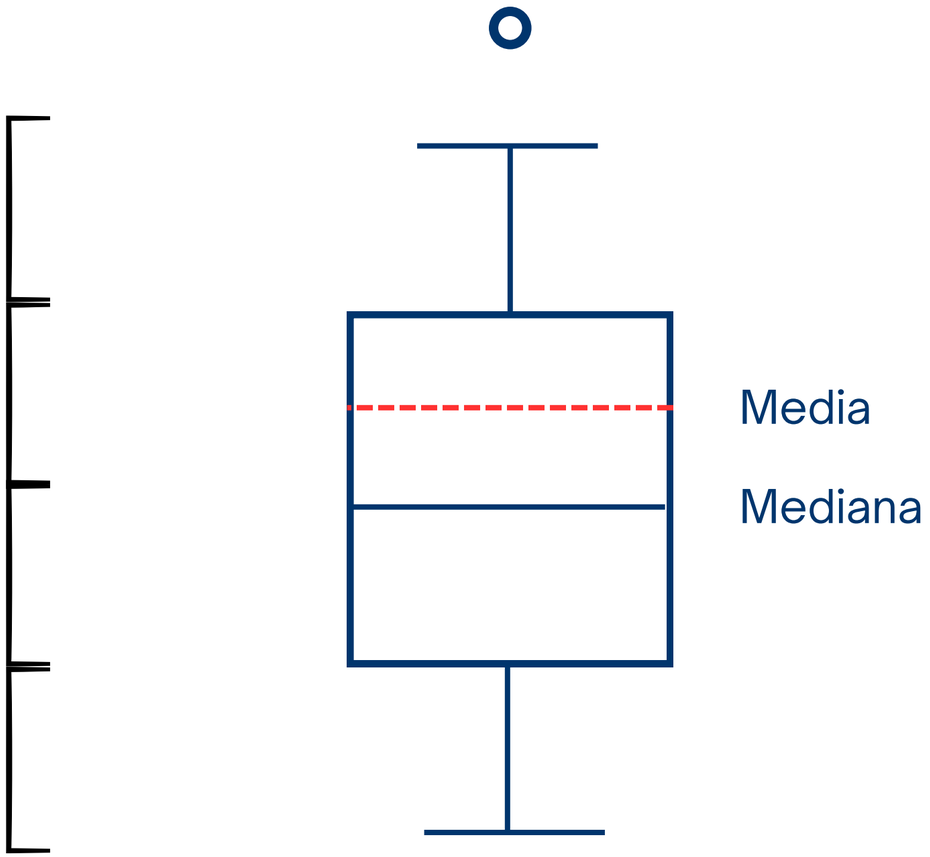

Medidas de dispersión

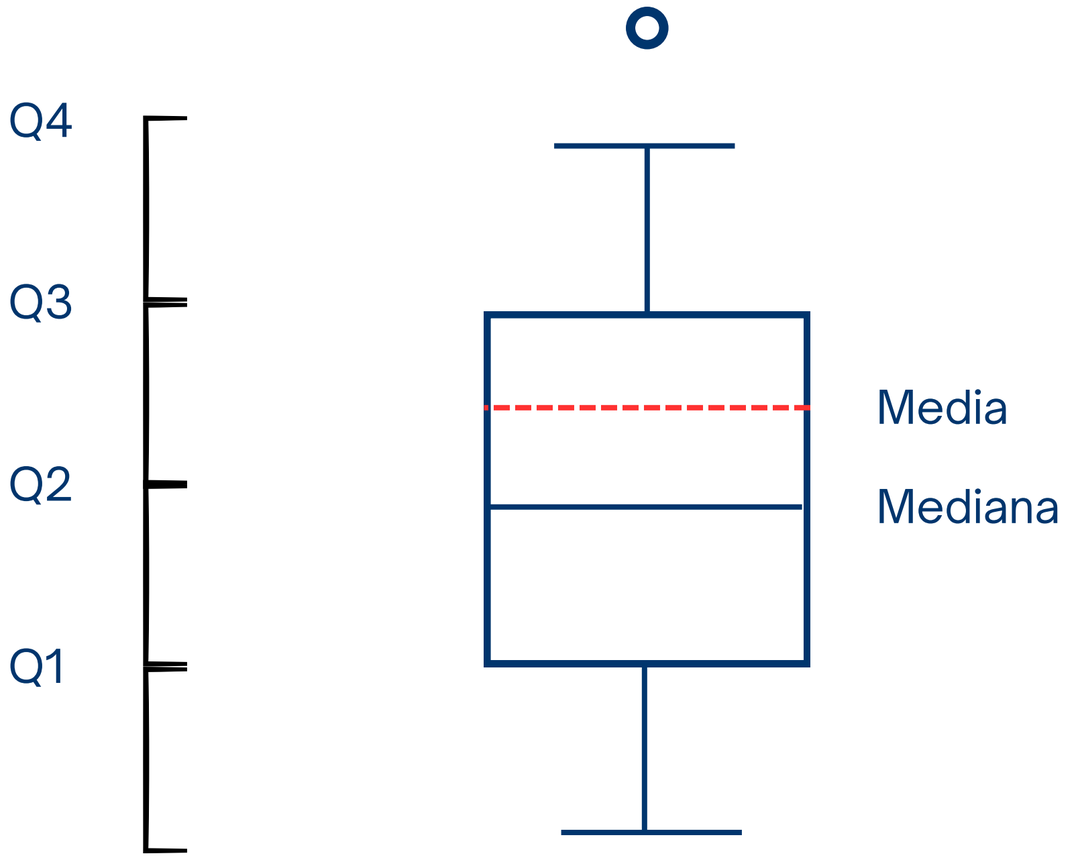

Medidas de dispersión

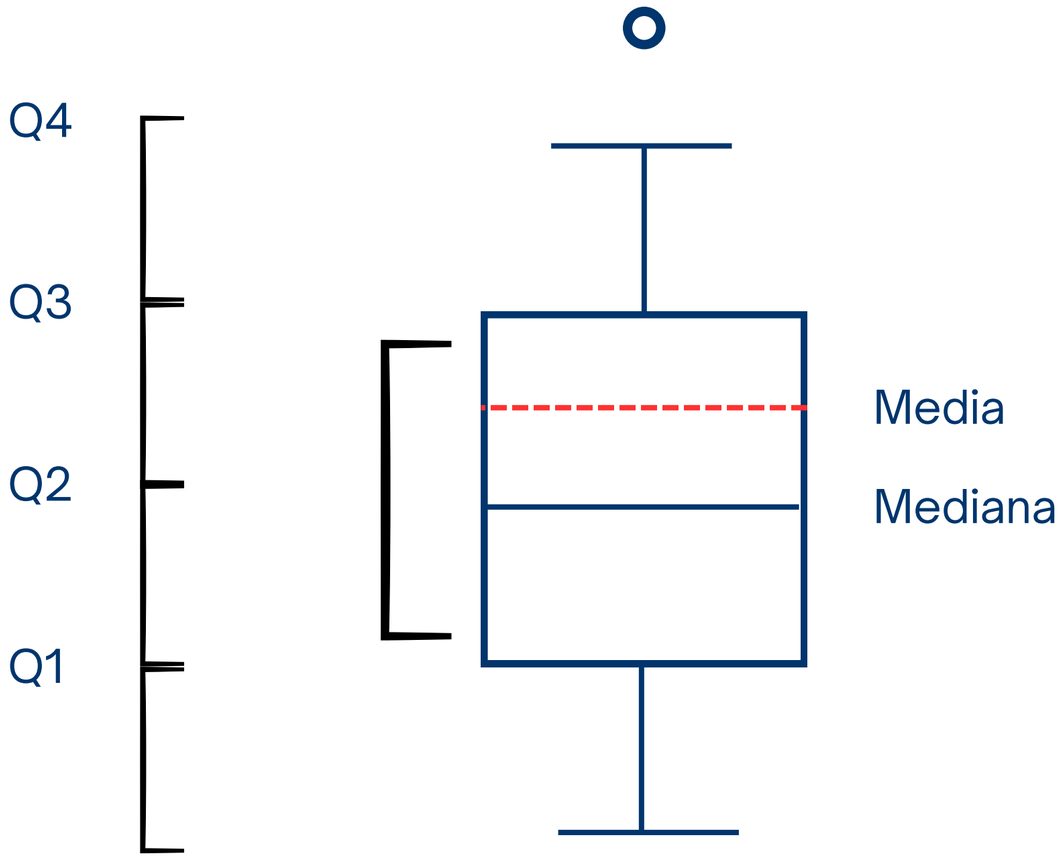

Medidas de dispersión

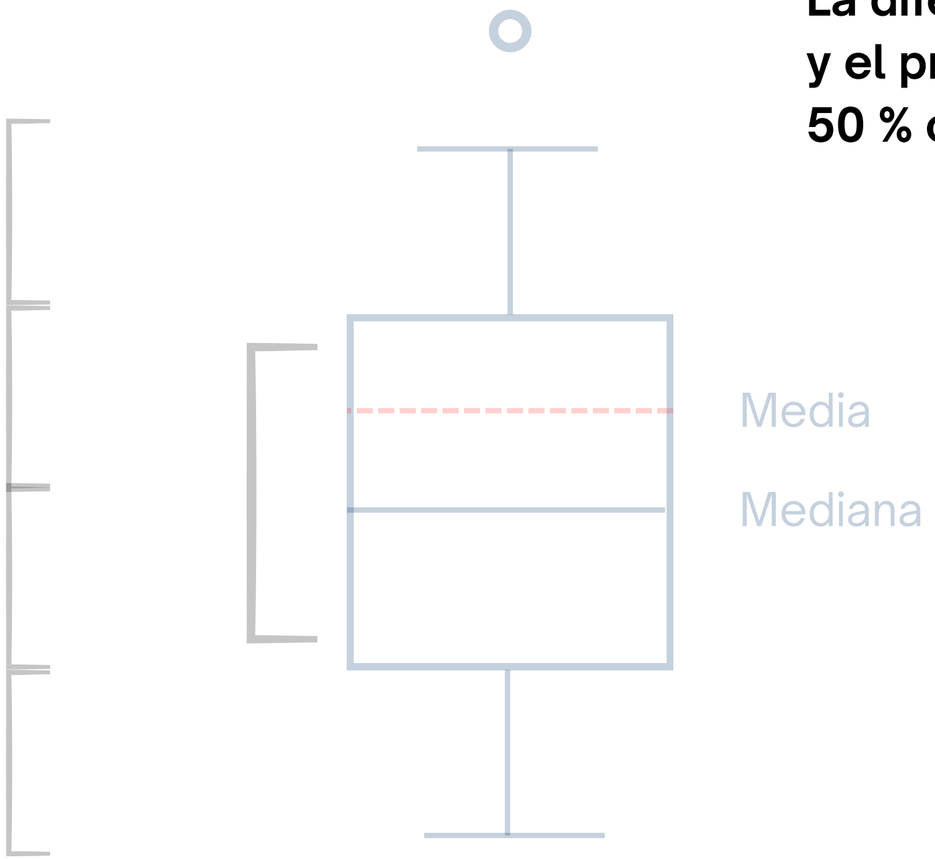

La diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1), y representa el 50 % central de los datos

Medidas de dispersión

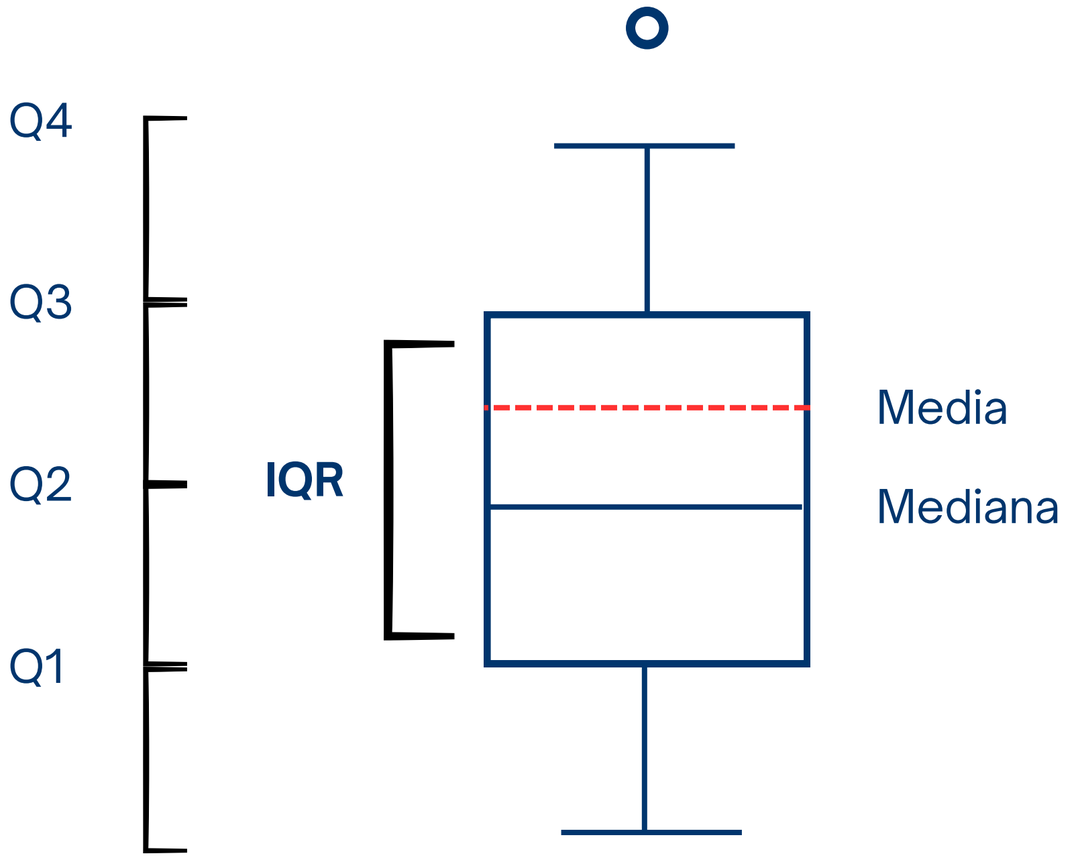

Medidas de dispersión

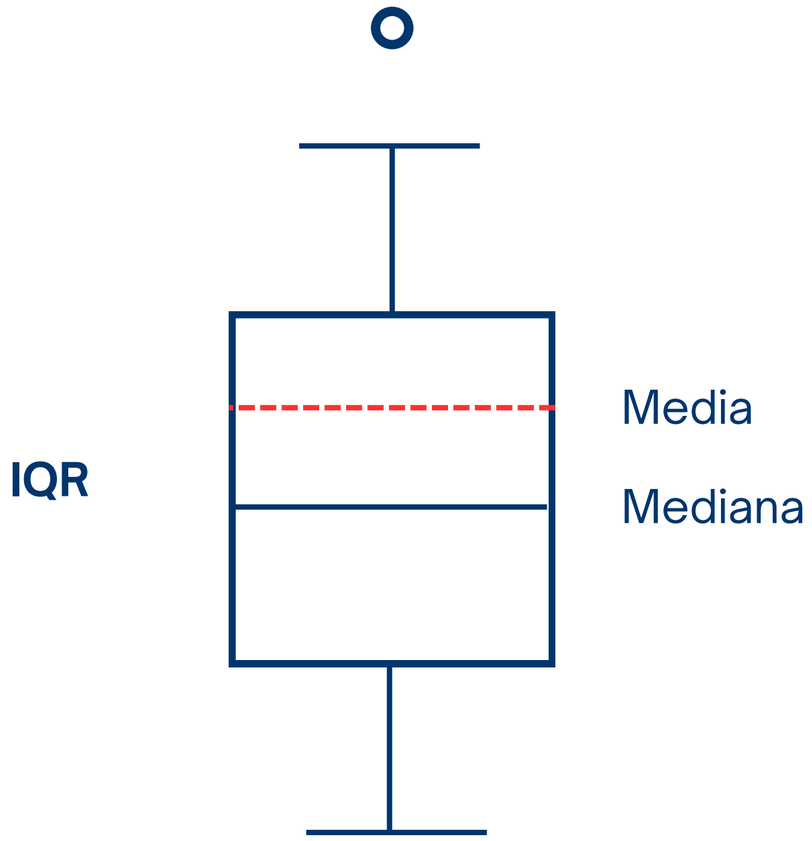

Medidas de dispersión

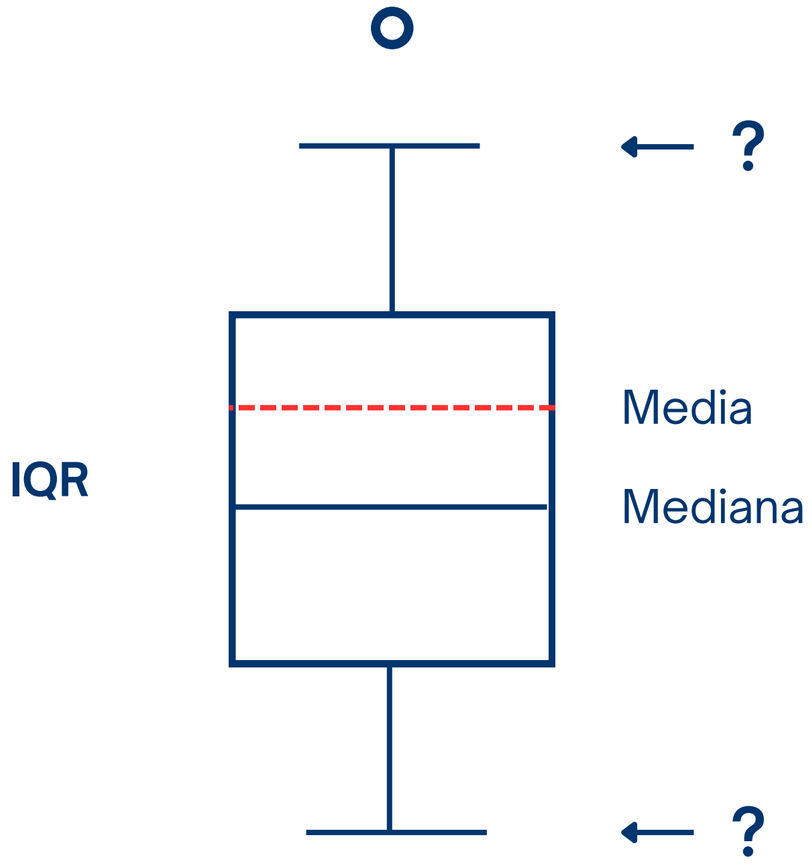

Medidas de dispersión

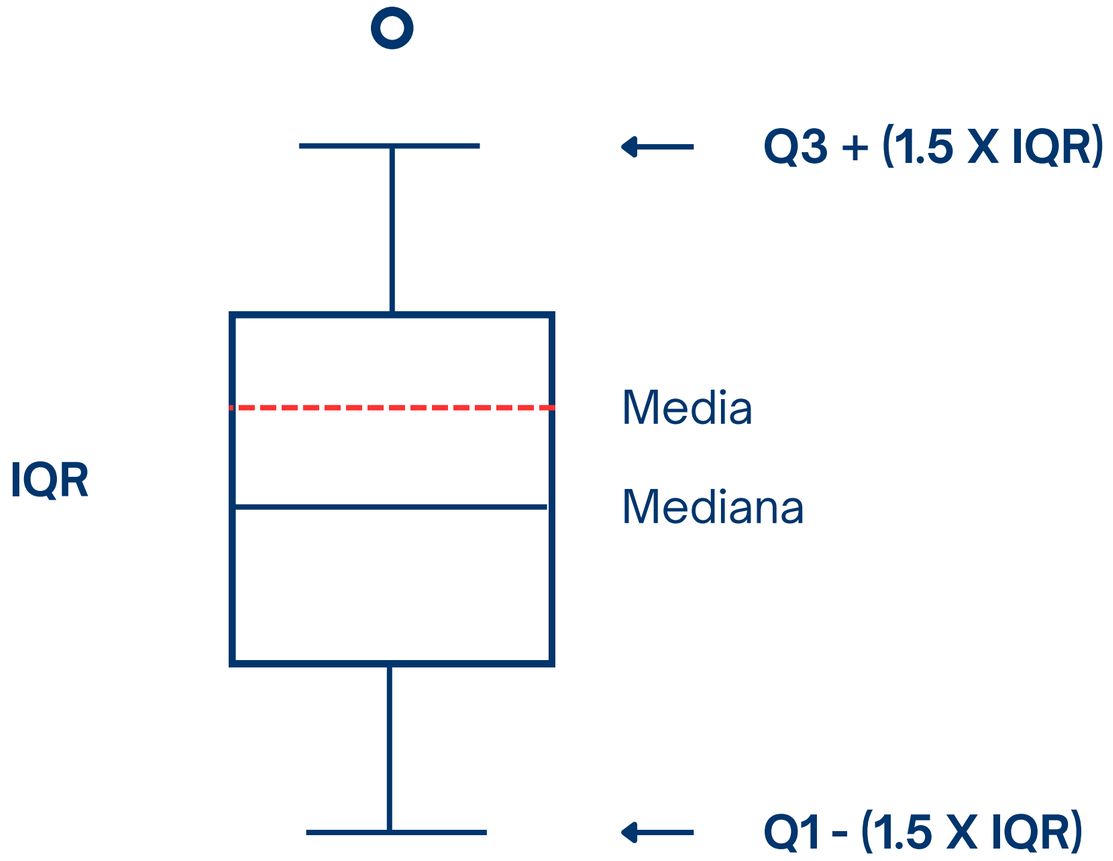

Medidas de dispersión

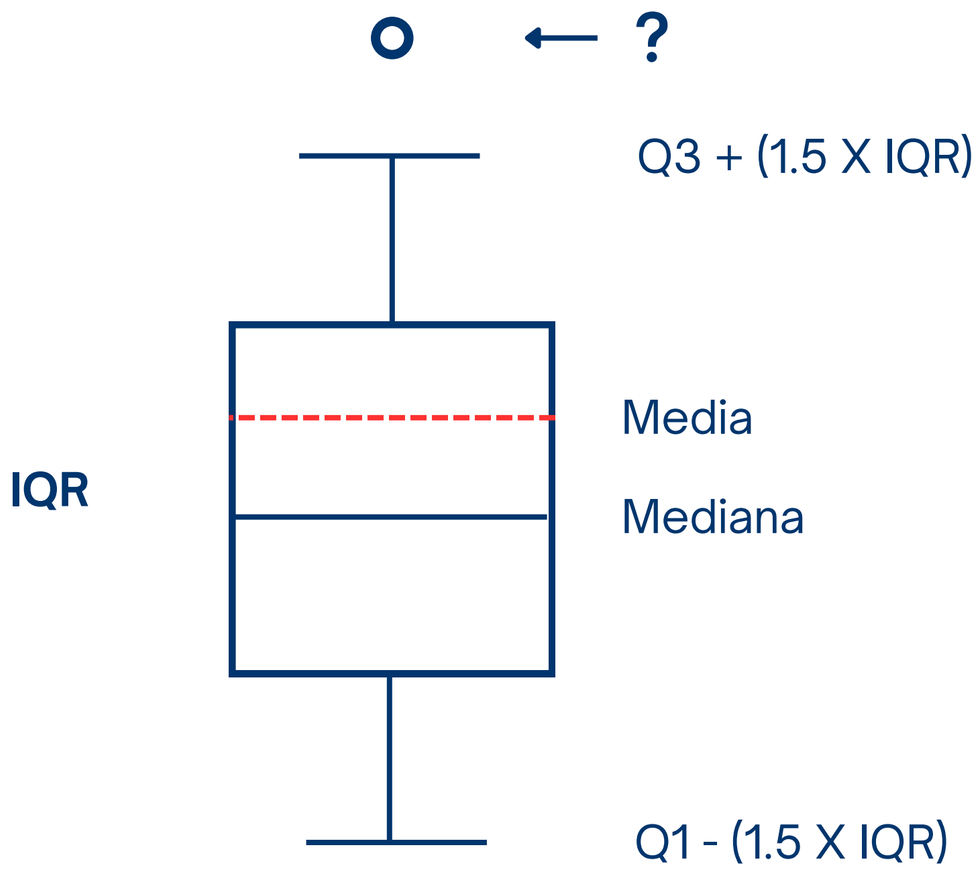

Medidas de dispersión

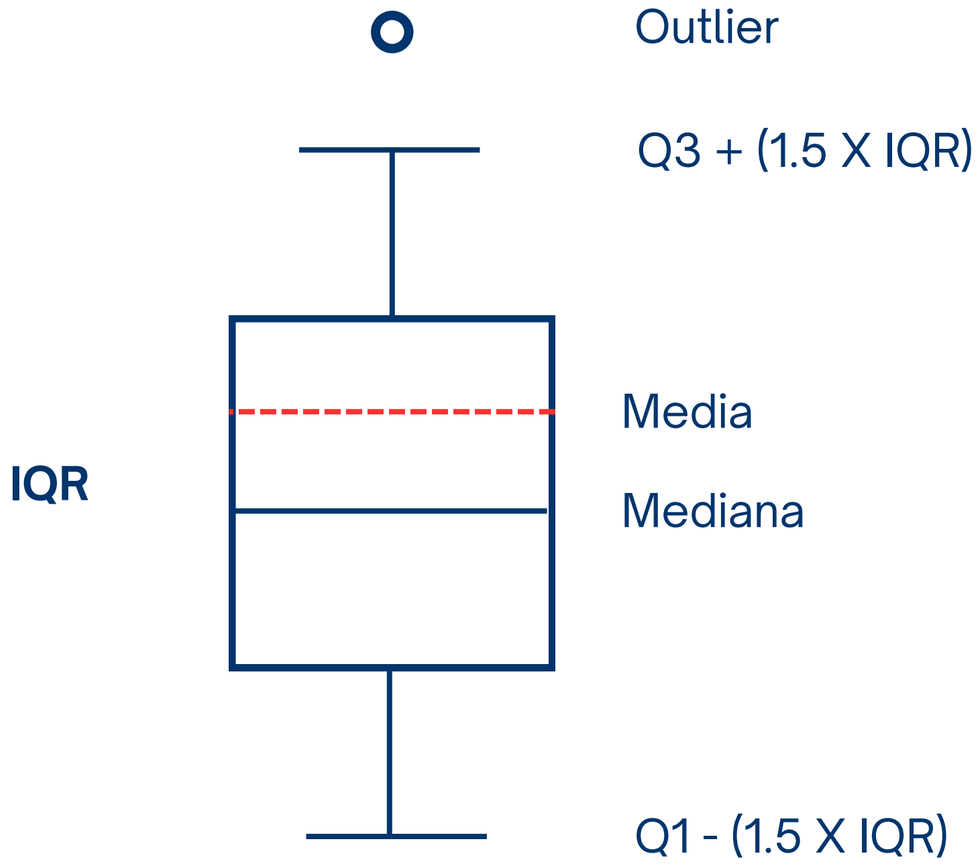

1. Medidas de tendencia central

2. Medidas de dispersión

3. **Datos faltantes**

Visualización de datos

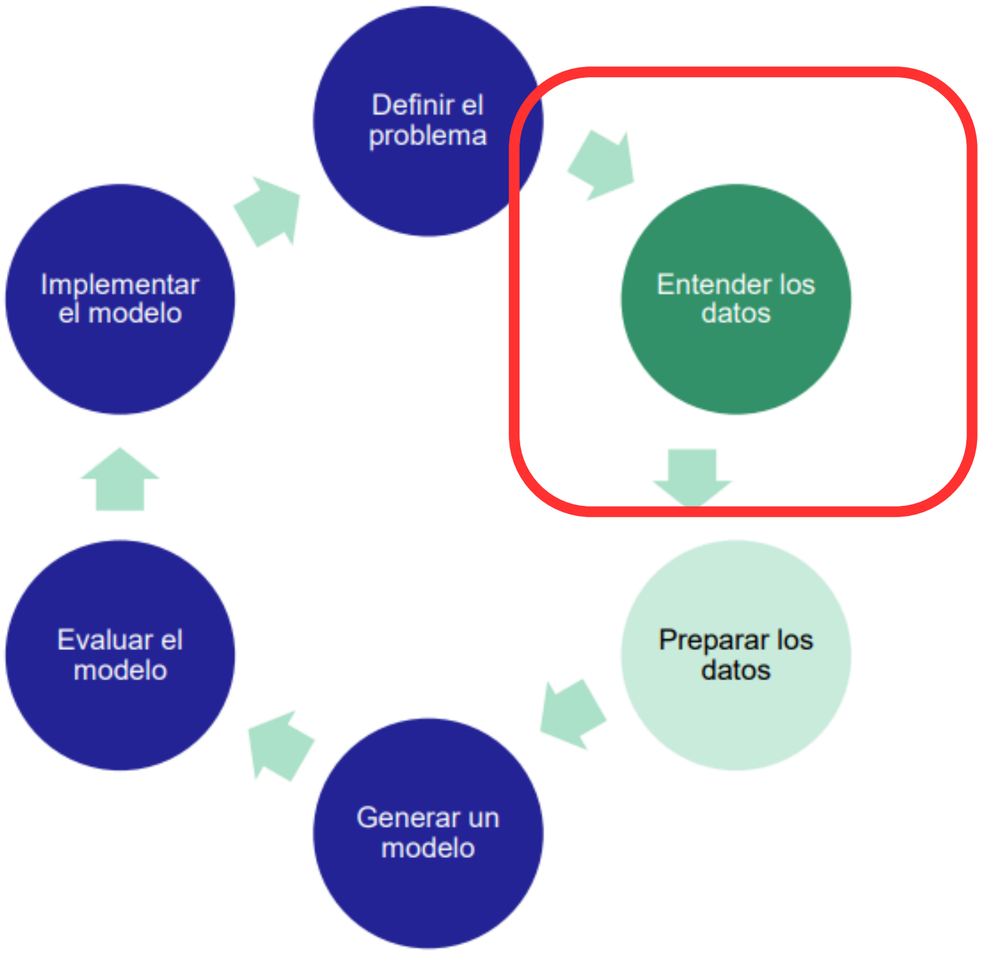

Visualización de datos

- Hace visibles patrones e insights que no se detectan fácilmente solo con números (tendencias, outliers, relaciones)
- Facilita la comprensión rápida, reduciendo el esfuerzo cognitivo de la audiencia
- Mejora la toma de decisiones, porque comunica información clave de forma clara y directa
- Evita interpretaciones erróneas, si está bien diseñada (sin distorsiones ni ruido visual)
- Permite comunicar una historia con datos, haciendo el mensaje más persuasivo y memorable

Elegir el gráfico equivocado

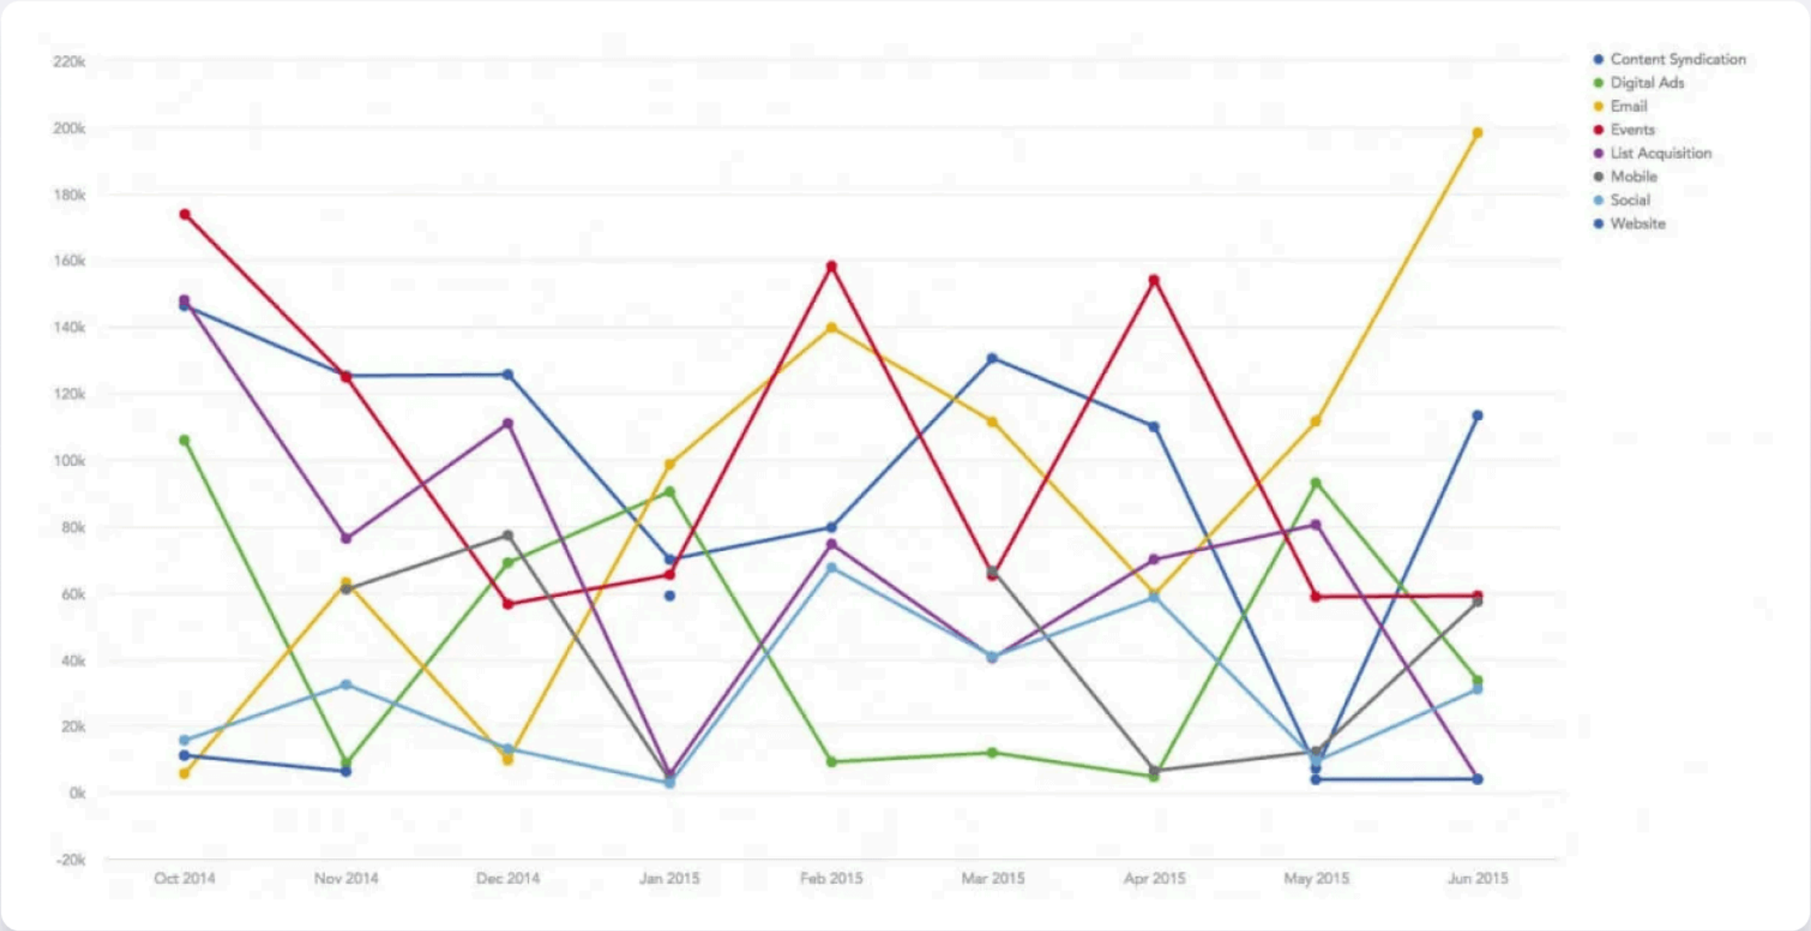

Complejizar la información sin sentido

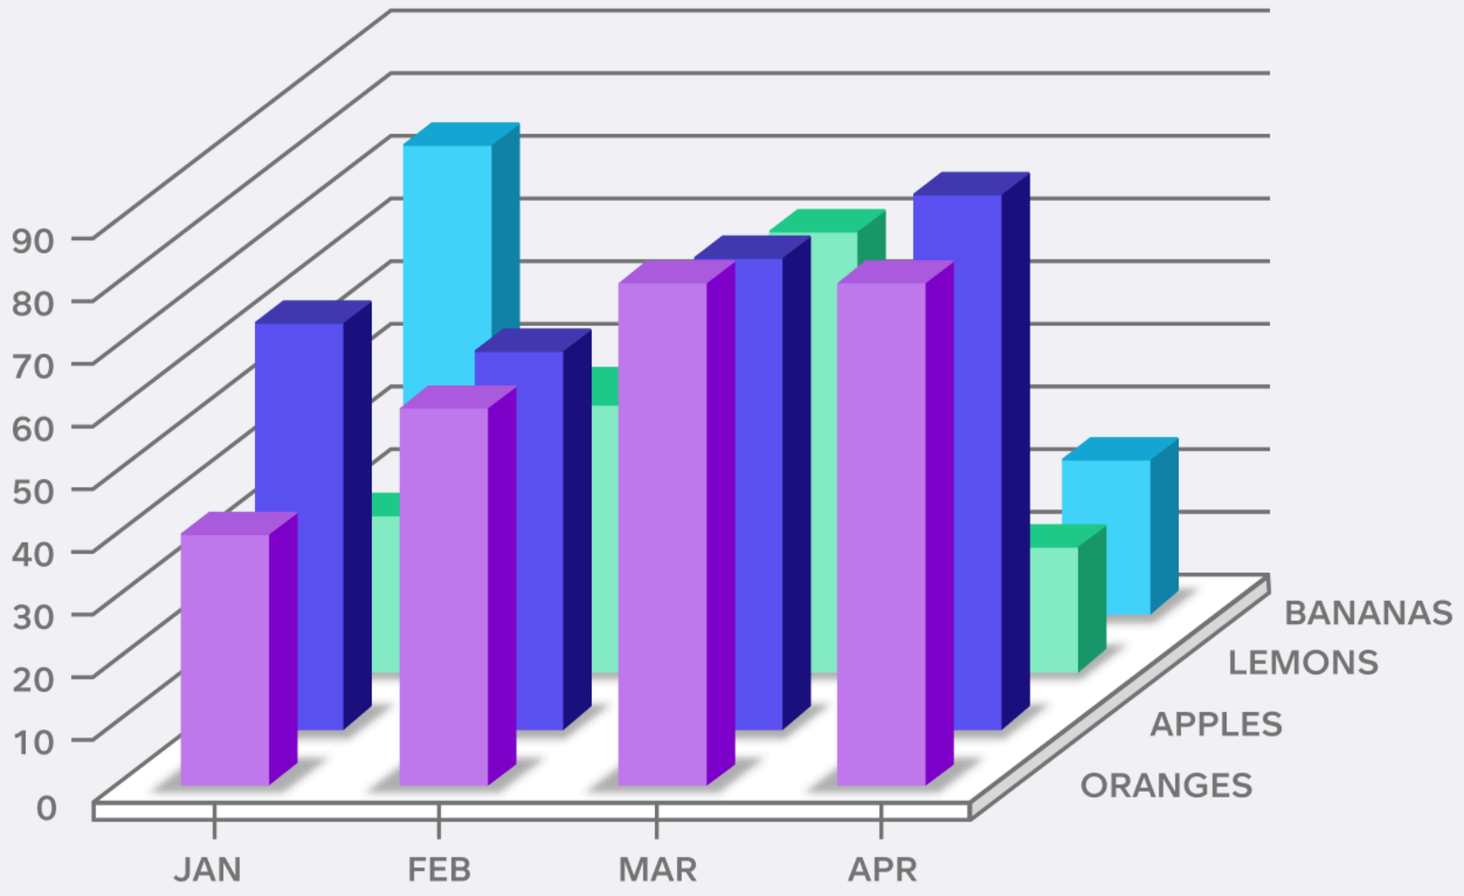

No decir NADA

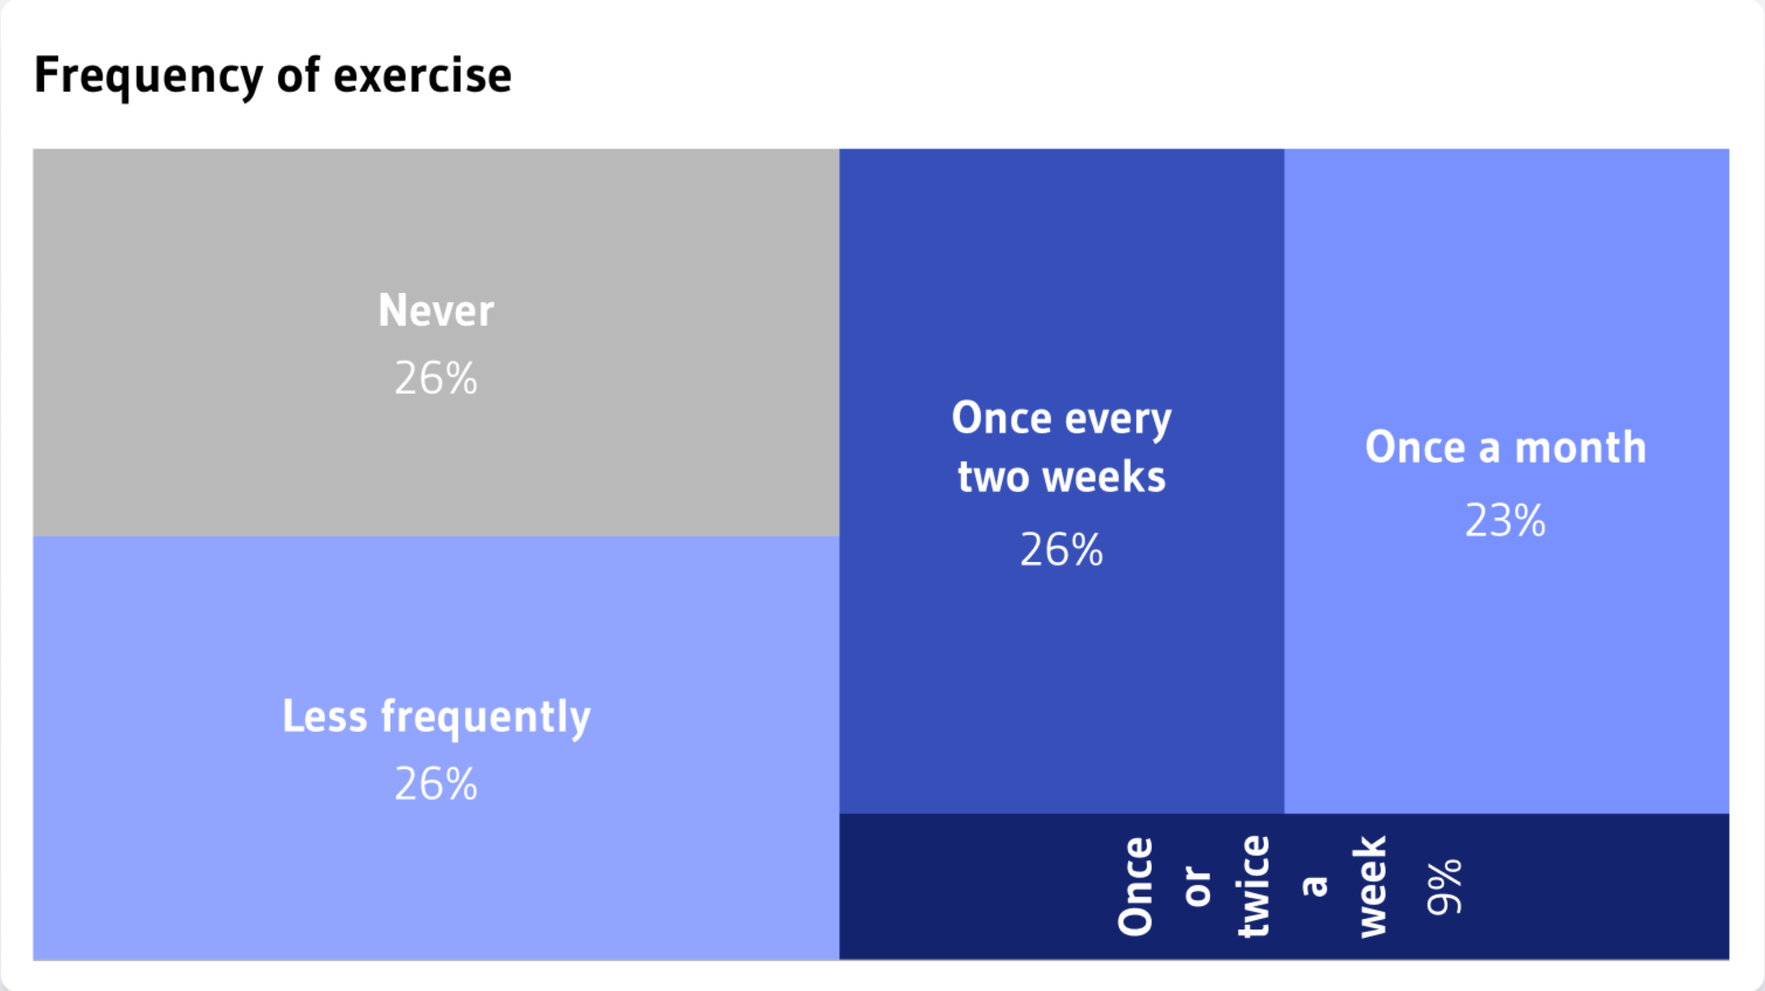

Mal uso del color

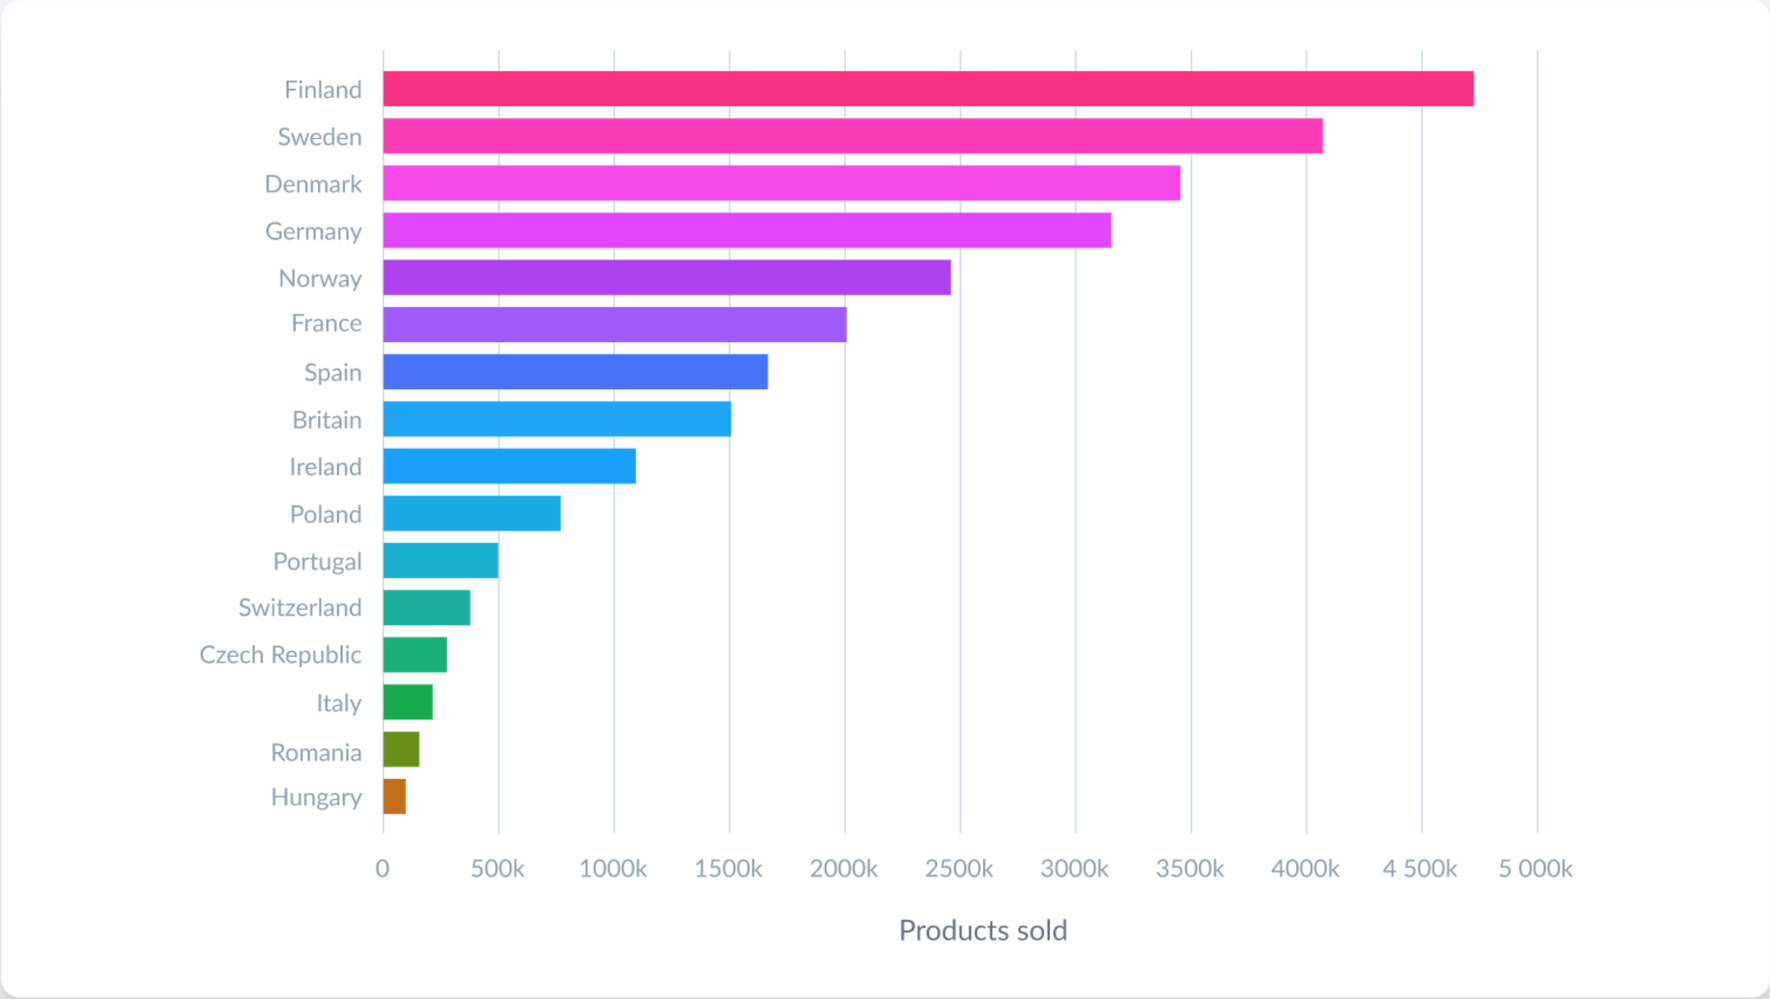

Usar 3D (Sin razón)

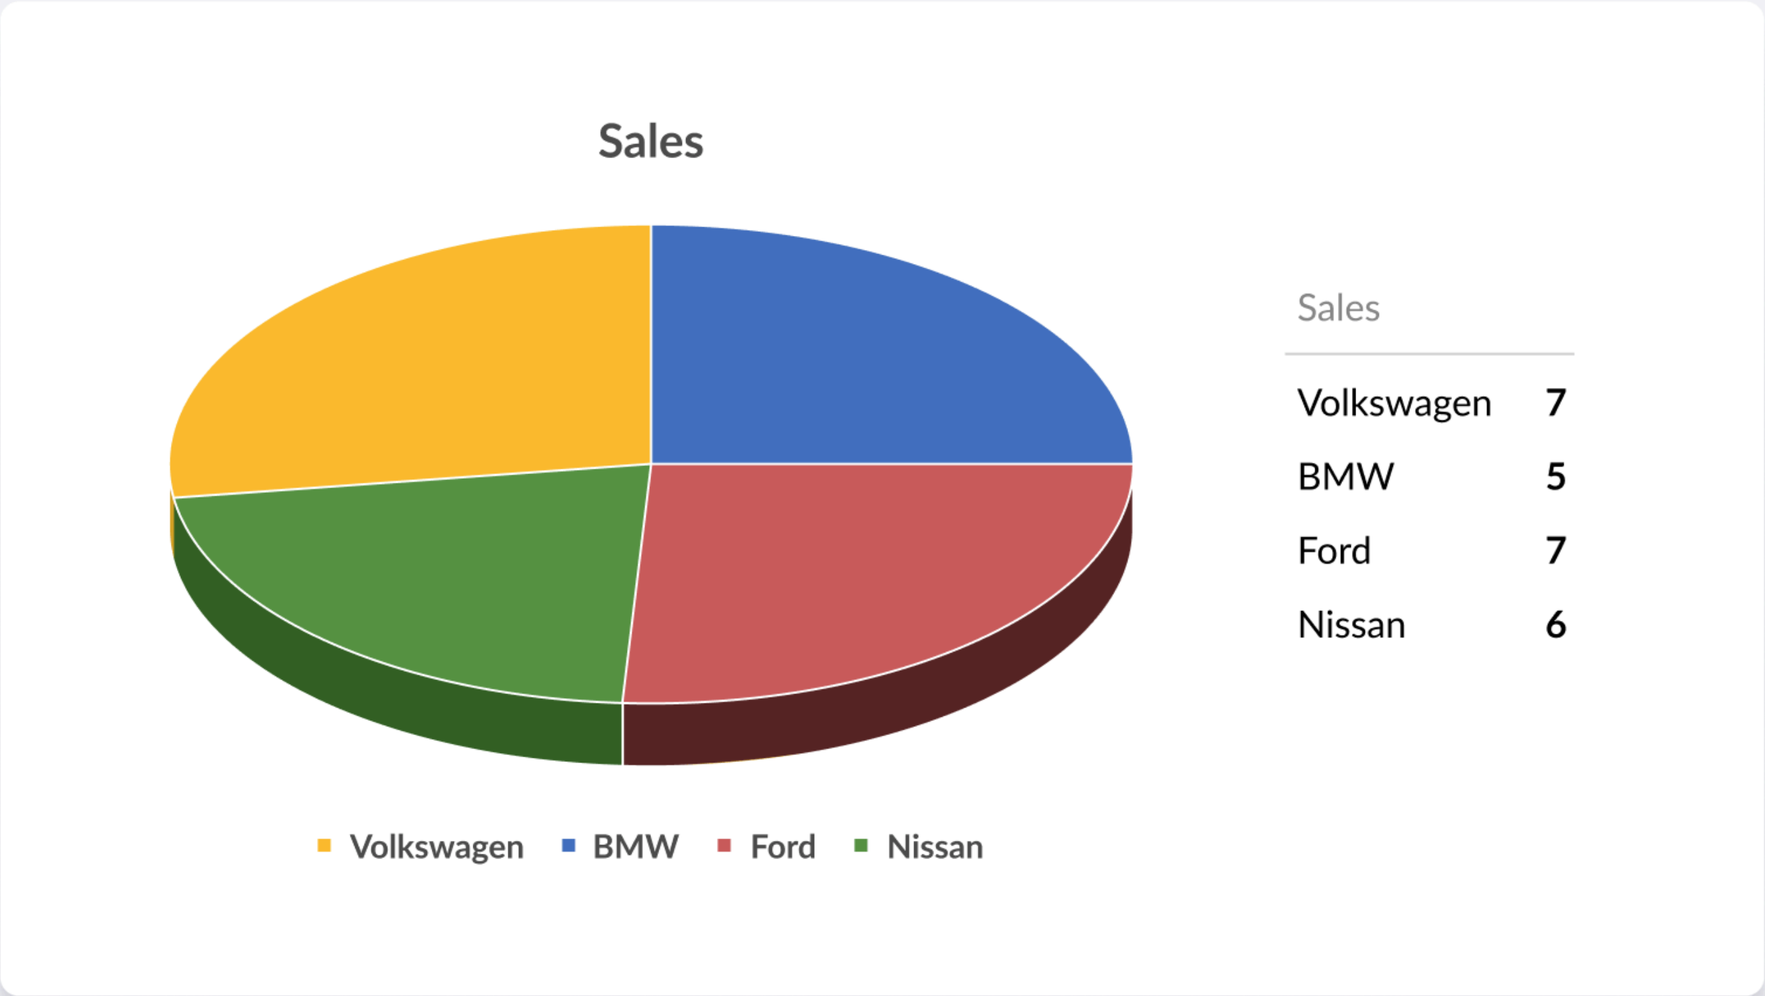

Hablemos de esto...

Barras apiladas, gráfico

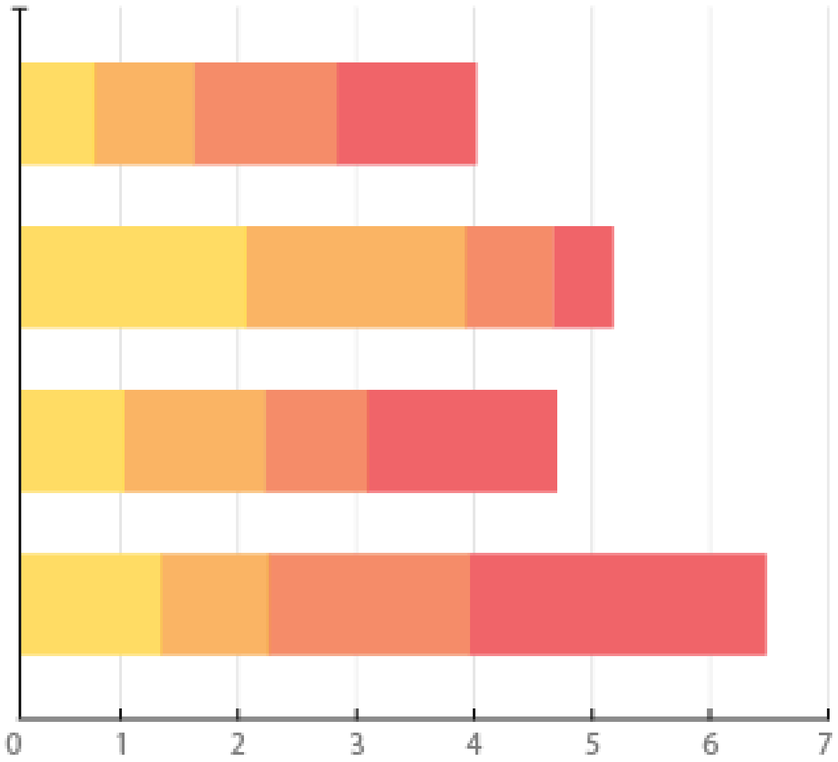

Hablemos de esto...

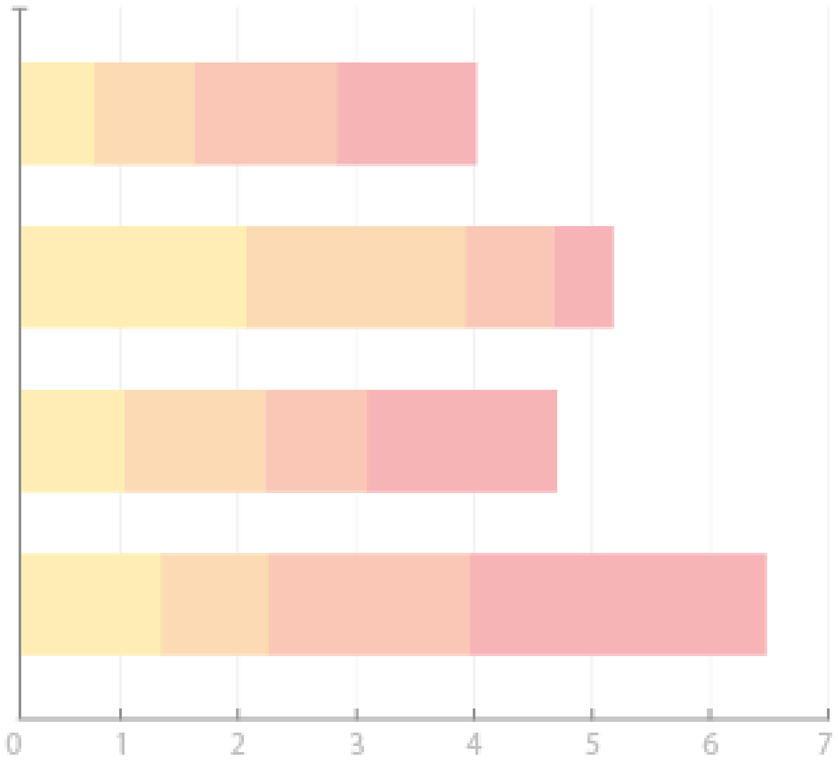

Barras apiladas, gráfico

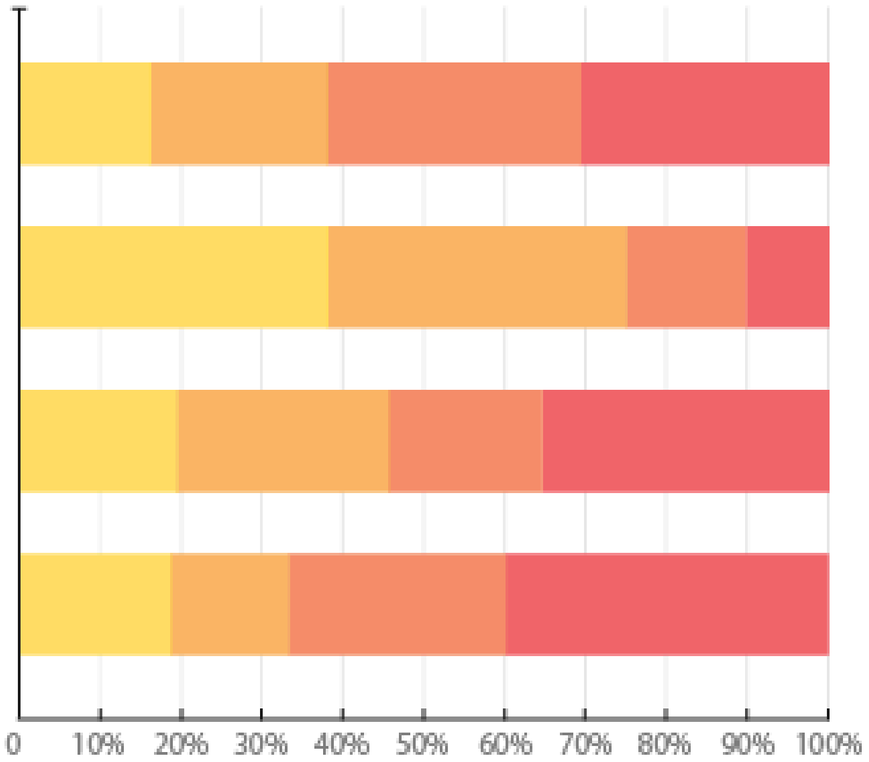

Hablemos de esto...

Gráfico de tortas

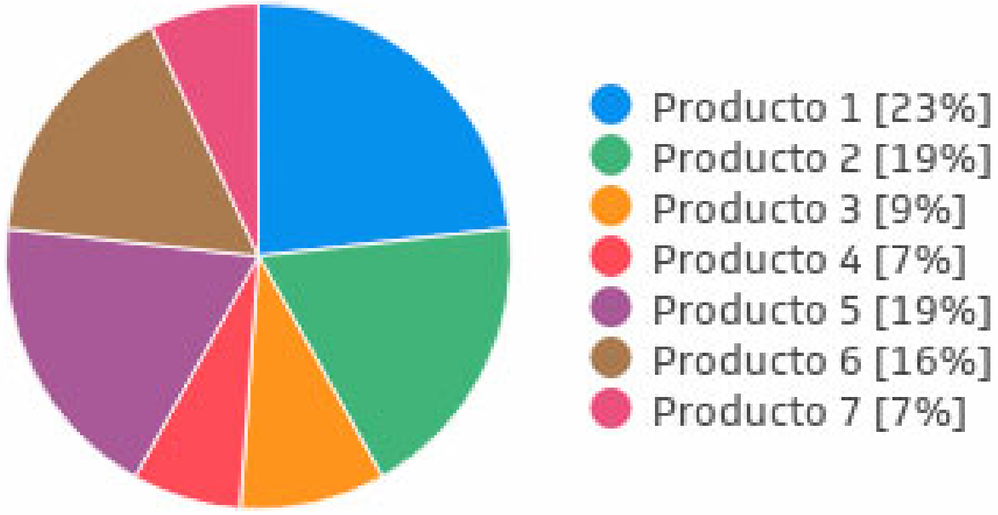

Hablemos de esto...

Gráfico de tortas

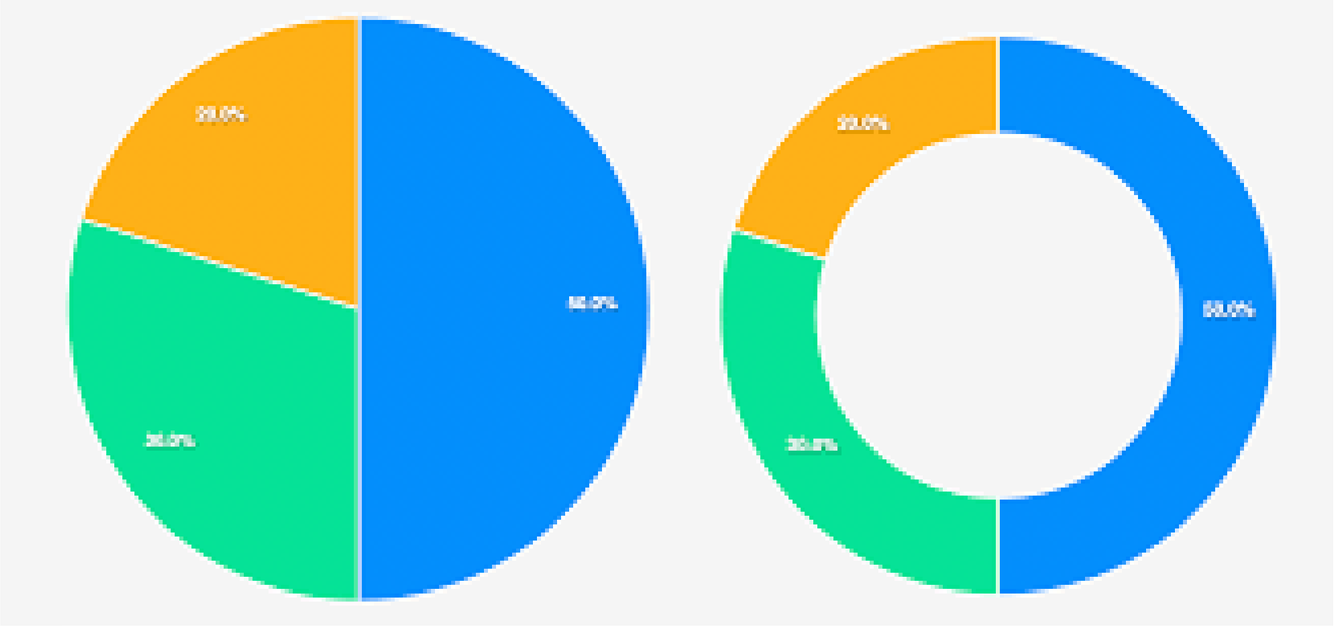

¿Cómo sería una buena visualización?

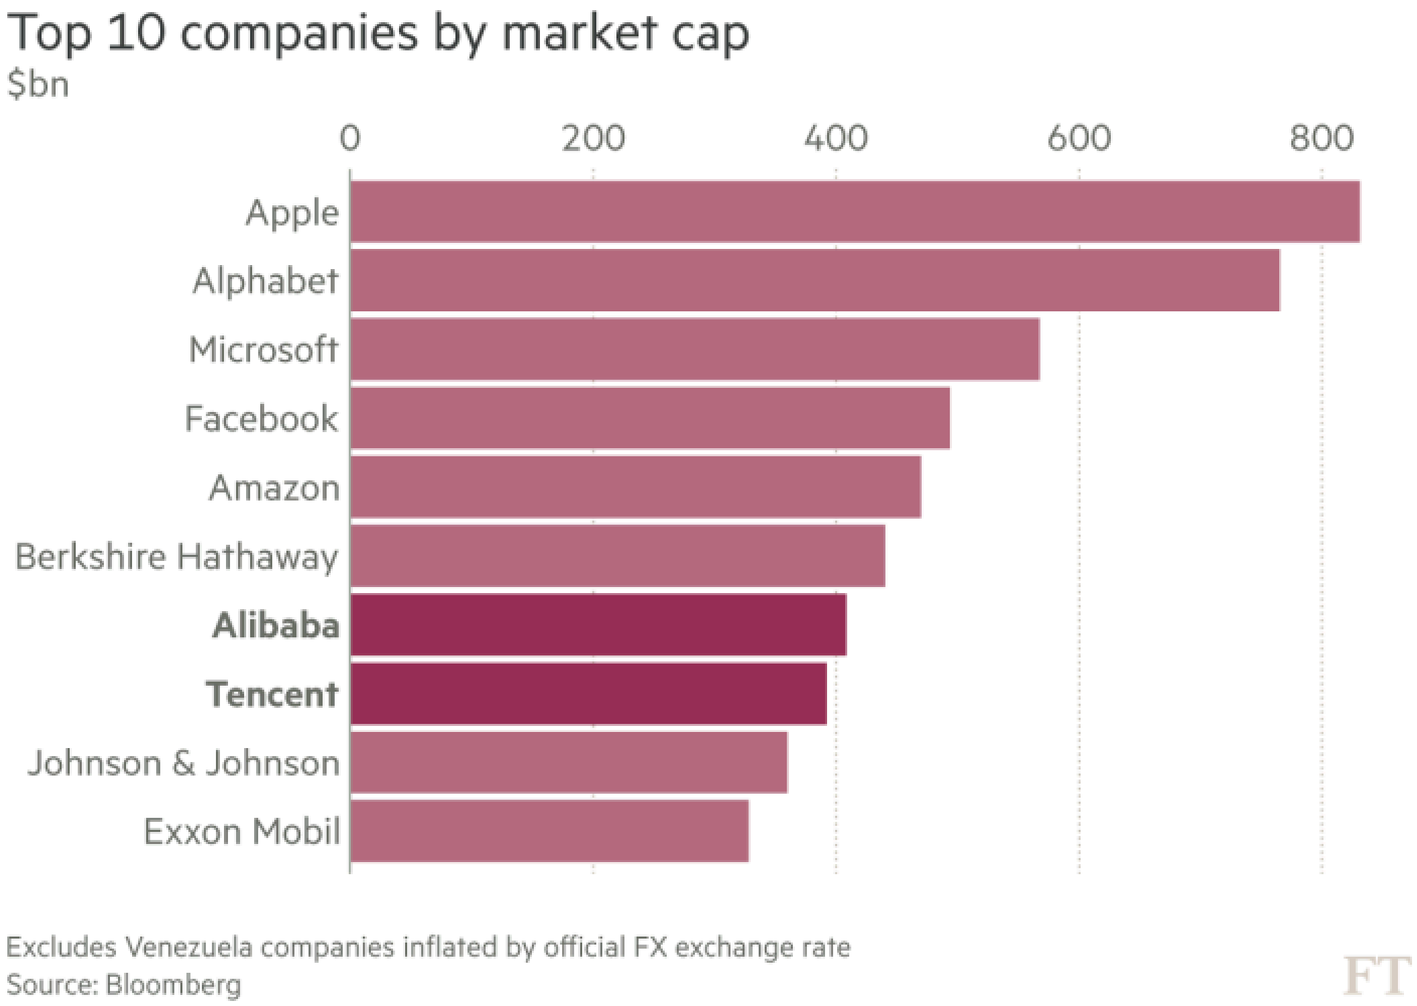
Top 10 companies by market cap
$bn
0
200
400
600
800
Apple
Alphabet
Microsoft
Facebook
Amazon
Berkshire Hathaway
Alibaba
Tencent
Johnson & Johnson
Exxon Mobil
Excludes Venezuela companies inflated by official FX exchange rate
Source: Bloomberg
FT

Good vs Bad Data Visualization: Information Congestion

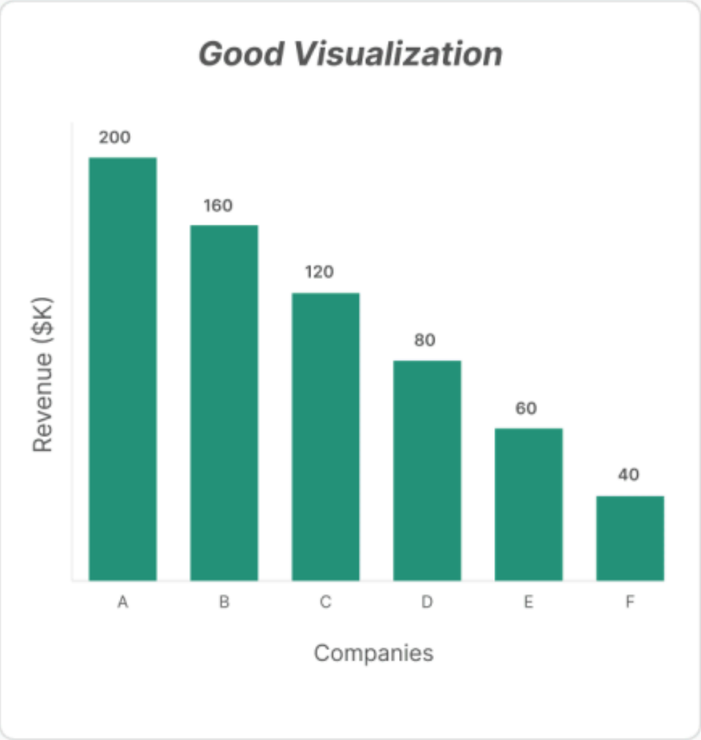

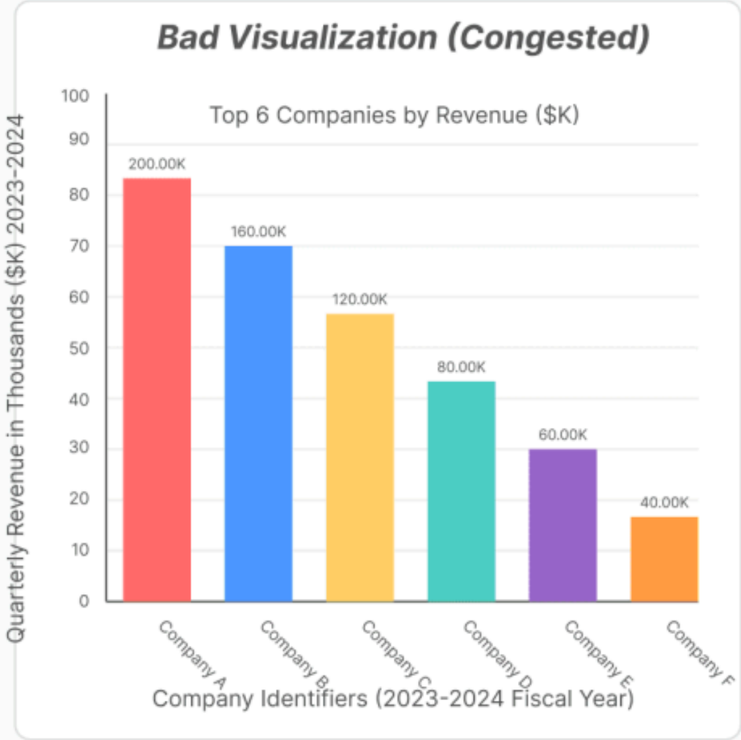

SR analytics

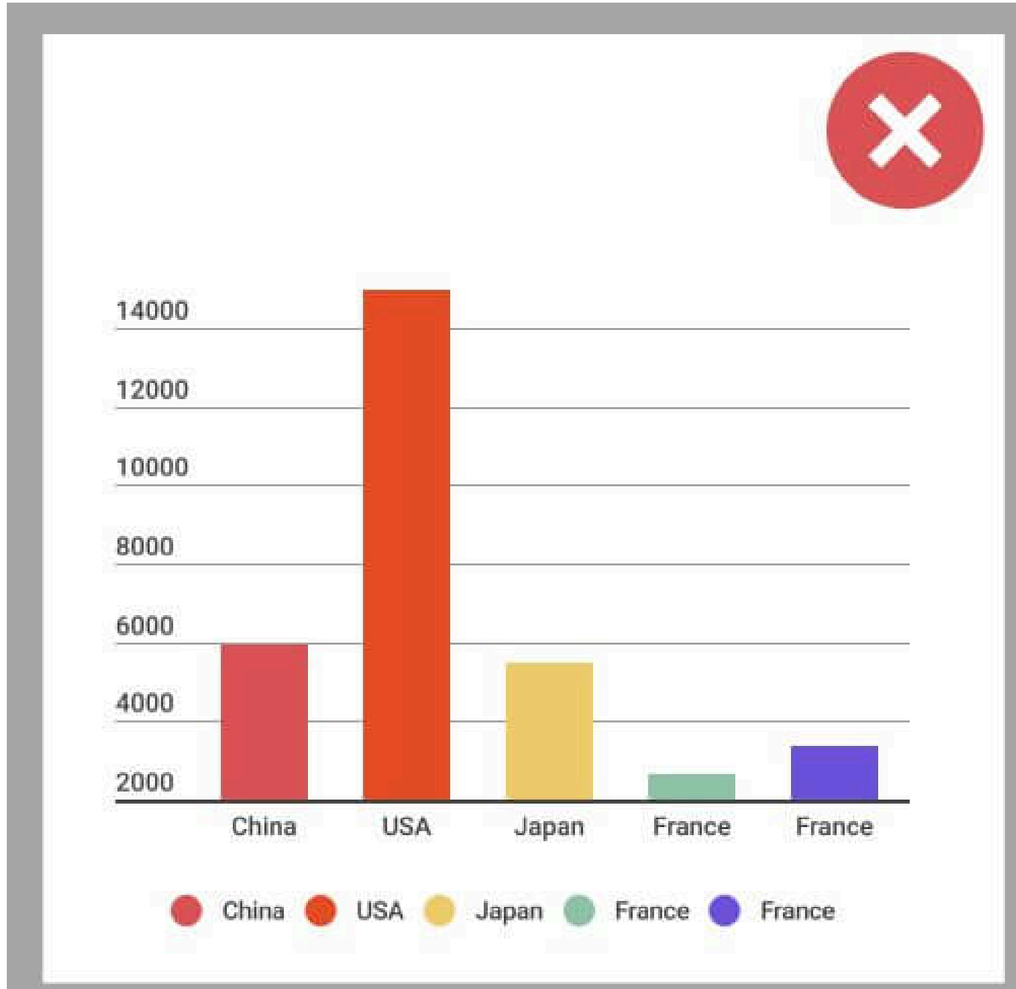
14000
12000
10000
8000
6000
4000
2000
China
USA
Japan
France
France
China
USA
Japan
France
France

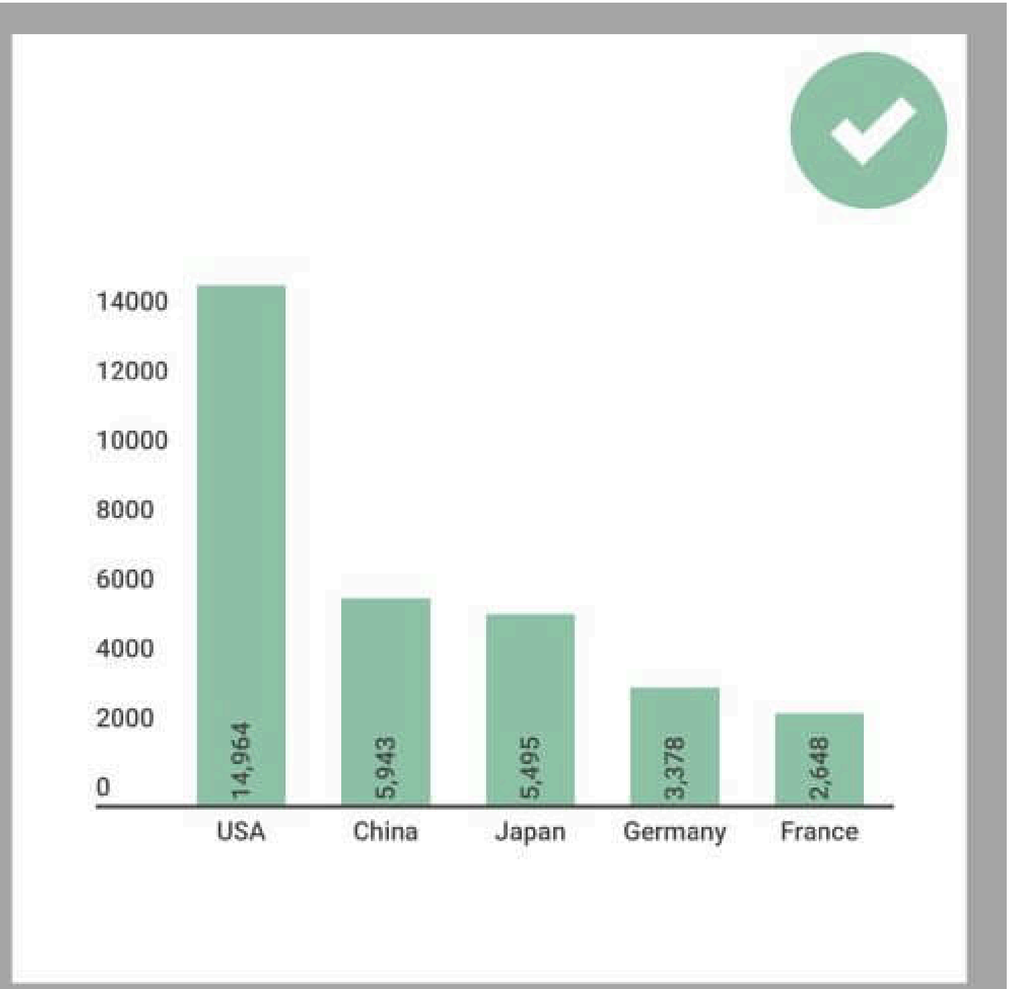
14000
12000
10000
8000
6000
4000
2000
0
14,964
5,943
5,495
3,378
2,648
USA
China
Japan
Germany
France

Pensemos entre todos

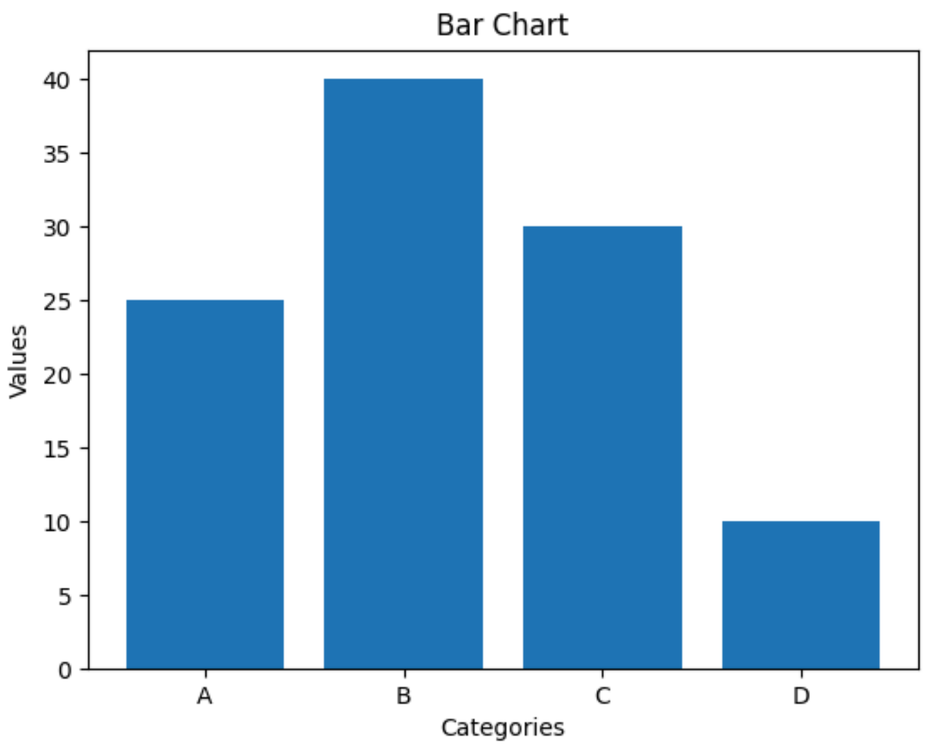

Pensemos entre todos

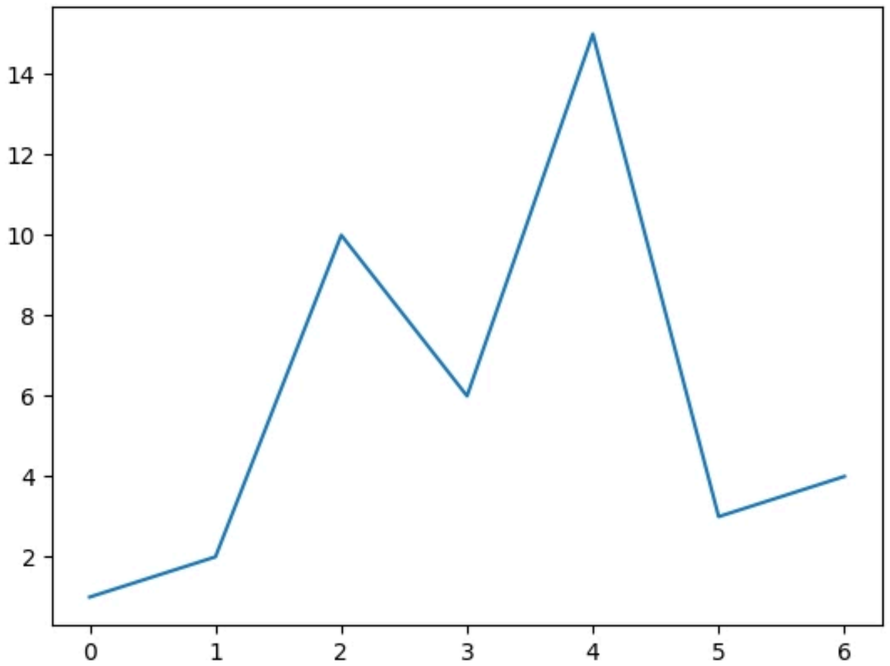

Trabajo Práctico

Analítica de Datos
Profesor: Ing. Pablo Sciolla

Actividad Práctica de Visualización de Datos

1. Objetivo

El objetivo de esta práctica es desarrollar habilidades de exploración, análisis y comunicación de datos, utilizando datos abiertos del Gobierno de la Ciudad de Buenos Aires para construir una historia basada en evidencia.

El portal de datos abiertos de la Ciudad reúne más de 400 datasets públicos sobre distintas áreas de gestión (transporte, educación, seguridad, ambiente, obras públicas, entre otros) que pueden ser descargados y reutilizados libremente para generar visualizaciones, análisis y nuevas ideas.

A partir de uno de estos datasets, cada equipo deberá identificar un insight interesante y comunicarlo mediante un storytelling claro y atractivo.

2. Consigna

1. Ingresar al portal de datos abiertos del Gobierno de la Ciudad de Buenos Aires: https://data.buenosaires.gob.ar/
2. Seleccionar un dataset que resulte interesante para analizar.
3. Realizar un análisis exploratorio de los datos, buscando patrones, tendencias o fenómenos relevantes.
4. Construir una historia basada en datos (data storytelling) que responda a una pregunta o problema claro.

Caso real de analítica de datos

Ausentismo en turnos médicos programados: una implementación de técnicas de aprendizaje automático

Universidad de San Andrés

Departamento de educación

Licenciatura en Ciencias del Comportamiento

Alumno: Juan Costa

Caso real de analítica de datos

Ausentismo en turnos médicos programados: una implementación de técnicas de aprendizaje automático

Universidad de San Andrés

Departamento de educación

Licenciatura en Ciencias del Comportamiento

Alumno: Juan Costa