


Analítica de Datos


Clase 4 - Modelos de Machine Learning


¿Qué tal con Pablo?


Agenda


- Regre Lineal
- Regre Logística
- KNN
- Notebooks
- Caso de aplicación
- Kahoot











Regresión Lineal

¿Qué es la regresión lineal?

Un modelo que intenta predecir un valor numérico usando una relación lineal entre variables.

Regresión Lineal

¿Qué es la regresión lineal?

Un modelo que intenta predecir un valor numérico usando una relación lineal entre variables.

Idea intuitiva

Busca dibujar una línea que mejor se ajuste a los datos.

Regresión Lineal

¿Qué es la regresión lineal?

Un modelo que intenta predecir un valor numérico usando una relación lineal entre variables.

Idea intuitiva


Busca dibujar una línea que mejor se ajuste a los datos.

¿Cómo aprende? Machine LEARNING

Ajusta la línea para minimizar el error entre:


- valores reales
- valores predichos

Regresión Lineal



Regresión Lineal

¿Que podría representar este gráfico?




Regresión Lineal


¿Que podría representar este gráfico?

X: Años de experiencia laboral

Y: Salario (en millones)




Regresión Lineal




$$y = m \cdot x + b$$

Regresión Lineal




$$y = m \cdot x + b$$

Regresión Lineal



$$y = m \cdot x + b$$

Regresión Lineal



$$y = m \cdot x + b$$

Regresión Lineal

Ejemplos

Años de experiencia vs salario

Más experiencia → mayor salario (relación positiva)

Horas estudiadas vs nota del examen

Más horas → mejor nota (positiva)

Temperatura vs consumo de calefacción

Más temperatura → menos calefacción (negativa)

Velocidad vs tiempo de viaje (misma distancia)

Más velocidad → menos tiempo (negativa)

Regresión Lineal

Ejemplos

¿Otros ejemplos?

Regresión Lineal

Supuestos (muy simple)

- Relación aproximadamente lineal
- No mucho ruido extremo (outliers afectan)

Ventajas

- Fácil de entender
- Rápido
- Buen baseline

Limitaciones

- Solo captura relaciones lineales
- Sensible a outliers
- Puede quedarse corto en problemas complejos

Regresión Lineal

Supuestos (muy simple)

- Relación aproximadamente lineal
- No mucho ruido extremo (outliers afectan)

Ventajas

- Fácil de entender
- Rápido
- Buen baseline

Limitaciones


- Solo captura relaciones lineales
- Sensible a outliers
- Puede quedarse corto en problemas complejos

¿Cómo funciona el LEARNING, dentro de MACHINE LEARNING?

Qué ahora el modelo aprendió como se comportan los datos, entonces cuando ingresemos un dato nuevo con un valor x y no conozcamos la y , lo vamos a poder predecir (o intentar).

En el caso de la regresión lineal, se situa el valor numérico sobre la linea de regresión

Regresión Lineal



¿Cómo se aplica esto en la vida real?

Aplicación real



Journal of Retailing xxx (xxx, xxxx) xxx–xxx



Joint In-Season and Out-of-Season Promotion Demand Forecasting in a Retail Environment

Jannik Wolters*, Arnd Huchzermeier

WHU – Otto Beisheim School of Management, Burgplatz 2, 56179 Vallendar, Germany

Abstract

Inaccurate forecasts of demand during promotions diminish the already meager profit margins of retailers. No forecasting method described in the literature can accurately account for the combination of seasonal sales variations and promotion-induced sales peaks over forecasting horizons of several weeks or months. We address this research gap by developing a forecasting method for seasonal, frequently promoted products that generates accurate predictions, can handle a large number of sales series, and requires minimal training data. In our method's first stage, we forecast the seasonal sales cycle by fitting a harmonic regression model to a decomposed training set, which excludes promotional and holiday sales, and then extrapolate that model to a testing set. In the second stage, we integrate the resulting seasonal forecast into a multiplicative demand function that accounts for consumer stockpiling and captures promotional and holiday sales uplifts. The final model is then fitted using ridge regression. We use sales data from a grocery retailing chain to compare the forecasting accuracy of our method with popular seasonal and promotion demand forecasting models at multiple aggregation levels for both short and long forecasting horizons. The significantly more accurate forecasts generated by our model attest to the merit of the approach developed here.

© 2021 New York University. Published by Elsevier Inc. All rights reserved.

Keywords: Demand forecasting; Seasonality; Price promotions; Retailing

JEL classification: L81; C51; C52; C53

Aplicación real

Imaginemos que ustedes son los responsables de un supermercado y la próxima semana van a sacar una **promoción**.

Si traen muy poco stock → *pierden ventas*

Si traen demasiado stock → *pierden dinero*

Entonces la pregunta de negocios es: **¿Cuántas unidades vamos a vender?**

Aplicación real

¿Cómo resolvemos esto? Usamos **datos del pasado** para hacer un modelo de predicción

Analizamos promociones anteriores y recogemos información como:

- Nivel de descuento
- Temperatura (la gente consume más cuando hace calor)
- Si es feriado o no
- Ventas pasadas

¿Esto sería un caso de aprendizaje supervisado o no supervisado?

Aplicación real

¿Que hacemos? Una **regresión lineal**

Ventas = base + (efecto del descuento) + (efecto de la temperatura) + (efecto del feriado)

Efectos

Más descuento → aumentan las ventas

Más temperatura → aumentan las ventas

Feriatos → aumentan mucho las ventas

Aplicación real

¿Que hacemos? Una **regresión lineal**

- ✓ Mejora significativa en la precisión frente a modelos tradicionales
- ✓ Mejor predicción en productos estacionales
- ✓ Funciona incluso con pocos datos históricos

Aplicación real

¿Que hacemos? Una **regresión lineal**

- ✓ Mejora significativa en la precisión frente a modelos tradicionales
- ✓ Mejor predicción en productos estacionales
- ✓ Funciona incluso con pocos datos históricos

Impacto en negocio

Con mejores predicciones:

- ✓ Menos quiebres de stock
- ✓ Menos sobrestock
- ✓ Más promociones rentables

Regresión Logística

La diferencia con la regresión lineal es...

Regresión Logística

La diferencia con la regresión lineal es que la regresión lineal predice un número y la regresión logística predice una ***categoría***

Regresión Logística

La diferencia con la regresión lineal es que la regresión lineal predice un número y la regresión logística predice una ***categoría***

binaria

Regresión Logística

La regresión logística utiliza una fórmula para predecir la probabilidad de que un dato pertenezca a una clase

Regresión Logística

La regresión logística utiliza una fórmula para predecir la probabilidad de que un dato pertenezca a una clase

Cómo predigo probabilidades, la regresión logística va a dar un número entre 0 y 1

Regresión Logística


La regresión logística utiliza una fórmula para predecir la probabilidad de que un dato pertenezca a una clase

Cómo predigo probabilidades, la regresión logística va a dar un número entre 0 y 1



Después, va a asignar un umbral para decidir si el dato pertenece a la clase A o a la clase B, en función de sus probabilidades

Regresión Logística

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



Regresión Logística



¿Cómo funciona el modelo?

1. Tengo un nuevo punto
2. El modelo calcula la probabilidad de qué ese punto sea de alguna clase
3. Establece un umbral de decisión
4. Predice la categoría

¿Cómo funciona el modelo?

1. Tengo un nuevo punto
2. El modelo calcula la probabilidad de qué ese punto sea de alguna clase
3. Establece un umbral de decisión
4. Predice la categoría

Pregunta medio tramposa...

¿Cómo funciona el modelo?

Si el output de la regresión logística es un número (De 0 a 1), ¿por qué es un modelo de clasificación?

¿Cómo funciona el modelo?

Si el output de la regresión logística es un número (De 0 a 1), ¿por qué es un modelo de clasificación?

Porque la clasificación no depende de la probabilidad, sino del umbral de decisión que le pongamos

¿Cómo funciona el modelo?

¿Cómo elijo mi umbral de decisión?

Regresión Logística



Regresión Logística

Estoy prediciendo si una persona va a cometer un delito

1 = Comete el delito

0 = No comete el delito

Regresión Logística

Estoy prediciendo si una persona va a cometer un delito

1 = Comete el delito

0 = No comete el delito

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

Regresión Logística

Estoy prediciendo si una persona va a cometer un delito

1 = Comete el delito

0 = No comete el delito

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

¿Qué pasa si tengo un umbral de decisión bajo? (Cercano a 0)

Regresión Logística

Estoy prediciendo si una persona va a cometer un delito

1 = Comete el delito

0 = No comete el delito

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

¿Qué pasa si tengo un umbral de decisión bajo? (Cercano a 0)

¿es peor señalar como delincuentes a personas que en realidad no van a cometer ningún delito, o no identificar a quienes sí lo van a cometer?

Regresión Logística



Regresión Logística

Estoy prediciendo si una persona va a faltar a su turno médico

1 = Falta

0 = No falta

Regresión Logística

Estoy prediciendo si una persona va a faltar a su turno médico

1 = Falta

0 = No falta

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

¿Qué pasa si tengo un umbral de decisión bajo? (Cercano a 0)

Regresión Logística

Estoy prediciendo si una persona va a faltar a su turno médico

1 = Falta

0 = No falta

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

¿Qué pasa si tengo un umbral de decisión bajo? (Cercano a 0)

¿Es preferible marcar como “faltador” a un paciente que en realidad asistirá a su turno, o asumir que un paciente asistirá cuando en realidad no lo hará?

Regresión Logística

En síntesis, **no hay respuesta correcta** - Uno tiene que ajustar de acuerdo al problema que esté prediciendo

Regresión Logística

Ventajas

Fácil de interpretar

Rápido

Probabilidades claras

Funciona bien con pocos datos

Desventajas

Solo separa de forma lineal

No capta relaciones complejas

Sensible a outliers

Requiere buen feature engineering

KNN

Necesito UN voluntario

KNN

KNN (K-Nearest Neighbors) es un algoritmo de machine learning **supervisado** que:

- Sirve para clasificación y *regresión*
- Se basa en una idea simple
 - Cuanto más cerca estás de algo, más te pareces

Modelos paramétricos y no paramétricos

Algo a tener en cuenta...

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **paramétrico**?

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **paramétrico**?

$$Y = \beta_0 + \beta_1 X_1$$

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **paramétrico**?

Que tiene...

$$Y = \beta_0 + \beta_1 X_1$$

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **paramétrico**?

Que tiene ¡parámetros!

$$Y = \beta_0 + \beta_1 X_1$$

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **no paramétrico**?

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **no paramétrico**?

NO asume una forma fija para la relación entre
variables

y

NO tiene un número fijo de parámetros que aprender

“No voy a imponer una fórmula. Voy a dejar que los datos definan la forma.”

Modelos paramétricos y no paramétricos

Regresión: Paramétrico

KNN: No Paramétrico

KNN

KNN es un algoritmo supervisado, de clasificación, no paramétrico

KNN


KNN es un algoritmo supervisado, de clasificación, no paramétrico

¿Cómo funciona KNN?

KNN

1. Aparece un nuevo punto qué quiero predecir
2. Calculo la ***DISTANCIA*** a los otros puntos de mi dataset
3. Elijo cuantos **K** vecinos más cercano quiero considerar
4. **Clasifica** (Con clase mayoritaria) o **Regresiona** (Con el valor promedio)

KNN



KNN

¿Cual es el K ideal?

KNN

¿Cual es el K ideal? Depende de tu problema

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un K muy chico?

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

¿Si tengo un **K muy grande**?

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

¿Si tengo un **K muy grande**? Tengo un modelo muy general

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

¿Si tengo un **K muy grande**? Tengo un modelo muy general

¿Si tengo un **K medio**?

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

¿Si tengo un **K muy grande**? Tengo un modelo muy general

¿Si tengo un **K medio**? Hay que encontrar el equilibrio

KNN

¿Cual es el K ideal? Depende de tu problema


*¿Si tengo un **K muy chico**? Tengo un modelo muy sensible*

*¿Si tengo un **K muy grande**? Tengo un modelo muy general*

*¿Si tengo un **K medio**? Hay que encontrar el equilibrio*

K tiene que tener una característica...

KNN



KNN

Tipos de distancia

KNN

Tipos de distancia

Euclidiana

Manhattan

Hamming

Minkowski

KNN

Distancia Euclidiana

La distancia euclidiana es la distancia “normal” en línea recta entre dos puntos en un espacio.


KNN

Distancia Euclidiana

La distancia euclidiana es la distancia “normal” en línea recta entre dos puntos en un espacio.


KNN

Distancia Euclidiana



KNN

Distancia Euclidiana



KNN


Distancia de Manhattan

La distancia Manhattan mide la distancia entre dos puntos sumando las diferencias absolutas en cada dimensión

No vas en línea recta, sino “en L” (horizontal + vertical), como si no pudieras cortar en diagonal.


KNN

Distancia Manhattan



KNN

Distancia Manhattan



KNN

¿Qué distancia uso?

KNN

¿Qué distancia uso? DEPENDE



KNN

El problema de la distancia

KNN es muy sensible a la escala

KNN

El problema de la distancia

KNN es muy sensible a la escala

Edad 0-100

Ingreso 0-1.000.000

Toda mi distancia va a estar **dominada** por la variable ingreso, y los cambios en la edad no van a ser muy determinantes.

KNN

El problema de la distancia

¿Cómo lo soluciono?

KNN

El problema de la distancia

¿Cómo lo soluciono?

Estandarizando / Normalizando

KNN

Persona	Edad	Ingresos
A	22	25,000
B	25	30,000
C	28	45,000
D	30	50,000
E	35	60,000
F	40	200,000
G	45	300,000
H	50	500,000
I	55	700,000
J	60	900,000

KNN

StandardScaler

$$z = \frac{x - \mu}{\sigma}$$

Calculo la media y la desviación standard

KNN

Persona	Edad (z)	Ingresos (z)
A	-1.36	-0.88
B	-1.12	-0.86
C	-0.88	-0.81
D	-0.72	-0.79
E	-0.32	-0.76
F	0.08	-0.28
G	0.48	0.07
H	0.88	0.75
I	1.28	1.45
J	1.68	2.14

KNN

El problema de la distancia

¿Cómo lo soluciono?

Estandarizando / Normalizando

StandardScaler → datos normales, uso general

MinMaxScaler → cuando necesitás valores entre 0 y 1

RobustScaler → cuando hay outliers

MaxAbsScaler → datos sparse (muchos ceros)

KNN

Ejemplos...

KNN

Ejemplos...

Diagnóstico médico

Algoritmo de recomendaciones

Precio de propiedades

Desempeño de estudiantes

KNN

Ventajas de KNN

Fácil de entender e implementar

Sirve para clasificación y regresión

Puede capturar relaciones complejas

Desventajas de KNN

Lento en predicción (compara con todos los datos)

Sensible a la escala de variables

Depende de la métrica de distancia

Sensible al ruido y outliers

Problemas en alta dimensión (curse of dimensionality)

Regre Logística + KNN

Notebook

Repaso

Machine Learning

Aprende patrones de datos para predecir o tomar decisiones.

Modelo

Función que aprende de los datos y genera predicciones.

Supervisado

Aprende usando datos con variable objetivo (target).

No Supervisado

Encuentra patrones sin variable objetivo.

Clasificación

Predice categorías (ej: sí/no, spam/no spam).

Regresión

Predice valores numéricos continuos.

Repaso

Regresión Lineal

Modelo que predice valores usando una relación lineal.

Regresión Logística

Modelo que predice probabilidades para clasificar.

KNN

Predice según los vecinos más cercanos.

Distancia

Mide qué tan similares son los datos (ej: euclidiana).

Paramétrico

Modelo con forma fija y parámetros definidos.

No Paramétrico

Modelo flexible que se adapta a los datos.

Repaso

Overfitting

Aprende demasiado → no generaliza.

Underfitting

Aprende poco → mal desempeño.

Umbral de decisión

Define cómo se asigna una clase.

Escalado de datos

Ajusta variables para que sean comparables.

Repaso

Data Cleaning

Proceso de limpiar y preparar los datos.

Datos nulos

Valores faltantes que deben tratarse.

Outliers

Valores extremos que pueden afectar el modelo

Inconsistencias

Datos mal cargados o con formatos distintos.